

EFICIENCIA DE MODELOS LLM PARA INDUSTRIAS ESTRATÉGICAS

EMIE

2.2 Investigación en Multimodalidad en modelos LLM e IA

Fecha- 2025

MULTIVERSE COMPUTING S.L.
LIS DATA SOLUTIONS S.L.
DATUA IA S.A.
IBERDROLA ESPAÑA



Índice

1. Introducción	2
2. Revisión del Estado del Arte en Modelos Multimodales.....	10
2.1 Codificadores de imagen	15
2.2 Conectores o projectors.....	17
2.3 Adición de audio y expansión a modos no visuales.....	18
2.4 Embeddings multimodales y almacenamiento semántico compartido	21
2.5 Evaluación, benchmarks y limitaciones del estado del arte	22
2.6 Lectura del estado del arte desde la transferencia empresarial.....	25
3. Análisis de Requisitos y Casos de Uso	26
3.1 Delimitación funcional de los casos de uso dentro de EMIE	29
3.2 Requisitos de negocio transversales	30
3.3 Caso de uso A: asistencia multimodal al mantenimiento	31
3.4 Caso de uso B: RAG multimodal documental para Iberdrola.....	32
3.5 Requisitos funcionales derivados	34
3.6 Requisitos no funcionales y restricciones de diseño.....	35
3.7 Priorización de casos de uso y senda recomendada de despliegue.....	36
3.8 Síntesis del análisis.....	37
4. Marco de Trabajo para la Investigación Multimodal	37
4.1 Objetivos y preguntas de investigación	38
PI-1: Capacidad de los modelos de embedding multimodal para recuperación cross-modal sobre documentación técnica.....	38
PI-2: Impacto del modality gap en la calidad de la recuperación	39
PI-3: Eficacia de la estrategia de página-como-imagen para indexación de PDFs técnicos.....	41
PI-4: Calidad de las respuestas generadas en función de la calidad del RAG previo	42
PI-5: Comparación de modelos de embedding en tarea de identificación visual sobre documentación técnica.....	42
4.2 Criterios de evaluación y métricas	42
Métricas de recuperación	43
Métricas de generación.....	44
Métricas operativas	44
4.3 Arquitectura de referencia del pipeline experimental	45



Etapa 1: Ingestión y preprocesado.....	45
Etapa 2: Generación de embeddings multimodales	46
Etapa 3: Recuperación por similitud	46
Etapa 4: Generación de respuesta	47
4.4 Selección de modelos y justificación	48
Modelos de embedding multimodal.....	48
Modelo generador	51
4.5 Datasets y escenarios de prueba.....	52
Escenario 1 – Imágenes con texto visible (Experimento Perros)	52
Escenario 2 – Imágenes industriales con texto (Experimento Grúas)	53
Escenario 3 – PDFs documentales heterogéneos (Experimento PDFs Financieros).....	53
Escenario 4 – Manuales técnicos de motos (Escenario cuasi-industrial)	54
Escenario 5 – Vídeos, audios, imágenes y PDFs de temáticas lejanas.....	54
4.6 Estrategia de indexación: página-como-imagen vs. parsing multimodal	54
Justificación técnica.....	55
Limitaciones conocidas.....	56
4.7 Metodología de validación.....	56
Validación de la recuperación.....	56
Validación del modality gap	57
Limitaciones metodológicas.....	58
5. Exploración de Técnicas Innovadoras en Multimodalidad	59
5.1 RAG multimodal: de la recuperación textual a la recuperación cross-modal	60
Paradigma A: Textualización completa.....	60
Paradigma B: Indexación multimodal separada con fusión de resultados	61
Paradigma C: Indexación multimodal unificada.....	61
5.2 Embeddings multimodales unificados: técnicas de alineamiento entre espacios latentes.....	62
Diferencias arquitectónicas entre los modelos evaluados	63
Tokenización de imágenes y su impacto en la resolución	65
5.3 El problema del modality gap: análisis teórico y estrategias de mitigación.....	65
El cone effect y la geometría de las redes profundas	66
Preservación del gap por el entrenamiento contrastivo	67
Estrategias de mitigación recientes.....	67



5.4 Estrategias de indexación de documentos visualmente ricos	68
El enfoque ColPali: retrieval en el espacio visual	68
Posicionamiento de la estrategia EMIE	69
5.5 Fusión de evidencias multimodales para generación aumentada	70
Estrategias de inyección de contexto	71
El problema del cross-modal misalignment en generación aumentada	71
5.6 Técnicas de combinación de embeddings cross-modal	72
Media aritmética como operador de fusión	72
5.7 Hacia la multimodalidad operativa: voz, vídeo y tiempo real	74
Incorporación de audio y voz	74
Modelos omni como horizonte de convergencia	75
Vídeo: segmentación temporal y embeddings	76
6. Implementación y Evaluación Experimental	77
Introducción	78
Modelos de embedding	78
1. VertexAI- multimodalembdding@001	78
2. VoyageAI - voyage-multimodal-3	90
3. Otros modelos multimodales	99
4. Gemini embedding 2	102
Modelos generadores	107
7. Análisis Crítico y Discusión	109
7.1 Síntesis de hallazgos experimentales	110
7.2 El modality gap como factor determinante del rendimiento cross-modal	111
Interpretación del gap en Vertex AI	112
La paradoja de Voyage AI: menos gap, peor retrieval visual	112
Reducción del gap en gemini embedding 2	113
Implicaciones para el diseño del pipeline	113
7.3 Evaluación crítica de la estrategia página-como-imagen	114
Fortalezas confirmadas	114
Debilidades identificadas	114
7.4 Limitaciones de los modelos generadores en comprensión visual de datos estructurados	116
Implicaciones para los casos de uso EMIE	117
7.5 Comparación con el estado del arte y posicionamiento de los resultados	118

CONFIDENCIAL



7.6	Discusión sobre reproducibilidad, validez y generalización	119
	Limitaciones de validez externa.....	120
	Elementos generalizables	120
7.7	Líneas de mejora identificadas y recomendaciones técnicas	120
	Mejoras inmediatas (sin cambio de arquitectura).....	120
	Mejoras a medio plazo (evolución arquitectónica)	121
	Mejoras a largo plazo (alineadas con la hoja de ruta EMIE).....	121
8.	Aplicabilidad Industrial y Transferencia Tecnológica	122
8.1	Del laboratorio al entorno industrial: evaluación de madurez tecnológica.....	123
8.2	Aplicabilidad al Caso de Uso A: asistencia multimodal al mantenimiento.....	124
8.3	Aplicabilidad al Caso de Uso B: RAG multimodal documental para Iberdrola	126
8.4	Barreras de transferencia y condiciones de éxito.....	127
8.5	Hoja de ruta de transferencia tecnológica	129
8.6	Valor industrial y posicionamiento competitivo	130
9.	Conclusiones.....	131
9.1	Recapitulación del objetivo y del alcance investigado	132
9.2	Respuesta a las preguntas de investigación.....	132
	PI-1 – Capacidad de recuperación cross-modal	133
	PI-2 – Impacto del modality gap	133
	PI-3 – Eficacia de la estrategia página-como-imagen	134
	PI-4 – Calidad de la generación en función del RAG.....	134
	PI-5 – Comparación de modelos de embedding en identificación visual	135
9.3	Hallazgos transversales no anticipados	135
9.4	Limitaciones de la investigación	136
9.5	Líneas de trabajo futuro.....	137
9.6	Reflexión final	138
10.	Referencias Bibliográficas	139



1. Introducción

Los modelos de lenguaje constituyen una de las líneas de investigación más influyentes dentro de la inteligencia artificial moderna, pero su origen conceptual es muy anterior al auge reciente de los grandes modelos fundacionales. Desde una perspectiva formal, un modelo de lenguaje puede entenderse como una distribución de probabilidad sobre secuencias de símbolos, palabras o tokens, cuyo objetivo es estimar la plausibilidad de una secuencia completa o predecir el siguiente elemento condicionado al contexto previo. Esta formulación probabilística hunde sus raíces en la teoría de la información de Shannon, donde la noción de entropía y de fuente de información ya establecía un marco matemático para razonar sobre regularidades estadísticas en secuencias simbólicas. Posteriormente, durante las décadas de 1980 y 1990, la escuela estadística impulsada por IBM consolidó una visión plenamente data-driven del procesamiento del lenguaje, en la que los parámetros del sistema se estimaban directamente a partir de datos y el componente de modelo de lenguaje se entendía explícitamente como el mecanismo encargado de proporcionar la probabilidad de la siguiente palabra dado el historial previo.

Reprinted with corrections from *The Bell System Technical Journal*,
Vol. 27, pp. 379–423, 623–656, July, October, 1948.

A Mathematical Theory of Communication

By C. E. SHANNON

INTRODUCTION

THE recent development of various methods of modulation such as PCM and PPM which exchange bandwidth for signal-to-noise ratio has intensified the interest in a general theory of communication. A basis for such a theory is contained in the important papers of Nyquist¹ and Hartley² on this subject. In the present paper we will extend the theory to include a number of new factors, in particular the effect of noise in the channel, and the savings possible due to the statistical structure of the original message and due to the nature of the final destination of the information.

The fundamental problem of communication is that of reproducing at one point either exactly or approximately a message selected at another point. Frequently the messages have *meaning*; that is they refer to or are correlated according to some system with certain physical or conceptual entities. These semantic aspects of communication are irrelevant to the engineering problem. The significant aspect is that the actual message is one *selected from a set of possible messages*. The system must be designed to operate for each possible selection, not just the one which will actually be chosen since this is unknown at the time of design.

If the number of messages in the set is finite then this number or any monotonic function of this number can be regarded as a measure of the information produced when one message is chosen from the set, all choices being equally likely. As was pointed out by Hartley the most natural choice is the logarithmic function. Although this definition must be generalized considerably when we consider the influence of the statistics of the message and when we have a continuous range of messages, we will in all cases use an essentially logarithmic measure.

Ilustración 1 Paper de Shannon "A Mathematical Theory of Communication"

En sus primeras generaciones, los modelos de lenguaje de uso práctico fueron predominantemente estadísticos y, en gran medida, basados en aproximaciones de orden finito, como los modelos *n-gram*. Bajo esta familia de enfoques, la probabilidad de una secuencia se descompone en productos de probabilidades condicionales locales, asumiendo que la predicción de una palabra depende únicamente de una ventana acotada de contexto anterior. Este supuesto de Markov reduce drásticamente la complejidad del problema y permitió construir sistemas útiles para reconocimiento del habla, traducción automática y otras tareas de PLN. Sin embargo, esa simplificación introducía una limitación estructural: el modelo

capturaba bien regularidades locales, pero tenía dificultades para representar dependencias de largo alcance, ambigüedades sintácticas distribuidas o fenómenos semánticos que emergen a escalas superiores a unas pocas palabras. Además, el crecimiento combinatorio del espacio de secuencias hacía que la generalización fuese frágil ante contextos no observados, lo que se conoce clásicamente como el problema de la “maldición de la dimensionalidad”.

Una de las respuestas más importantes a estas limitaciones fue la transición hacia modelos neuronales. El trabajo de Bengio y colaboradores sobre *neural probabilistic language models* representó un punto de inflexión al introducir la idea de aprender representaciones distribuidas densas de las palabras y, simultáneamente, la función probabilística sobre secuencias. El valor técnico de esta aportación fue doble. En primer lugar, permitió que secuencias no vistas durante el entrenamiento compartiesen información estadística a través de embeddings continuos, en lugar de ser tratadas como combinaciones completamente independientes. En segundo lugar, abrió la puerta a una noción mucho más rica de similitud léxica y semántica, en la que palabras funcionalmente próximas ocupan regiones vecinas en un espacio latente. Con ello, el modelado del lenguaje dejó de depender únicamente de conteos discretos y comenzó a apoyarse en estructuras geométricas aprendidas.




Ilustración 2 Paper de Bengio et al. "A Neural Probabilistic Language Model" Arquitectura con embeddings, proyección del contexto y salida Softmax.

En paralelo, la comunidad investigó arquitecturas específicamente diseñadas para procesar información secuencial, entre ellas las redes neuronales recurrentes. Los modelos recurrentes incorporaron el concepto de memoria dinámica al realimentar su estado oculto, de modo que la representación interna en cada instante dependía

CONFIDENCIAL

no solo de la entrada actual, sino también de estados previos. El trabajo de Elman formalizó con claridad esta idea de representar el tiempo de forma implícita mediante el efecto del pasado sobre el procesamiento presente. No obstante, aunque conceptualmente muy potentes, las RNN clásicas sufrían graves dificultades de optimización cuando la tarea requería propagar información relevante a lo largo de secuencias largas. Las arquitecturas LSTM mitigaron este problema mediante mecanismos de compuertas y trayectorias de error más estables, convirtiéndose en el estándar dominante para modelado secuencial durante muchos años al demostrar capacidad para resolver problemas con dependencias temporales de gran longitud.

El auténtico cambio de paradigma llegó con la introducción del transformer en 2017. La contribución central de esta arquitectura fue sustituir la recurrencia y, en gran medida, también las convoluciones, por mecanismos de autoatención capaces de modelar relaciones entre posiciones arbitrarias de la secuencia en paralelo. Desde el punto de vista computacional, esto supuso una mejora decisiva: el procesamiento dejó de estar estrictamente encadenado paso a paso, lo que permitió escalar el entrenamiento a volúmenes de datos y tamaños de modelo mucho mayores. Desde el punto de vista representacional, la autoatención hizo posible que el modelo aprendiera dependencias de largo alcance de forma directa, asignando dinámicamente pesos distintos a diferentes partes del contexto según la tarea y el token procesado. Esta combinación de paralelización, capacidad de contexto y escalabilidad es la base técnica sobre la que se construye la familia moderna de *Large Language Models* (LLMs).




Figure 1: The Transformer - model architecture.

Ilustración 3 Paper "Attention Is All You Need". Arquitectura encoder-decoder del Transformer con multi-head attention.



Los LLMs no deben entenderse únicamente como modelos grandes en número de parámetros, sino como sistemas fundacionales preentrenados sobre corpus masivos capaces de adquirir regularidades sintácticas, semánticas y pragmáticas reutilizables en un amplio rango de tareas. Su importancia industrial no deriva solo de la calidad generativa del texto que producen, sino de que el preentrenamiento a gran escala y el ajuste posterior permiten reutilizar una misma base arquitectónica para tareas de conversación, resumen, extracción de información, clasificación, razonamiento asistido, generación de código, búsqueda semántica o interacción con herramientas externas. En términos de ingeniería de sistemas, esto ha desplazado el foco desde modelos aislados para tareas concretas hacia plataformas de propósito general capaces de ser especializadas mediante *instruction tuning*, *retrieval augmentation*, llamadas a funciones y orquestación con servicios externos.

La versatilidad del transformer provocó de forma natural su expansión más allá del texto. En visión por computador, durante años dominaron las redes convolucionales debido a su sesgo inductivo espacial, su eficiencia local y su excelente rendimiento en clasificación, detección y segmentación. Sin embargo, el desarrollo del *Vision Transformer* mostró que una imagen podía reinterpretarse como una secuencia de parches, análoga a una secuencia de tokens, y que un transformer “puro” aplicado directamente sobre dichos parches podía competir con el estado del arte convolucional cuando se disponía de suficiente preentrenamiento. Este resultado fue conceptualmente muy relevante porque apuntaba hacia una posible unificación arquitectónica: una misma familia de modelos podía servir, con adaptaciones relativamente homogéneas, tanto para lenguaje como para visión. En paralelo, la literatura reciente ha mostrado que esa misma capacidad para capturar dependencias de largo alcance resulta atractiva también en series temporales, donde los transformers se han extendido a problemas de predicción, detección de anomalías y clasificación secuencial.




Ilustración 4 Paper “An Image is Worth 16x16 Words”. Vision Transformer con división en parches, embeddings y encoder Transformer.

La transición desde modelos unimodales hacia sistemas verdaderamente multimodales se aceleró cuando comenzaron a proponerse estrategias efectivas de alineamiento entre texto e imagen. Un hito fundamental en esta dirección fue CLIP, que mostró que el aprendizaje contrastivo sobre grandes volúmenes de pares imagen-texto podía producir representaciones visuales transferibles y semánticamente alineadas con el lenguaje natural. El hecho de entrenar sobre 400 millones de pares imagen-texto evidenció que la supervisión lingüística podía actuar como una fuente de anotación extremadamente rica y abierta, permitiendo capacidades *zero-shot* y una generalización mucho más flexible que la clasificación cerrada tradicional. A partir de ahí, los *Vision-Language Models* y posteriormente los *Multimodal Large Language Models* comenzaron a incorporar no solo imágenes, sino también vídeo, audio y documentos complejos dentro de un mismo flujo de inferencia.




Ilustración 5 Paper de CLIP. Esquema de entrenamiento contrastivo entre encoder de imagen y encoder de texto.

En esta evolución reciente, modelos como Flamingo marcaron una transición importante al proponer arquitecturas capaces de enlazar modelos de visión previamente entrenados con modelos de lenguaje también preentrenados, procesando secuencias arbitrariamente intercaladas de texto e imágenes e incorporando incluso vídeo como entrada. Más adelante, familias como Gemini han llevado esta idea hacia sistemas multimodales de contexto muy largo, capaces de razonar sobre documentos extensos, horas de vídeo y audio, y colecciones heterogéneas de información dentro de un mismo espacio de contexto. Desde una perspectiva de I+D industrial, este punto es especialmente relevante: la multimodalidad ya no debe entenderse solo como una capacidad de “ver y leer”, sino como la posibilidad de integrar evidencia diversa, de distinta granularidad y de distinta estructura, dentro de una misma cadena de decisión asistida por IA.




Ilustración 6 Paper de Flamingo, Transición desde modelos vision-language hacia modelos multimodales fundacionales de contexto largo.

Ahora bien, la integración multimodal no nace con los LLMs. Mucho antes del auge actual existía una tradición consolidada de fusión de datos multimodales en estadística multivariante, quimiometría, neuroimagen y análisis tensorial. En este marco se desarrollaron modelos como PARAFAC, introducido en 1970, que extiende la lógica de las descomposiciones matriciales a tensores de orden superior y permite separar factores latentes compartidos entre diferentes modos del dato. De forma similar, aparecieron extensiones tensoriales de ICA y, posteriormente, metodologías como *Linked ICA*, orientadas a modelar conjuntamente varias modalidades permitiendo ponderaciones distintas, componentes compartidos y componentes específicos de modalidad. Estas familias metodológicas ofrecen ventajas notables en interpretabilidad, identificación de estructura latente y control matemático del proceso de fusión. Sin embargo, su capacidad expresiva se apoya en gran medida en relaciones lineales o multilineales, lo que limita su poder representacional frente a datos heterogéneos, no estacionarios y semánticamente ricos como los que dominan hoy en entornos documentales, audiovisuales e industriales.




Ilustración 7Esquema conceptual de PARAFAC

Por ello, el panorama actual de la multimodalidad puede interpretarse como una convergencia entre dos tradiciones. La primera procede de la fusión estadística clásica y prioriza interpretabilidad, descomposición estructural y explicitud en el modelado de las relaciones entre fuentes. La segunda procede del aprendizaje profundo y prioriza capacidad de representación, escalabilidad y aprendizaje extremo a extremo. Dentro de esta segunda tradición, además, conviven hoy dos líneas de diseño claramente diferenciadas. Por un lado, se persigue la construcción de modelos unificados capaces de procesar simultáneamente múltiples modalidades dentro de una misma arquitectura, aprendiendo internamente el alineamiento y la integración entre señales heterogéneas. Por otro lado, sigue ganando fuerza una visión modular en la que existen encoders especializados por modalidad y la inferencia conjunta se resuelve mediante mecanismos de fusión, agentes u orquestadores superiores. La literatura reciente sobre modelos fundacionales multimodales describe precisamente esta tensión entre el entrenamiento extremo a extremo de MLLMs y el encadenamiento de herramientas o módulos multimodales gobernados por LLMs.

Esta dualidad no es solo una cuestión de arquitectura, sino también de filosofía de modelado y de transferencia a la industria. Un enfoque totalmente unificado promete simplicidad conceptual, aprendizaje conjunto de representaciones y potencial emergencia de capacidades generales. Sin embargo, también exige enormes volúmenes de datos alineados, infraestructuras de entrenamiento muy costosas y mecanismos complejos de control, evaluación y trazabilidad. Por el contrario, los enfoques modulares permiten reutilizar componentes ya optimizados para cada modalidad, facilitan la sustitución incremental de piezas del sistema y se adaptan mejor a escenarios empresariales donde los datos son heterogéneos, desbalanceados, fragmentados entre silos o sometidos a requisitos de gobernanza. En ámbitos estratégicos como industria avanzada, energía, salud o fabricación, esta consideración práctica es esencial, ya que la viabilidad de una solución no depende únicamente del rendimiento en benchmark, sino de su integrabilidad con procesos, costes de operación, mantenibilidad y robustez ante cambios en las fuentes de datos.






Ilustración 8 Esquema general de un survey de Multimodal Foundation Models.

En este contexto, la investigación en multimodalidad aplicada a modelos LLM e IA resulta especialmente pertinente para proyectos orientados a eficiencia y transferencia tecnológica como EMIE. La cuestión ya no es únicamente si un modelo puede combinar texto e imagen, sino cómo debe diseñarse esa combinación para maximizar utilidad industrial, eficiencia computacional, capacidad de generalización, auditabilidad del proceso y reutilización en diferentes verticales estratégicas. Esto obliga a analizar no solo arquitecturas, sino también embeddings multimodales, estrategias de alineamiento, esquemas de fusión temprana o tardía, mecanismos de recuperación multimodal, costes de inferencia, longitud efectiva de contexto, sensibilidad a distribución de datos y comportamiento en escenarios reales con documentación técnica, señales visuales, audio operativo o series temporales.

Partiendo de este marco, el presente trabajo tiene como objetivo estudiar de forma sistemática el estado actual de la multimodalidad en modelos basados en transformers y LLMs, evaluar sus implicaciones técnicas y explorar su aplicabilidad en entornos industriales estratégicos. En particular, se analizarán tanto enfoques de multimodalidad nativa como aproximaciones modulares basadas en componentes especializados, prestando atención a sus ventajas, limitaciones y trade-offs operativos. La hipótesis de fondo es que, en el corto y medio plazo, la supremacía de una u otra corriente no dependerá exclusivamente del rendimiento bruto del modelo, sino del equilibrio entre capacidad multimodal, eficiencia, facilidad de despliegue y adecuación a restricciones reales de negocio. Desde esta perspectiva, la investigación desarrollada no busca únicamente describir tendencias de la literatura, sino avanzar hacia criterios prácticos que permitan seleccionar arquitecturas y estrategias multimodales con valor transferible al tejido industrial.

2. Revisión del Estado del Arte en Modelos Multimodales

La multimodalidad en inteligencia artificial ha dejado de ser una propiedad marginal asociada a tareas concretas de fusión de datos y se ha convertido en uno de los ejes centrales del desarrollo de modelos fundacionales. En la práctica, el término “modelo multimodal” engloba hoy un conjunto muy heterogéneo de arquitecturas capaces de recibir, alinear, razonar o generar información a partir de distintas modalidades, principalmente texto, imagen, vídeo y audio. Por ello, una revisión rigurosa del estado del arte exige comenzar por una taxonomía precisa. En la literatura reciente puede distinguirse, como mínimo, entre cuatro grandes familias: modelos de alineamiento o *joint embedding*; modelos de comprensión multimodal con salida textual; modelos generativos condicionados multimodalmente; y modelos unificados u *omni* capaces de operar en múltiples modalidades tanto en la entrada como en la salida. Esta clasificación no es solo terminológica, sino estructural, porque cada familia optimiza objetivos distintos, usa conectores diferentes y responde a restricciones computacionales y empresariales también diferentes.




Ilustración 9 Arquitectura general del survey “A Survey on Multimodal Large Language Models”

Desde un punto de vista arquitectónico, la mayor parte de los MLLMs modernos comparten una estructura canónica compuesta por cuatro bloques. El primer bloque es un conjunto de codificadores por modalidad, encargados de transformar la señal cruda – imagen, secuencia de frames, onda de audio, espectrograma o texto – en representaciones latentes densas. El segundo bloque es un mecanismo de conexión o *connector/projector*, cuya función es resolver el desajuste entre el espacio latente del encoder multimodal y el espacio de representación del modelo de lenguaje. El

tercer bloque es el LLM o backbone lingüístico, normalmente un transformer decoder-only o encoder-decoder, que actúa como núcleo de razonamiento, seguimiento de instrucciones y generación textual. Finalmente, en algunos sistemas aparece un cuarto bloque generativo opcional para producir modalidades distintas del texto, como imagen, voz o vídeo. Esta formulación ha terminado imponiéndose porque desacopla percepción, alineamiento e inferencia, permitiendo reutilizar encoders y LLMs ya preentrenados sin necesidad de reentrenar de extremo a extremo modelos gigantescos desde cero.

En la práctica, este patrón modular suele entrenarse en dos fases. La primera fase se centra en **alinear modalidades**, es decir, en aprender cómo proyectar la información visual, acústica o audiovisual hacia un espacio que el LLM pueda consumir sin perder semántica relevante. La segunda fase se orienta al **instruction tuning** o alineamiento conductual del sistema completo, de modo que el modelo no solo reciba correctamente los estímulos multimodales, sino que sepa responder de acuerdo con instrucciones humanas y tareas específicas. BLIP-2 formalizó con gran claridad esta idea al proponer un entrenamiento en dos etapas donde un *Q-Former* conecta un encoder visual congelado con un LLM también congelado, reduciendo drásticamente el coste del preentrenamiento respecto a enfoques fully end-to-end. InstructBLIP amplió esa filosofía incorporando la instrucción al propio Q-Former, de forma que el extractor visual no solo resumiera la imagen, sino que aprendiera a extraer la parte de la imagen relevante para la instrucción concreta.




Ilustración 10 Arquitectura de BLIP-2 con encoder visual congelado, Q-Former y LLM congelado.

Sobre esa base común se han desarrollado los grandes modelos de **comprensión multimodal con salida textual**, que hoy constituyen probablemente la familia dominante en despliegues empresariales. Flamingo supuso uno de los primeros hitos al mostrar cómo combinar un modelo visual potente y un LLM para soportar secuencias arbitrariamente intercaladas de texto e imágenes, incluyendo incluso vídeo, y explotar *few-shot prompting* multimodal. Después llegaron BLIP-2, InstructBLIP y LLaVA, que simplificaron y abarataron notablemente la receta mediante conectores más ligeros y grandes volúmenes de datos de *visual instruction tuning*. LLaVA resultó especialmente influyente al demostrar que un encoder visual

CONFIDENCIAL

y un LLM pueden conectarse con una proyección relativamente simple y aun así producir capacidades de diálogo visual generales, mientras que el trabajo posterior sobre LLaVA evidenció que un proyector MLP totalmente conectado puede ser sorprendentemente eficiente y competitivo en coste/rendimiento.

La línea abierta y de alto rendimiento avanzó después hacia familias como **Llama 3.2 Vision**, **Phi-3.5-Vision**, **Qwen2-VL**, **Qwen2.5-VL**, **InternVL 2.5** y **LLaVA-OneVision**. Llama 3.2 Vision emplea una serie de capas de *cross-attention* como adaptador entre el encoder visual y el núcleo lingüístico, reforzando la integración explícita de características visuales dentro del flujo del LLM. Phi-3.5-Vision, por su parte, se posiciona como una opción compacta, con capacidades para uno o varios frames y un contexto largo de 128K tokens, orientada a usos ligeros y escenarios de productividad. Qwen2-VL introdujo dos ideas de especial interés técnico: el procesamiento de resolución dinámica y el uso de **M-RoPE** para fusionar información posicional de texto, imagen y vídeo. Qwen2.5-VL profundizó esa línea con comprensión de documentos, diagramas, vídeo largo y localización temporal más precisa. InternVL 2.5 insistió en la escalabilidad sistemática del encoder visual, del LLM y del tamaño/diseño del dataset como variables principales de rendimiento. LLaVA-OneVision, por su parte, buscó unificar imagen única, multiimagen y vídeo dentro de un mismo marco de transferencia visual. En el segmento propietario, Gemini 1.5 consolidó la idea de MLLM multimodal de contexto ultralargo, capaz de razonar sobre múltiples documentos, horas de audio y vídeo y millones de tokens de contexto.




Ilustración 11 Arquitectura de Llama 3.2 Vision

Ahora bien, dentro del estado del arte conviene separar con total claridad estos modelos de comprensión de la familia de **modelos generativos condicionados multimodalmente**. En esta segunda familia el objetivo no es entender una imagen y responder en texto, sino **generar una modalidad visual, audiovisual o sonora a partir de otra modalidad**, normalmente texto, pero también imagen de referencia, máscara, estilo, boceto, audio o vídeo previo. En este grupo se sitúan DALL-E 2,

Imagen, Latent Diffusion/Stable Diffusion, SDXL, DiT y sus extensiones a vídeo. DALL-E 2 es especialmente importante para esta taxonomía porque utiliza **CLIP** no como generador directo, sino como espacio intermedio semántico: primero aprende un *prior* que genera un embedding visual CLIP a partir del texto, y luego un decodificador genera la imagen condicionada a ese embedding. Imagen mostró que escalar el encoder textual podía mejorar de forma decisiva la fidelidad semántica de la imagen generada. Latent Diffusion y SDXL desplazaron la generación a espacios latentes comprimidos, reduciendo coste computacional sin perder calidad. DiT demostró que los transformers también podían sustituir con éxito al U-Net clásico en modelos de difusión. Por tanto, cuando en el documento se hable de “input textual y output imagen”, las referencias correctas no son CLIP o Phi-3.5-Vision, sino esta familia de modelos generativos.




Ilustración 12 Diagrama de DALL-E 2 con prior y decoder condicionados por CLIP latents

Una tercera línea, mucho más ambiciosa, es la de los **modelos unificados** o **any-to-any**, que intentan resolver dentro de un solo sistema la percepción y la generación en varias modalidades. Esta corriente es aún más reciente, pero ya resulta estratégica porque apunta hacia asistentes empresariales multimodales de interacción natural. Un survey específico de 2025 resume precisamente la evolución de estos modelos y muestra la transición desde arquitecturas centradas solo en entendimiento hacia modelos capaces de entender y generar. En esa línea, **Qwen2.5-Omni** propuso una arquitectura *Thinker-Talker* capaz de recibir texto, imagen, audio y vídeo, y de responder tanto en texto como en voz de forma *streaming*. Pocos meses después, **Ming-Omni** se presentó como un modelo unificado para percepción y generación multimodal con soporte explícito de audio e imagen, mientras que trabajos posteriores como **Qwen3-Omni** han continuado la línea hacia sistemas omni de mayor cobertura modal y menor latencia de primera respuesta. Esta dirección es especialmente relevante para interfaces naturales en empresa, incluyendo gafas inteligentes, terminales de asistencia en planta, soporte de inspección guiada y sistemas audiovisuales interactivos.



El rendimiento de un MLLM depende en gran medida de la calidad de su **encoder visual**, ya que ese módulo es el responsable de transformar una señal bidimensional de alta dimensión y fuerte redundancia espacial en una secuencia de tokens o embeddings semánticamente útiles. Históricamente, los encoders visuales dominantes fueron las redes convolucionales profundas, especialmente desde la irrupción de ResNet. Las CNN introducen un sesgo inductivo espacial muy potente: localidad, compartición de pesos y jerarquía de receptive fields. Eso las hace particularmente eficientes para reconocer patrones locales, bordes, texturas y composiciones progresivamente más abstractas. En el contexto multimodal, los encoders convolucionales siguen teniendo sentido cuando se prioriza robustez local, eficiencia y madurez operativa, aunque en muchos MLLMs contemporáneos han sido sustituidos o complementados por ViTs preentrenados.



Los **Vision Transformers** reformulan la imagen como una secuencia de parches, cada uno proyectado linealmente a un embedding y procesado mediante autoatención. Esta estrategia elimina el sesgo local fijo de la convolución y permite modelar interacciones globales entre regiones distantes de la imagen desde etapas tempranas. En MLLMs, esto es especialmente ventajoso porque el output del encoder ya nace como una secuencia de tokens, lo que facilita su acoplamiento posterior con el backbone lingüístico. Además, el diseño transformer simplifica la incorporación de mecanismos de resolución dinámica, reordenación espacial o compresión adaptativa de tokens visuales. No es casual que CLIP, LLaVA, BLIP-2, Qwen2-VL, Llama 3.2 Vision o muchos encoders documentales recientes se apoyen en variantes de ViT o en híbridos cercanos a esta filosofía.

Los **variational autoencoders** deben describirse con más matiz. No son, en sentido estricto, el encoder visual predominante en los MLLMs de comprensión, pero sí son fundamentales en la rama generativa y en los pipelines que operan en espacios latentes compactos. Un VAE aprende una codificación probabilística comprimida del input y un decodificador capaz de reconstruirlo. En generación visual moderna, esa compresión latente es crucial porque permite que el modelo de difusión opere sobre un espacio mucho más manejable que el espacio de píxeles. Por eso, cuando en el documento se cite “VAE” dentro del ecosistema multimodal, conviene presentarlo como un **mecanismo de compresión latente y representación generativa**, no como el encoder estándar de percepción de los VLMs actuales.




Ilustración 15 Esquema encoder-latent space-decoder de un VAE

Finalmente, **CLIP** ocupa una posición singular en esta taxonomía. Técnicamente, CLIP no es solo un codificador de imagen, sino una arquitectura dual de codificador de imagen y codificador de texto entrenados contrastivamente para alinear ambos espacios en un mismo espacio semántico compartido. Esa alineación hace de CLIP una pieza extremadamente útil como base de encoders visuales para retrieval, zero-shot transfer, clasificación abierta y proyección multimodal inicial. Muchos MLLMs abiertos han reutilizado variantes de CLIP-ViT como encoder visual de arranque

precisamente porque ofrecen una representación visual ya alineada con lenguaje. En otras palabras, CLIP actúa como puente entre visión y lenguaje antes incluso de que intervenga el LLM principal.




Ilustración 16 CLIP con encoder de imagen, encoder de texto y pérdida contrastiva

2.2 Conectores o projectors

Una de las piezas más importantes, y al mismo tiempo más infravaloradas, en la arquitectura de los MLLMs es el **conector multimodal**. Su función no es meramente cambiar dimensiones tensoriales, sino resolver un problema mucho más profundo: cómo traducir una representación visual, audiovisual o acústica – producida por un encoder entrenado con objetivos y distribuciones muy distintos – al espacio en el que el LLM puede razonar y generar respuestas. Un survey reciente dedicado específicamente a conectores muestra que estos mecanismos han evolucionado desde proyecciones atómicas simples hasta diseños multicapa, multi-encoder y multimodales con compresión, mezcla o routing adaptativo. En términos prácticos, el conector determina cuánta información se preserva, cuántos tokens se transfieren, cuánta latencia se añade y qué grado de alineamiento semántico se consigue antes de entrar en el LLM.

En la categoría más simple están los conectores **projection-based**, normalmente capas lineales o MLPs. Su ventaja es la eficiencia: pocos parámetros, bajo coste y buena compatibilidad con estrategias de instruction tuning. LLaVA popularizó esta ruta y el trabajo posterior de "Improved Baselines with Visual Instruction Tuning" mostró que un proyector MLP totalmente conectado puede rendir sorprendentemente bien si se acompaña de una buena selección de encoder visual, datos académicos y formato de respuesta. En la práctica industrial, este tipo de conector es muy atractivo cuando se necesita equilibrio entre calidad, coste y facilidad de fine-tuning.

Los conectores **query-based** representan una alternativa más sofisticada. En BLIP-2, el Q-Former introduce consultas aprendibles que interrogan las features del encoder visual y extraen un subconjunto de tokens visuales más condensado y útil para el LLM. InstructBLIP llevó esta idea un paso más allá al hacer que la propia instrucción textual interactúe con el Q-Former, de modo que la extracción visual ya sea dependiente de la tarea. Este enfoque suele mejorar la eficiencia semántica del

flujo de información, ya que no se transfieren todas las características visuales indiscriminadamente, sino una síntesis guiada por queries.

Finalmente, los conectores **fusion-based** y los basados en **cross-attention** abren la puerta a una integración mucho más profunda entre modalidades. Flamingo y Llama 3.2 Vision son ejemplos claros de esta filosofía: las features visuales no se reducen solo a una proyección estática, sino que son inyectadas mediante capas de atención cruzada dentro del flujo del modelo lingüístico. Este enfoque suele ser más potente cuando se requiere razonamiento fino sobre relaciones espaciales, secuencias intercaladas o dependencia larga entre texto e imagen, aunque introduce más complejidad de entrenamiento e inferencia. A medida que los MLLMs avanzan hacia vídeo, audio y escenarios multiimagen/multiframe, este tipo de conector gana importancia porque el problema ya no es solo alinear, sino también **seleccionar y sincronizar** qué parte de cada modalidad debe influir en cada paso del razonamiento.




Ilustración 17 Taxonomía de conectores de un survey específico de connectors, complementada con la figura de BLIP-2 Q-Former

2.3 Adición de audio y expansión a modos no visuales

Añadir audio a un modelo multimodal no consiste simplemente en “pasar otra señal más” a la arquitectura. El audio introduce retos propios de temporalidad, granularidad, compresión y sincronización. A diferencia de una imagen estática, una señal de audio tiene estructura temporal densa y multi-escala: fonemas, sílabas, prosodia, eventos acústicos, ambiente, timbre, música o ruido pueden coexistir y operar en distintas escalas temporales. Por ello, los encoders de audio han seguido

históricamente tres grandes familias. La primera trabaja sobre **espectrogramas** o representaciones tiempo-frecuencia, lo que permite reutilizar inductivos biases y arquitecturas de visión como CNNs o transformers visuales. La segunda trabaja directamente sobre la **onda temporal** o representaciones latentes derivadas de la forma de onda, como en wav2vec 2.0 o HuBERT. La tercera se centra en la **alineación audio-texto**, como CLAP, para construir espacios semánticos compartidos útiles en retrieval, clasificación o conditioning generativo.

wav2vec 2.0 es una referencia esencial porque mostró que pueden aprenderse representaciones del habla de forma autosupervisada a partir de grandes volúmenes de audio sin transcribir, usando enmascaramiento y aprendizaje contrastivo sobre representaciones latentes. **HuBERT** siguió una lógica distinta, basada en predicción de unidades ocultas derivadas de clustering offline, y consolidó la idea de que el modelado autosupervisado del habla puede servir como encoder general de audio lingüístico. Ambos trabajos son fundamentales para entender por qué los modelos actuales de audio-lenguaje no dependen únicamente de pipelines ASR clásicos, sino de encoders robustos capaces de preservar información acústica y semántica útil antes del paso al LLM.




Ilustración 18 Arquitectura de wav2vec 2.0 o HuBERT.

En paralelo, la línea de **alineamiento audio-texto** ha ganado peso con CLAP y sus sucesores. El objetivo aquí no es necesariamente transcribir, sino construir embeddings compartidos entre audio y lenguaje natural, de forma análoga a CLIP en visión. Este enfoque es particularmente útil para recuperación semántica, clasificación zero-shot, *audio tagging*, búsqueda en archivos sonoros y condicionamiento de modelos generativos de audio. La evolución reciente hacia variantes que escalan el número de pares audio-texto, la duración de los audios o la densidad de la supervisión sugiere que los modelos empresariales de próxima generación necesitarán embeddings acústicos compartidos con texto para poder integrar voz, entorno sonoro y documentación textual dentro de los mismos flujos RAG y de asistencia operativa.

CONFIDENCIAL

Otra estrategia muy influyente consiste en usar primero un sistema de **ASR robusto** y trabajar después en texto. Whisper es aquí una referencia fundamental: entrenado con 680.000 horas de supervisión débil, demostró una gran capacidad de generalización multilingüe y robustez zero-shot. Este enfoque tiene ventajas claras en entornos empresariales porque simplifica la integración con LLMs textuales ya existentes. Sin embargo, también introduce una pérdida de información potencial: una vez colapsado el audio a texto, se pierden matices prosódicos, acústicos o ambientales que pueden ser relevantes para tareas avanzadas. Por eso la tendencia del estado del arte ya no se limita al *speech-to-text-to-text*, sino que se desplaza progresivamente hacia **audio-language models** y sistemas *speech-native*.




Ilustración 19 Diagrama o figura de Whisper que represente el pipeline de reconocimiento robusto de habla.

En esa frontera se sitúan **Qwen-Audio**, **Qwen2-Audio** y propuestas como **Ultravox**, que ya no conciben el audio solo como una fuente a transcribir, sino como una modalidad que puede alimentar directamente la conversación y el razonamiento del modelo. Qwen-Audio y Qwen2-Audio amplían la cobertura de tareas, tipos de audio y capacidad de seguir instrucciones a partir de audio y texto. Ultravox, por su parte, explicita una idea muy relevante para aplicaciones en tiempo real: evitar una etapa ASR separada e insertar directamente el audio en el espacio de alta dimensión usado por el LLM mediante un proyector multimodal. Esta línea converge de forma natural con los modelos *omni* actuales, donde un mismo sistema puede oír, ver, leer y responder con texto o voz.




Ilustración 20 Arquitectura de Qwen2-Audio

2.4 Embeddings multimodales y almacenamiento semántico compartido

Uno de los objetivos más estratégicos del proyecto EMIE es el almacenamiento conjunto y seguro de la información semántica proveniente de distintos modos del lenguaje en un espacio vectorial común. Desde el punto de vista científico, esta línea se apoya en la hipótesis de que distintas modalidades que refieren al mismo concepto – por ejemplo, una fotografía de una pieza industrial, su nombre en un orden de trabajo, una tabla de medidas o una instrucción verbal de montaje – pueden representarse como puntos próximos en un espacio latente compartido. CLIP convirtió esta hipótesis en una tecnología operativa para imagen y texto. Hoy, los servicios empresariales de embeddings multimodales avanzan justamente en esa dirección: Vertex AI expone embeddings multimodales para texto, imagen y vídeo; voyage-multimodal-3 declara soporte para textos e imágenes intercalados y destaca especialmente capturas de PDF, tablas, figuras y diapositivas; Gemini, con su modelo gemini-embedding-2-preview, amplía este espectro al integrar de forma nativa texto, imagen, vídeo (con y sin audio), audio puro y documentos (PDF), destacando además por la implementación de vectores MRL (Matryoshka Representation Learning) que permiten escalar y reducir la dimensionalidad del vector resultante según los requisitos de eficiencia del sistema; y Cohere presenta modelos destinados a búsqueda multimodal empresarial sobre texto e imagen. Para un proyecto como EMIE, esta línea es clave porque habilita RAG multimodal, recuperación cruzada entre modalidades y trazabilidad semántica sobre activos heterogéneos.

Aquí conviene hacer una distinción importante. Un **MLLM de comprensión** no es necesariamente un **modelo de embedding multimodal** optimizado para recuperación. Muchos MLLMs razonan bien sobre inputs multimodales, pero no

garantizan que sus estados internos sean ideales para indexación vectorial, comparación de similitud o clustering empresarial. En cambio, los modelos explícitamente diseñados para embeddings optimizan estabilidad de representación, separación entre conceptos y utilidad en tareas de retrieval. Por eso, desde una perspectiva de arquitectura de sistema, suele ser recomendable separar el “modelo que entiende y responde” del “modelo que representa y recupera”. Esa distinción es especialmente relevante cuando el objetivo del proyecto incluye almacenamiento conjunto de semántica multimodal, búsqueda sobre documentos técnicos, recuperación de evidencias visuales y posterior razonamiento asistido por LLM.

2.5 Evaluación, benchmarks y limitaciones del estado del arte

La evaluación de MLLMs ha madurado rápidamente, pero también se ha vuelto mucho más compleja. Un survey reciente sobre benchmarks recoge alrededor de 180–200 referencias de evaluación y propone organizar el campo en percepción y entendimiento, cognición y razonamiento, dominios específicos, capacidades clave y modalidades adicionales. Esta proliferación de benchmarks refleja tanto el crecimiento del campo como una dificultad metodológica de fondo: no existe una única métrica capaz de resumir la capacidad multimodal. Un modelo puede ser excelente en captioning o OCR, mediocre en razonamiento visual, débil en seguimiento de instrucciones y muy pobre en robustez frente a alucinaciones o largas secuencias de vídeo. Por tanto, un “estado del arte” sólido no debe limitarse a citar un único benchmark agregado, sino explicar qué mide cada familia de pruebas.

Entre los benchmarks generales, **MMMU** se ha convertido en una referencia central porque evalúa comprensión y razonamiento multimodal de nivel universitario sobre 30 materias y 183 subcampos, integrando diagramas, tablas, mapas, partituras, estructuras químicas y otras representaciones heterogéneas. Su interés para industria es enorme porque se acerca más a entornos documentales y técnicos reales que muchos benchmarks de VQA tradicionales. **MMMU-Pro** endurece aún más esa evaluación para medir de forma más robusta las capacidades reales de razonamiento multimodal. Para matemáticas y figuras, **MathVista** es especialmente valioso porque combina razonamiento matemático con percepción visual profunda. Para vídeo, **Video-MME** es una referencia de primer nivel al incorporar duración, diversidad de dominios y combinaciones de vídeo, subtítulos y audio. Para seguimiento estricto de instrucciones multimodales, **MIA-Bench** aporta una dimensión crítica que muchos benchmarks clásicos no cubrían adecuadamente.



Art & Design	Business	Science
Question: Among the following harmonic intervals, which one is constructed incorrectly? Options: (A) Major third <image 1> (B) Diminished fifth <image 2> (C) Minor seventh <image 3> (D) Diminished sixth <image 4>	Question: ...The graph shown is compiled from data collected by Gallup <image 1>. Find the probability that the selected Emotional Health Index Score is between 80.5 and 82? Options: (A) 0 (B) 0.2142 (C) 0.3571 (D) 0.5	Question: <image 1> The region bounded by the graph as shown above. Choose an integral expression that can be used to find the area of R. Options: (A) $\int_0^{1.5} [f(x) - g(x)] dx$ (B) $\int_0^{1.5} [g(x) - f(x)] dx$ (C) $\int_0^2 [f(x) - g(x)] dx$ (D) $\int_0^2 [g(x) - x(x)] dx$
Subject: Music; Subfield: Music; Image Type: Sheet Music; Difficulty: Medium	Subject: Marketing; Subfield: Market Research; Image Type: Plots and Charts; Difficulty: Medium	Subject: Math; Subfield: Calculus; Image Type: Mathematical Notations; Difficulty: Easy
Health & Medicine	Humanities & Social Science	Tech & Engineering
Question: You are shown subtraction <image 1>, T2 weighted <image 2> and T1 weighted axial <image 3> from a screening breast MRI. What is the etiology of the finding in the left breast? Options: (A) Susceptibility artifact (B) Hematoma (C) Fat necrosis (D) Silicone granuloma	Question: In the political cartoon, the United States is seen as fulfilling which of the following roles? <image 1> Option: (A) Oppressor (B) Imperialist (C) Savior (D) Isolationist	Question: Find the VCE for the circuit shown in <image 1>. Neglect VBE Answer: 3.75 Explanation: ...$I_E = [(V_{EE}) / (R_E)] = [(5 \text{ V}) / (4 \text{ k-ohm})] = 1.25 \text{ mA}$; $V_{CE} = V_{CC} - I_E R_L = 10 \text{ V} - (1.25 \text{ mA}) 5 \text{ k-ohm}$; $V_{CE} = 10 \text{ V} - 6.25 \text{ V} = 3.75 \text{ V}$
Subject: Clinical Medicine; Subfield: Clinical Radiology; Image Type: Body Scans: MRI, CT; Difficulty: Hard	Subject: History; Subfield: Modern History; Image Type: Comics and Cartoons; Difficulty: Easy	Subject: Electronics; Subfield: Analog electronics; Image Type: Diagrams; Difficulty: Hard

Ilustración 21 Metodológica de MMMU

No obstante, la literatura reciente también ha mostrado que muchos resultados de benchmark deben interpretarse con cautela. El trabajo “Are We on the Right Way for Evaluating Large Vision-Language Models?” identificó dos problemas especialmente serios: por un lado, en numerosos ejemplos el contenido visual no es realmente necesario porque la respuesta puede inferirse desde el texto o el conocimiento paramétrico del LLM; por otro, existe riesgo de fuga de datos o memorización de muestras presentes en los corpus masivos de entrenamiento. Ese trabajo muestra, por ejemplo, que un modelo puede obtener resultados sorprendentemente altos en ciertos benchmarks incluso sin ver la imagen, lo que distorsiona la interpretación del progreso real en multimodalidad. Esta crítica es muy importante para un entregable empresarial, porque obliga a distinguir entre “benchmark score” y “ganancia multimodal genuina”.



	Validation Overall (900)	Test Overall (10,500)	Art & Design (1,163)	Business (1,428)	Science (2,426)	Health & Medicine (1,752)	Human. & Social Sci. (947)	Tech & Eng. (2,784)
Random Choice	22.1	23.9	24.1	24.9	21.6	25.3	22.8	24.8
Frequent Choice	26.8	25.8	26.7	28.4	24.0	24.4	25.2	26.5
Expert (Worst)	76.2	-	-	-	-	-	-	-
Expert (Medium)	82.6	-	-	-	-	-	-	-
Expert (Best)	88.6	-	-	-	-	-	-	-
Large Multimodal Models (LLMs): Text + Image as Input								
OpenFlamingo2-9B [4]	28.7	26.3	31.7	23.5	26.3	26.3	27.9	25.1
Kosmos2 [63]	24.4	26.6	28.8	23.7	26.6	27.2	26.3	26.8
Adept Fuyu-8B [6]	27.9	27.4	29.9	27.0	25.6	27.0	32.5	26.4
MiniGPT4-Vicuna-13B [94]	26.8	27.6	30.2	27.0	26.2	26.9	30.9	27.2
LLaMA-Adapter2-7B [88]	29.8	27.7	35.2	25.4	25.6	30.0	29.1	25.7
CogVLM [77]	32.1	30.1	38.0	25.6	25.1	31.2	41.5	28.9
Qwen-VL-7B-Chat [5]	35.9	32.9	47.7	29.8	25.6	33.6	45.3	30.2
InstructBLIP-T5-XXL [16]	35.7	33.8	48.5	30.6	27.6	33.6	49.8	29.4
BLIP-2 FLAN-T5-XXL [35]	35.4	34.0	49.2	28.6	27.3	33.7	51.5	30.4
InternLM-XComposer2-VL* [17]	43.0	38.2	56.8	32.8	30.1	39.8	60.7	31.8
Yi-VL-34B* [84]	45.9	41.6	56.1	33.3	32.9	45.9	66.5	36.0
LLaVA-1.6-34B* [46]	51.1	44.7	58.6	39.9	36.0	51.2	70.2	36.3
InternVL-Chat-V1.2* [11]	51.6	46.2	62.5	37.6	37.9	49.7	70.1	40.8
VILA1.5* [39]	51.9	46.9	62.1	40.6	37.7	51.7	74.0	39.5
Qwen-VL-MAX* [65]	51.4	46.8	64.2	39.8	36.3	52.5	70.4	40.7
SenseChat-Vision-0423-Preview* [68]	54.6	50.3	62.7	44.1	42.3	55.7	74.7	43.5
GPT-4V(ision) (Playground) [60]	56.8	55.7	65.3	64.3	48.4	63.5	76.3	41.7
Claude 3 Opus* [72]	59.4	-	-	-	-	-	-	-
Gemini 1.5 Pro* [23]	62.2	-	-	-	-	-	-	-
GPT-4o* [61]	69.1	-	-	-	-	-	-	-
Large Language Models (LLMs): Only Text as Input								
Llama2 7B [75]	30.1	28.7	30.7	27.2	26.7	27.7	32.6	29.8
FLAN-T5-XXL [14]	32.1	31.2	36.8	28.9	26.7	32.8	44.8	28.3
+ OCR	34.7	31.9	36.2	28.8	26.2	32.6	50.5	29.7
+ LLaVA Caption	34.8	31.9	38.4	27.8	27.0	33.2	49.9	28.7
Vicuna-13B [12]	33.3	31.0	35.1	30.1	24.7	31.4	44.8	30.1
+ OCR	35.4	31.9	37.1	28.6	26.5	32.0	49.3	30.0
+ LLaVA Caption	33.9	32.7	42.0	26.8	26.2	33.4	49.4	31.4
GPT-4 Text [59]	34.9	33.8	32.9	28.5	30.6	41.3	53.0	28.4

Ilustración 22 Resultados de diferentes modelos de MMMU validation y test set

A esto se suma el problema de las **alucinaciones multimodales**, es decir, respuestas plausibles pero no fieles al contenido visual, acústico o documental de entrada. La literatura reciente ya trata este fenómeno como un eje completo de evaluación y no como un problema secundario. En entornos industriales, esta cuestión es todavía más crítica que en asistentes conversacionales generales, porque una alucinación sobre una imagen técnica, una pieza defectuosa, una señal de alarma sonora o un procedimiento operativo puede traducirse directamente en una mala decisión. Por ello, la evaluación del estado del arte debe incluir no solo rendimiento en benchmarks, sino también fidelidad, calibración, trazabilidad y comportamiento bajo restricciones.






Ilustración 23 Paper "Are We on the Right Way for Evaluating Large Vision-Language Models?" que muestre la diferencia entre rendimiento con y sin señal visual, o bien una figura del survey de alucinaciones multimodales.

2.6 Lectura del estado del arte desde la transferencia empresarial

Vista en conjunto, la literatura actual apunta a una conclusión clara: el estado del arte no se dirige únicamente hacia modelos más grandes, sino hacia sistemas **mejor alineados, más eficientes, más contextuales y más integrables** en arquitecturas de producción. Para el ámbito empresarial, esto tiene varias implicaciones. La primera es que la receta dominante no suele ser entrenar desde cero un modelo puramente multimodal de gran tamaño, sino combinar encoders especializados, conectores adecuados, embeddings compartidos y un LLM de razonamiento o generación alineado a dominio. La segunda es que el verdadero cuello de botella no está solo en el modelo, sino en la preparación de datos, el diseño de la recuperación multimodal, el control de generación y la evaluación continua. La tercera es que la interfaz final está evolucionando hacia contextos naturales de uso: documentos largos, multiimagen, vídeo, voz, y dispositivos edge o wearables. En esa dirección, propuestas como Gemini 1.5, Llama 3.2 Vision y Qwen2.5-Omni resultan especialmente ilustrativas por su foco en contexto largo, edge/mobile vision y multimodalidad natural con voz, respectivamente.

Esta lectura enlaza directamente con los objetivos del proyecto EMIE. El paso desde el ámbito investigador al ámbito empresarial exige tres saltos tecnológicos simultáneos. El primero consiste en convertir la multimodalidad en una capacidad operativa y no solo demostrativa, lo que implica integrar documentos, imágenes, tablas, audio y vídeo dentro de un pipeline gobernable y auditable. El segundo consiste en construir espacios semánticos compartidos útiles para recuperación, memoria y trazabilidad, y no limitarse al uso de un chat multimodal aislado. El tercero consiste en desarrollar mecanismos de evaluación, monitorización y adaptación a dominio que reduzcan alucinaciones, aumenten satisfacción y permitan introducir estos modelos en procesos productivos reales. Desde esta perspectiva, el estado del arte revisado no debe entenderse como una colección de modelos, sino como un mapa de decisiones arquitectónicas para seleccionar qué combinación de

encoders, conectores, embeddings, modelos de razonamiento y mecanismos de control tiene más sentido en cada vertical industrial.



3. Análisis de Requisitos y Casos de Uso

El análisis de requisitos del proyecto EMIE no debe abordarse como la definición aislada de un único demostrador tecnológico, sino como la formalización de una familia de casos de uso industriales que comparten un mismo núcleo funcional: el uso de modelos de lenguaje y modelos multimodales para reducir fricción operativa, acelerar el acceso a conocimiento relevante y transformar interacciones industriales tradicionalmente manuales en flujos asistidos, trazables y progresivamente más contextuales. A partir de la documentación de trabajo disponible, se observa con claridad que el proyecto articula actualmente dos ejes principales. El primero corresponde al caso de uso de asistencia al mantenimiento, centrado en el técnico de planta y en la evolución desde un entorno clásico o parcialmente digitalizado hacia un entorno asistido por IA, voz, visión y realidad aumentada. El segundo corresponde al caso de uso de Iberdrola, cuyo foco está en el acceso inteligente a documentación extensa y heterogénea mediante un sistema de RAG multimodal capaz de manejar texto, imágenes y tablas, y de evolucionar desde interacción textual hasta interacción por voz e imagen.

Desde una perspectiva empresarial, esta convergencia resulta especialmente relevante porque coincide con la evolución real de los procesos industriales. Los sistemas de mantenimiento y operación se estructuran hoy alrededor de órdenes de trabajo, inventario, procedimientos, evidencias de intervención y conocimiento experto distribuido. En entornos con GMAO o CMMS, el flujo habitual parte de la identificación de la tarea, la creación o asignación de la orden de trabajo, la ejecución por el técnico y la posterior documentación y análisis del trabajo realizado. IBM describe precisamente este ciclo como la columna vertebral de la gestión de mantenimiento, destacando que la documentación de tiempos, materiales, imágenes y observaciones forma parte crítica del cierre y revisión de cada orden de trabajo, y que las plataformas CMMS modernas centralizan ese flujo, automatizan asignaciones, soportan inventario y habilitan acceso móvil o remoto a las tareas y a la información operativa.

En el caso de uso de mantenimiento desarrollado en el proyecto, esta lógica industrial aparece ya perfectamente identificada. El documento describe una progresión de cinco niveles de madurez: desde el técnico que trabaja con papel y manuales físicos, pasando por el técnico apoyado en GMAO, luego por el técnico asistido por un LLM conversacional, después por un asistente multimodal basado en voz y, finalmente, por un asistente multimodal desplegado en realidad aumentada con análisis de imágenes, vídeo y sensores en tiempo real. También se identifican de forma explícita los problemas operativos que justifican la intervención tecnológica: pérdida de tiempo en consultas, elaboración costosa de informes, falta de visión de 360 grados sobre el entorno, necesidad de apoyo en reparaciones y dificultad para conservar y transferir conocimiento experto.



En paralelo, el caso de uso de Iberdrola formaliza otra necesidad empresarial de enorme relevancia: el acceso rápido y fiable a información distribuida en una documentación técnica muy extensa y muy heterogénea. El documento indica que la solución debe poder responder preguntas cuya evidencia no se encuentra únicamente en texto, sino también en imágenes y tablas, y que la interacción debe soportarse inicialmente sobre texto, pero evolucionar hacia voz e incluso permitir que el usuario aporte imágenes para formular consultas contextualizadas. Técnicamente, el problema se formula como un sistema de RAG multimodal avanzado, en el que la recuperación no puede limitarse a fragmentos textuales, sino que debe ser capaz de explotar información visual y tabular integrada dentro de documentos complejos.

Este planteamiento encaja de forma muy sólida con la dirección actual de la investigación. Los surveys recientes sobre **multimodal retrieval-augmented generation** subrayan que el paso de RAG textual a MRAG no es un refinamiento menor, sino una extensión necesaria para dominios reales donde la evidencia está repartida entre texto, imágenes, audio, vídeo, tablas, diagramas y diseño de página. Estas revisiones destacan además que MRAG reduce alucinaciones al forzar el anclaje de la respuesta en conocimiento externo multimodal y que mejora frente a RAG puramente textual cuando la pregunta requiere integrar evidencia visual y textual de forma conjunta.




Ilustración 24 Paper de A Survey on Multimodal Retrieval-Augmented Generation

La importancia concreta de esta necesidad en entornos documentales ricos queda reforzada por los trabajos recientes de recuperación multimodal en documentos largos. MMDocIR señala que en documentos visualmente ricos el texto ocupa solo una parte del contenido total y que imágenes y tablas concentran una fracción informativa muy significativa; además, muestra que la recuperación útil no siempre puede quedarse en nivel de página, sino que a menudo debe llegar a granularidad

de elemento, es decir, localizar el párrafo, la figura, la tabla o el gráfico exacto donde reside la evidencia necesaria para responder a la consulta. Esta observación es particularmente importante para el caso Iberdrola, porque justifica que la arquitectura no debe diseñarse como un chatbot documental convencional, sino como una infraestructura de indexación, recuperación y razonamiento multimodal.




Ilustración 25 Paper MMDocIR: Benchmarking Multimodal Retrieval for Long Documents

3.1 Delimitación funcional de los casos de uso dentro de EMIE

A la vista de ambos documentos, puede afirmarse que el proyecto EMIE trabaja actualmente sobre dos categorías de caso de uso que comparten capacidades técnicas, pero difieren en el lugar donde se materializa el valor. En el caso de asistencia al mantenimiento, el valor se produce **durante la ejecución de la tarea**, es decir, en el puesto de trabajo, en presencia del activo, con el técnico operando y necesitando ayuda contextual, documentación localizada, guiado paso a paso, registro automático de evidencias y eventualmente monitorización de riesgos. En el caso Iberdrola, el valor se produce **durante la explotación del conocimiento corporativo**, es decir, en el acceso a documentación compleja para responder preguntas, analizar componentes, interpretar imágenes aportadas por el usuario o recuperar información precisa desde corpus técnicos extensos y heterogéneos.

Esta diferencia de punto de aplicación no implica dos arquitecturas inconexas. Al contrario, los dos casos pueden interpretarse como dos niveles de una misma pila funcional. En la base se sitúa la capacidad de ingestión e indexación de conocimiento técnico. Sobre esa base se construye una capa de recuperación y razonamiento multimodal. Encima aparece la capa de interacción, que puede ser

textual, vocal o visual. Finalmente, en el caso de mantenimiento, se añade una capa contextual y sensorial ligada al entorno físico, al GMAO, a las evidencias capturadas y, en la fase más avanzada, a los dispositivos de realidad aumentada. Esta lectura es relevante porque permite definir requisitos comunes y componentes reutilizables, evitando que el proyecto derive en prototipos desconectados entre sí.

3.2 Requisitos de negocio transversales

El primer gran requisito transversal del proyecto es el **acceso inmediato al conocimiento relevante**. En el caso de mantenimiento, este acceso inmediato evita desplazamientos a terminales, búsquedas manuales de documentación y dependencia de terceros para resolver dudas operativas. En el caso Iberdrola, evita búsquedas costosas dentro de documentación extensa y reduce el tiempo necesario para localizar la parte exacta de la evidencia documental que responde a una necesidad concreta. En ambos escenarios, la necesidad subyacente es la misma: reducir el tiempo entre la aparición de una duda operativa y la obtención de una respuesta accionable y contextualizada.

El segundo requisito transversal es la **integración con el ciclo real de trabajo**. No basta con responder preguntas bien en un entorno de demostración; el sistema debe insertarse en los procesos ya existentes, ya sean órdenes de trabajo, documentación técnica, inventario, cierre de partes, anexo de evidencias o revisión posterior del trabajo realizado. Esta exigencia coincide con la literatura industrial sobre CMMS, que sitúa la creación, asignación, documentación y revisión de órdenes de trabajo como la estructura básica del mantenimiento moderno, y que atribuye especial valor a la trazabilidad de materiales, tiempos, imágenes y observaciones, así como a la automatización de flujos y a la disponibilidad móvil/remota de la información.

El tercer requisito transversal es la **multimodalidad útil**, no puramente demostrativa. El proyecto no necesita multimodalidad como un atributo cosmético, sino como una capacidad operativa que resuelva problemas reales: interpretar tablas e imágenes dentro de documentos, responder a preguntas sobre una fotografía aportada por el usuario, guiar con soporte visual una intervención, generar documentación a partir de voz e imagen o analizar el entorno del técnico durante una tarea. Esta precisión es importante porque obliga a separar claramente qué modalidades se necesitan en cada fase y con qué propósito funcional. En el caso Iberdrola, la multimodalidad está centrada en documento, consulta y recuperación. En el caso de mantenimiento, la multimodalidad se expande hacia interacción natural, registro de evidencias y percepción del entorno.

El cuarto requisito transversal es la **capacidad de captura, estructuración y reutilización del conocimiento experto**. El caso de mantenimiento lo expresa al hablar de transferencia de conocimiento, histórico de procedimientos, aprendizaje a



partir de tareas realizadas y reducción de la curva de aprendizaje. El caso Iberdrola lo expresa desde el lado del repositorio documental y del acceso razonado a conocimiento corporativo complejo. En ambos casos, el proyecto apunta a transformar conocimiento tácito o disperso en conocimiento recuperable, trazable y reutilizable. Esta línea es coherente con las propuestas recientes que combinan XR y LLMs con RAG para mejorar transferencia de conocimiento, asistencia remota y guiado contextual en entornos industriales, especialmente cuando los expertos no siempre están disponibles físicamente y la documentación no está integrada de forma operativa en la interacción de campo.




Ilustración 26 Paper Bridging Industrial Expertise and XR with

3.3 Caso de uso A: asistencia multimodal al mantenimiento

El caso de uso de mantenimiento debe entenderse como una evolución funcional desde la digitalización hacia la asistencia contextual. En su formulación más básica, el sistema actúa como un interfaz más eficiente sobre el GMAO: informa del plan de trabajo, recupera instrucciones, resuelve dudas sobre procedimientos y ayuda a reportar acciones y materiales consumidos. En esta primera fase, el valor diferencial del modelo de lenguaje no está en “pensar por el técnico”, sino en reducir fricción cognitiva y de interacción sobre sistemas que ya contienen parte de la información necesaria pero que no están optimizados para una consulta natural y situada.

A partir de ahí, el caso de uso evoluciona hacia un asistente multimodal por voz. La voz tiene aquí una justificación operativa clara: libera las manos del técnico, reduce la necesidad de alternar entre tarea física y dispositivo, y convierte la consulta de información en una interacción más cercana al diálogo entre compañeros. El documento del proyecto ya describe este estadio como un entorno donde el técnico consulta el plan de trabajo por voz, recibe respuestas orales o visuales, describe verbalmente la intervención y deja documentado el proceso casi en tiempo real. Desde el punto de vista de requisitos, esto implica soporte de ASR/TTS robusto,

CONFIDENCIAL

gestión de turnos de palabra, memoria de diálogo ligada a la intervención, y sincronización con el sistema transaccional de mantenimiento para no convertir el asistente en un silo separado de información.

En la fase avanzada, la asistencia se desplaza a un dispositivo vestible o de realidad aumentada. Aquí el proyecto plantea algo más ambicioso que la mera visualización de instrucciones: el sistema debe capturar imágenes, vídeo y potencialmente datos de sensores; analizarlos en tiempo real; sugerir acciones; completar registros; verificar ejecución; advertir riesgos del entorno; y permitir, en situaciones complejas, compartir la visión del técnico con expertos externos. Esta formulación es totalmente coherente con la literatura reciente sobre AR industrial y asistencia XR+LLM, que identifica precisamente tres dominios donde estas tecnologías aportan más valor: formación, asistencia remota y soporte operativo en tiempo real. Sin embargo, esa misma literatura advierte que la introducción de AR-HMD en entornos peligrosos exige una validación específica de seguridad y conciencia situacional, ya que algunos estudios encuentran mejoras en guiado y productividad, pero también riesgos de distracción o reducción de la percepción del entorno cuando el dispositivo no está bien adaptado al contexto industrial.



Ilustración 27 AR Aplicación

3.4 Caso de uso B: RAG multimodal documental para Iberdrola

El caso Iberdrola presenta una naturaleza distinta, aunque tecnológicamente convergente. Aquí el núcleo del problema es documental: existe una necesidad empresarial prioritaria de acceder a información extensa, heterogénea y distribuida en texto, imágenes y tablas, con capacidad no solo de recuperar fragmentos relevantes, sino de **razonar** sobre información dispersa, combinada y multimodal. El documento lo formula con claridad al describir el sistema como una extensión

natural de RAG textual hacia un sistema capaz de recuperar información general en documentación escrita, imágenes y tablas, integrando los distintos tipos de evidencia para producir respuestas adecuadas a preguntas concretas.

Este planteamiento requiere requisitos muy específicos de preprocesado e indexación. No es suficiente con convertir PDFs a texto y aplicar chunking tradicional, porque parte del conocimiento reside en tablas, diagramas, imágenes de componentes, esquemas o diseño de página. El propio caso Iberdrola propone una línea de trabajo muy acertada: identificar texto, imágenes y tablas, analizarlos por separado, resumir las modalidades no textuales y añadir ese resultado a la base vectorial para que la recuperación posterior no ignore dichas fuentes de evidencia. Esta idea coincide con la evolución histórica del MRAG, donde una primera etapa consistió precisamente en textualizar modalidades no textuales para poder aprovechar infraestructuras RAG ya maduras, aunque la investigación más reciente empuja cada vez más hacia recuperación y razonamiento multimodal nativos.




Ilustración 28 Arquitectura del sistema

La relevancia del caso Iberdrola se refuerza aún más al considerar que la consulta no se limita a documentos corporativos estáticos, sino que también contempla imágenes aportadas por el propio usuario, tanto en interacción textual como vocal. Esto desplaza el caso desde un simple “chat sobre documentos” hacia un sistema híbrido donde coexisten recuperación documental, percepción multimodal y diálogo contextual. En términos de requisitos, ello implica al menos tres modos de operación

coordinados: consulta sobre corpus documental, consulta sobre imagen aportada por usuario y consulta combinada en la que la respuesta depende tanto del conocimiento indexado como de la evidencia visual del input actual. Esta tripleta funcional es una de las razones por las que el caso Iberdrola no debe modelarse como un chatbot de FAQ, sino como un sistema de composición multimodal de evidencias.

3.5 Requisitos funcionales derivados

De la lectura conjunta de ambos casos se desprende un primer bloque de requisitos funcionales de **ingestión y estructuración de conocimiento**. El sistema debe ser capaz de recibir documentación heterogénea, clasificarla por tipo de contenido, separar y tratar de forma diferenciada texto, tablas e imágenes, y generar representaciones recuperables. En el caso Iberdrola, esta necesidad está explicitada directamente en la propuesta de preprocesado; en el caso de mantenimiento, aparece de forma implícita cuando se habla de manuales interactivos, recuperación de procedimientos, históricos de tareas y entrenamiento sobre registros previos. Técnicamente, este requisito exige pipelines de parsing, normalización, chunking multimodal, enriquecimiento semántico y persistencia en infraestructuras de búsqueda o vectoriales.

Un segundo bloque de requisitos funcionales corresponde a la **interacción multimodal con el usuario**. La solución debe soportar texto, voz e imagen como entradas, y texto, voz y soporte visual como salidas según el caso de uso y el canal disponible. En mantenimiento, la voz y la visualización contextual tienen una función operativa de manos libres y de asistencia en campo. En Iberdrola, texto y voz constituyen canales alternativos de acceso al conocimiento, mientras que la imagen aportada por el usuario amplía el ámbito del sistema hacia consultas situadas sobre objetos, dispositivos o componentes. La coexistencia de estos canales implica gestión de contexto compartido, resolución de referencias entre modalidades y mecanismos claros para mantener la trazabilidad de qué parte de la respuesta proviene de la documentación indexada y qué parte del análisis del input actual.

Un tercer bloque funcional es el de **asistencia procedimental y generación de acciones**. El caso de mantenimiento exige guiado paso a paso, propuesta de causas y soluciones, recordatorio de herramientas y materiales, y cierre o completado de partes. El caso Iberdrola exige respuestas razonadas sobre documentación técnica. Aunque parezcan dominios diferentes, ambos requieren una misma capacidad superior: convertir información recuperada y contexto actual en una secuencia de ayuda útil para la acción humana. Desde el punto de vista del producto, esto significa que la respuesta no debe limitarse a ser correcta, sino que debe ser operativa, contextualizada y estructurada de acuerdo con el momento de uso.



Un cuarto bloque funcional es la **documentación automática o semiautomática del trabajo realizado**. En mantenimiento, este requisito es explícito y de alto valor: reducir el coste de rellenar partes, estructurar automáticamente la narración del técnico, generar informes a partir de voz o de imágenes captadas durante la tarea, y mantener la trazabilidad de materiales, acciones y tiempos. En Iberdrola, aunque el énfasis principal no está puesto en el reporte de intervención, sí existe la necesidad de registrar consultas, respuestas y evaluación posterior del sistema. En ambos casos, la documentación generada por el sistema no solo tiene valor administrativo, sino que alimenta el histórico de conocimiento sobre el que después se apoyarán nuevos usos del asistente.

Un quinto bloque funcional es la **transferencia y preservación del conocimiento experto**. El documento de mantenimiento lo expresa en términos de reducción de curva de aprendizaje, histórico de procedimientos y apoyo a operarios en formación. La literatura reciente sobre XR y LLMs para industria refuerza exactamente ese punto: uno de los mayores problemas de los entornos industriales avanzados es que el conocimiento experto está distribuido, no siempre disponible in situ y, en muchos casos, no plenamente integrado con la documentación estructurada ni con las interfaces de asistencia. El uso conjunto de RAG y XR aparece así como una vía de capturar conocimiento de dominio y servirlo de forma contextual, manos libres y adaptada al nivel de experiencia del usuario.

3.6 Requisitos no funcionales y restricciones de diseño

Los requisitos no funcionales del proyecto son especialmente importantes porque determinan la viabilidad real de los casos de uso. El primero es la **seguridad de la información**. El propio caso Iberdrola exige altos niveles de seguridad de datos, comunicaciones encriptadas y despliegues aún por decidir entre cloud y entorno local. Esta exigencia no es meramente corporativa; condiciona directamente la arquitectura, la elección de modelos, la estrategia de inferencia y el tratamiento de documentos internos y evidencias visuales.

El segundo gran requisito no funcional es la **latencia operativa**. En un caso documental, una latencia moderada puede ser tolerable; en un caso de asistencia en campo o de interacción por voz, la latencia pasa a ser un factor de aceptabilidad del sistema. El caso Iberdrola ya incorpora explícitamente latencia y coste como criterios de evaluación, y la evolución hacia interacción por voz exige responder con tiempos suficientemente bajos para no romper el flujo de trabajo ni penalizar la adopción. En mantenimiento, esta exigencia es aún más fuerte, ya que el asistente compite no contra un benchmark, sino contra la experiencia del técnico, la llamada a un compañero o la consulta rápida a un manual conocido.

El tercer requisito no funcional es la **modularidad arquitectónica**. Dado que el estado del arte de modelos multimodales evoluciona con enorme rapidez, el diseño



del sistema debe permitir sustituir o mejorar encoders, modelos de recuperación, ASR/TTS, analizadores visuales o interfaces sin rehacer el producto completo. Esto ya aparece insinuado en el propio caso Iberdrola cuando propone una solución demostrable pero adaptable a los avances de la literatura. En un proyecto como EMIE, donde conviven al menos dos casos de uso y varias fases de madurez, la modularidad no es una buena práctica opcional, sino una condición para la sostenibilidad técnica del desarrollo.

El cuarto requisito no funcional es la **seguridad operacional** cuando se despliegan interfaces vestibles o de realidad aumentada. La promesa de AR en mantenimiento es muy alta: guiado en contexto, manos libres, overlays sobre el activo y soporte de experto remoto. Sin embargo, la evidencia reciente también obliga a introducir cautela. Trabajos recientes encuentran que los AR-HMD pueden mejorar ciertos aspectos de asistencia, pero que en entornos industriales peligrosos todavía existen dudas importantes sobre su impacto en la conciencia situacional y en la exposición a riesgos físicos, especialmente cuando el entorno es denso, ruidoso o con múltiples peligros simultáneos. Por ello, el paso hacia realidad aumentada debe considerarse una fase avanzada de validación, no un supuesto de partida.

3.7 Priorización de casos de uso y senda recomendada de despliegue

La primera fase debe centrarse en capacidades **textuales y documentales** de alta utilidad inmediata: ingestión de documentación, recuperación de conocimiento, consulta conversacional y soporte a preguntas sobre texto, imágenes y tablas dentro de corpus documentales. Esta fase se alinea especialmente bien con el caso Iberdrola y, además, proporciona una base tecnológica reutilizable para el resto del proyecto.

La segunda fase debe incorporar **interacción vocal y evidencia visual aportada por el usuario**, manteniendo todavía dispositivos convencionales como móvil o terminal de escritorio. Esto permite ensayar la multimodalidad útil sin asumir todavía los riesgos y complejidades de la realidad aumentada industrial. El propio caso Iberdrola ya plantea exactamente esta evolución y propone medir la solución de voz frente a una baseline basada en voice-to-text y text-to-voice, comparando calidad de respuesta y latencia.

La tercera fase debe orientar el desarrollo hacia el **asistente operacional en campo**, integrando GMAO, registro guiado de intervención, documentación automática y ayuda contextual al técnico durante la ejecución de la tarea. Esta fase recoge el valor central del caso de mantenimiento y comienza a convertir el sistema en una herramienta de trabajo real y no solo en un asistente de consulta.

Finalmente, la cuarta fase puede abordar la **interacción XR/AR**, siempre que previamente se hayan estabilizado las capacidades de recuperación, razonamiento,



voz, visión y registro transaccional. La literatura reciente sobre XR+RAG y asistencia industrial sugiere que este es el punto donde más valor diferencial puede aparecer en términos de manos libres, guiado contextual y transferencia de conocimiento, pero también donde más importante es validar seguridad, usabilidad y contexto real de adopción. En otras palabras, la realidad aumentada no debe ser tratada como la puerta de entrada al proyecto, sino como la culminación de una arquitectura ya demostrada en texto, documento, voz e imagen.

3.8 Síntesis del análisis

En síntesis, el análisis de requisitos y casos de uso del proyecto EMIE muestra que la multimodalidad no debe entenderse aquí como una funcionalidad aislada, sino como una estrategia de integración entre conocimiento documental, interacción natural y contexto operativo. El caso de mantenimiento pone el acento en el técnico, en la ejecución de la tarea, en la seguridad y en la documentación del trabajo. El caso Iberdrola pone el acento en el acceso inteligente a documentación multimodal extensa y en la recuperación precisa de conocimiento accionable. Juntos, ambos casos delimitan una visión coherente del proyecto: construir una infraestructura multimodal capaz de servir conocimiento industrial allí donde haga falta, ya sea en una consulta documental compleja, en una reparación en campo, en una conversación por voz o en una futura interfaz de realidad aumentada.



4. Marco de Trabajo para la Investigación Multimodal

El presente capítulo tiene como objetivo formalizar el marco metodológico que guía la investigación experimental desarrollada en las secciones posteriores de este entregable. La necesidad de un marco explícito surge de la propia naturaleza del problema abordado: la multimodalidad aplicada a contextos industriales no es un dominio en el que exista una única receta arquitectónica consolidada, sino un espacio de diseño amplio en el que conviven múltiples estrategias de codificación, alineamiento, indexación, recuperación y generación, cada una con trade-offs diferentes en términos de rendimiento, coste, latencia, mantenibilidad y escalabilidad. Sin un marco de referencia que explicita los objetivos, las métricas, los criterios de selección y la metodología de validación, los resultados experimentales corren el riesgo de ser interpretados de forma anecdótica y difícilmente reproducible.

Además, el proyecto EMIE se sitúa en una intersección particularmente exigente: por un lado, debe asimilar el estado del arte en modelos multimodales de gran escala; por otro, debe traducir ese estado del arte en decisiones de ingeniería viables para entornos empresariales con restricciones reales de seguridad, coste, latencia y gobernanza de datos. Esto obliga a que el marco de trabajo no se limite a definir qué modelos se evalúan, sino que especifique **por qué** se eligen esos modelos frente a las alternativas disponibles, **cómo** se mide su rendimiento, **con qué datos** se validan, y **bajo qué hipótesis** se interpretan los resultados. En otras palabras, este capítulo establece el contrato metodológico del trabajo experimental que sigue.

La estructura del capítulo refleja esta lógica. En primer lugar, se formalizan las preguntas de investigación que orientan la experimentación. En segundo lugar, se definen las métricas y criterios de evaluación. En tercer lugar, se presenta la arquitectura de referencia del pipeline experimental. En cuarto lugar, se justifica la selección de modelos. En quinto lugar, se describen los datasets y escenarios de prueba. En sexto lugar, se analiza la estrategia de indexación adoptada. Finalmente, se expone la metodología de validación empleada.

4.1 Objetivos y preguntas de investigación

La investigación experimental del proyecto EMIE se articula alrededor de un objetivo general y cinco preguntas de investigación derivadas. El objetivo general consiste en determinar qué combinación de modelos de *embedding* multimodal, estrategias de indexación y modelos generativos produce un sistema de RAG multimodal viable para los casos de uso industriales definidos en la sección 3, entendiendo viabilidad como el equilibrio entre calidad de recuperación, fidelidad de las respuestas generadas, coste operativo y latencia de inferencia.

Este objetivo general se descompone en las siguientes preguntas de investigación concretas:

PI-1: Capacidad de los modelos de *embedding* multimodal para recuperación cross-modal sobre documentación técnica

La primera pregunta de investigación aborda la cuestión fundamental de si los modelos de *embedding* multimodal actuales son capaces de producir



representaciones vectoriales suficientemente alineadas entre modalidades como para soportar una recuperación eficaz en escenarios documentales reales. En un sistema de RAG multimodal, el modelo de *embedding* es la pieza que determina si, ante una consulta textual del usuario, el sistema es capaz de localizar no solo los fragmentos de texto relevantes, sino también las imágenes, tablas, diagramas o gráficas que contienen la evidencia necesaria para responder. De forma simétrica, debe ser capaz de recibir una imagen como consulta y localizar las páginas o fragmentos documentales donde aparece contenido visual o textual relacionado. Esta capacidad de **recuperación cross-modal** es el requisito mínimo sin el cual un pipeline de RAG multimodal pierde su razón de ser frente a un RAG puramente textual.

La pregunta se operacionaliza evaluando dos modelos de *embedding* multimodal con características complementarias: **multimodalembd@001** de Vertex AI (Google Cloud), **voyage-multimodal-3** de Voyage AI (MongoDB) y **gemini-embedding-2-preview** de Google. Para cada uno, se mide la calidad de la recuperación en escenarios de complejidad creciente, desde imágenes aisladas hasta documentos PDF extensos tratados como colecciones de páginas-imagen.

PI-2: Impacto del modality gap en la calidad de la recuperación

La segunda pregunta de investigación se centra en un fenómeno bien documentado en la literatura reciente sobre aprendizaje contrastivo multimodal: el denominado **modality gap**. Este fenómeno, formalizado por Liang et al. (2022) en el trabajo "*Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning*", describe una propiedad geométrica intrigante de los espacios de representación de modelos multimodales entrenados con objetivos contrastivos como CLIP: las representaciones de las distintas modalidades (por ejemplo, imagen y texto) ocupan regiones separadas del espacio latente, incluso cuando corresponden a pares semánticamente alineados.






Ilustración 29 Visualización del modality gap en modelos multimodales contrastivos. Los embeddings de imagen (azul) y texto (naranja) se sitúan en regiones disjuntas del hiperespacio, incluso para pares semánticamente correspondientes. Fuente: Liang et al. (2022).

La explicación teórica de este fenómeno se apoya en tres mecanismos complementarios. En primer lugar, el **efecto cono** (cone effect): el sesgo inductivo de las redes neuronales profundas con activaciones no lineales restringe las representaciones a un cono estrecho en el espacio de alta dimensión. Dado que un modelo multimodal utiliza dos codificadores diferentes, cada uno con su propia inicialización aleatoria, los conos resultantes son distintos desde el inicio del entrenamiento. En segundo lugar, la **preservación del gap durante el entrenamiento contrastivo**: el objetivo InfoNCE utilizado en CLIP y modelos similares maximiza la similitud coseno entre pares positivos y la minimiza entre negativos, pero no impone explícitamente que las representaciones de ambas modalidades se superpongan en el espacio. Como demostraron Liang et al. mediante un experimento de desplazamiento de embeddings, el mínimo de la función de pérdida contrastiva no se encuentra en el punto de alineamiento perfecto entre modalidades, sino a una distancia no nula que depende del parámetro de temperatura τ de la función de pérdida. En tercer lugar, trabajos posteriores como *AlignCLIP* (ICLR 2025) han demostrado que añadir objetivos de separación intra-modal regularizada puede reducir significativamente este gap, pasando de ángulos medios de $\sim 70^\circ$ a $\sim 47^\circ$ entre pares imagen-texto.




Ilustración 30 Paisaje de la función de pérdida contrastiva bajo diferentes temperaturas. El mínimo no coincide con la distancia cero entre centros de modalidades, lo que explica la preservación del modality gap durante el entrenamiento. Fuente: Liang et al. (2022).

Para el proyecto EMIE, esta pregunta tiene implicaciones prácticas directas. Si los modelos de *embedding* seleccionados presentan un *modality gap* significativo, las consultas textuales del usuario tenderán a estar más próximas a los fragmentos indexados como texto que a los fragmentos indexados como imagen, incluso cuando la evidencia visual sea semánticamente más relevante. Esto degradaría la calidad del RAG multimodal al sesgar la recuperación hacia la modalidad del *query* en lugar de hacia la relevancia semántica real. La operacionalización de esta pregunta se realiza mediante dos estrategias complementarias: (a) comparación directa de distancias cuando el mismo contenido se indexa como texto y como imagen, y (b) análisis de componentes principales (PCA) del espacio de *embeddings* para visualizar si las representaciones de imagen y texto ocupan regiones separadas o solapadas.

PI-3: Eficacia de la estrategia de página-como-imagen para indexación de PDFs técnicos

La tercera pregunta aborda una decisión de diseño central del pipeline experimental: la viabilidad de tratar **cada página de un documento PDF como una imagen** y generar un *embedding* visual por página, en lugar de realizar un *parsing* separado de texto, tablas e imágenes seguido de múltiples *embeddings* por componente. Esta estrategia tiene una motivación práctica clara: simplifica enormemente el pipeline de ingestión, evita la pérdida de contexto de *layout* que se produce al extraer texto plano de documentos con formato complejo, y captura de forma nativa la información visual contenida en tablas, gráficas, diagramas y fotografías embebidas. Sin embargo, también introduce limitaciones potenciales: mayor coste de *embedding* por documento, pérdida de granularidad en la indexación textual, y dependencia de la capacidad del modelo de *embedding* para reconocer y codificar texto dentro de imágenes (OCR implícito).

Esta pregunta se evalúa comparando los resultados de recuperación sobre PDFs indexados como imágenes frente a la calidad esperada de un *parsing*

CONFIDENCIAL

convencional, y analizando en qué escenarios la estrategia de página-como-imagen produce ventajas claras (documentos con layout complejo, tablas ricas, mezcla de texto e imagen) y en cuáles introduce desventajas (documentos de texto plano extenso, búsquedas de cadenas textuales específicas).

PI-4: Calidad de las respuestas generadas en función de la calidad del RAG previo

La cuarta pregunta investiga la relación entre la calidad de la fase de recuperación y la calidad de la respuesta final producida por el modelo generador multimodal. En un sistema RAG, la cadena causal es clara: si la recuperación falla y proporciona contexto irrelevante, el modelo generador opera sobre información incorrecta y tenderá a producir alucinaciones o respuestas genéricas. Por el contrario, si la recuperación es precisa, el generador dispone de evidencia suficiente para producir respuestas específicas, fundamentadas y trazables. Esta pregunta se operacionaliza comparando tres condiciones experimentales: (a) respuesta del generador **sin RAG** (solo conocimiento paramétrico), (b) respuesta con **RAG erróneo** (documentos recuperados incorrectos), y (c) respuesta con **RAG exitoso** (documentos recuperados correctos). Esta comparación tripartita permite cuantificar el valor añadido real del componente de recuperación.

PI-5: Comparación de modelos de embedding en tarea de identificación visual sobre documentación técnica

La quinta pregunta aborda un escenario especialmente relevante para el caso de uso de mantenimiento: dado un input visual (por ejemplo, una fotografía de una pieza, un componente o un equipo), ¿es capaz el sistema de identificar el documento o la sección documental correspondiente? Este escenario es cualitativamente diferente a los anteriores porque la consulta no es textual sino visual, y la recuperación debe funcionar de imagen a imagen dentro de un espacio donde los documentos se han indexado como páginas-imagen. Se evalúa esta capacidad mediante el test de identificación de motos a partir de fotografías comparadas con páginas de manuales técnicos.

4.2 Criterios de evaluación y métricas

La evaluación de un sistema de RAG multimodal requiere medir de forma separada pero coordinada dos componentes distintos: la calidad de la **recuperación** (¿se localizan los documentos o fragmentos correctos?) y la calidad de la **generación** (¿la respuesta producida es precisa, fiel y útil?). Además, en un contexto industrial, es necesario incorporar métricas operativas relacionadas con el coste y la latencia. La literatura reciente sobre evaluación de sistemas MRAG ha avanzado significativamente en la formalización de estas métricas. Abootorabi et al. (2025), en el survey *"Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation"*, proponen una taxonomía estructurada que cubre datasets, benchmarks, métricas, metodologías y componentes del pipeline MRAG. Por su parte, trabajos como REAL-MM-RAG (Wasserman et al., 2025, ACL 2025) y Chart-MRAG Bench (Yang et al., 2025) han introducido benchmarks específicos que

evalúan la recuperación multimodal en documentos reales, incluyendo gráficas, tablas y contenido visual complejo.

Métricas de recuperación

Para evaluar la calidad de la fase de recuperación se emplean las siguientes métricas:

Top-k Recall (Recall@k): mide la proporción de consultas para las cuales el documento o página correcta aparece entre los k resultados más cercanos en el espacio vectorial. En los experimentos de este trabajo se reportan Recall@1, Recall@3 y Recall@5. Esta métrica es especialmente relevante porque en un sistema RAG el modelo generador solo recibe los top-k documentos recuperados, de modo que si la evidencia correcta no aparece en ese conjunto, la calidad de la generación se degrada necesariamente. El Recall@k se calcula formalmente como:

$$Recall@k = \left(\frac{1}{N}\right) \times \sum_i \mathbb{I}(relevante_i \in top - k)$$

Ilustración 31 Definición formal de Recall@k empleada en la evaluación de recuperación.

Distancia euclidiana entre vectores: además del Recall@k binario, se analiza la distancia euclidiana entre el vector de la consulta y los vectores de los documentos recuperados. Esta métrica proporciona información más granular que el recall: permite detectar cuándo un documento correcto aparece en el top-k pero con una distancia muy cercana a la de documentos incorrectos (lo que indicaría fragilidad del ranking), y también permite comparar directamente el comportamiento cross-modal. La elección de la distancia euclidiana sobre la similitud coseno se justifica por coherencia con la configuración por defecto de FAISS (Flat L2 index), que es la librería de búsqueda vectorial empleada en los experimentos. No obstante, dado que los *embeddings* de los modelos evaluados están normalizados (L2-norm), la distancia euclidiana y la similitud coseno son métricas monótonamente relacionadas: $d^2(a,b) = 2 - 2 \cdot \cos(a,b)$. Por tanto, los rankings producidos por ambas métricas son idénticos en este contexto.

Análisis del modality gap mediante PCA: para evaluar cuantitativamente el *modality gap* descrito en la PI-2, se emplea Análisis de Componentes Principales (PCA) sobre el conjunto completo de vectores indexados, distinguiendo por modalidad de origen (texto vs. imagen). Si las dos primeras componentes principales separan claramente los vectores según su modalidad, esto indica un *modality gap* estructural. La varianza explicada por la primera componente proporciona una medida de la magnitud de esta separación: una varianza alta concentrada en la primera componente que separa modalidades indicaría un gap pronunciado. Esta técnica reproduce la metodología empleada por Liang et al. (2022) y permite verificar empíricamente si los modelos de *embedding* seleccionados para EMIE presentan este fenómeno.






Ilustración 32 Distribución de autovalores de embeddings de imagen y texto, evidenciando la separación espectral entre modalidades que el PCA captura como primera componente principal.

Métricas de generación

Para la evaluación de la calidad de las respuestas generadas se emplea en esta fase del proyecto una **evaluación cualitativa experta** basada en tres criterios:

Especificidad de la respuesta: ¿contiene la respuesta información concreta y específica del documento recuperado, o es genérica y podría haberse producido sin contexto externo? Esta distinción es fundamental porque permite separar el valor del RAG del conocimiento paramétrico del modelo.

Fidelidad al contenido recuperado: ¿es la información contenida en la respuesta consistente con lo que aparece en los documentos proporcionados como contexto, o introduce fabricaciones o distorsiones? Este criterio es especialmente relevante en entornos industriales, donde una respuesta plausible pero incorrecta puede traducirse en una decisión operativa errónea, como se discutió en la sección 2.5 sobre alucinaciones multimodales.

Nivel de concreción operativa: ¿proporciona la respuesta información directamente accionable (páginas específicas, procedimientos concretos, referencias a imágenes o tablas del manual), o se limita a recomendaciones genéricas? En el contexto de EMIE, una respuesta que cite la página exacta, la imagen concreta y el procedimiento paso a paso tiene mucho más valor operativo que una respuesta correcta pero vaga.

Es importante señalar que en esta fase del proyecto la evaluación de generación no se realiza mediante métricas automáticas como BLEU, ROUGE-L o METEOR, dado que no se dispone de un *ground truth* formal de respuestas anotadas para los documentos utilizados. La construcción de un benchmark de evaluación formal con pares pregunta-respuesta anotados sobre documentación técnica real constituye una línea de trabajo futuro del proyecto, alineada con las recomendaciones de benchmarks como Open RAG Benchmark (Vectara, 2025) y Chart-MRAG Bench (Yang et al., 2025), que enfatizan la necesidad de evaluar RAG sobre documentos reales con contenido multimodal heterogéneo.

Métricas operativas

Además de la calidad funcional, el marco de evaluación incorpora dos métricas operativas que condicionan la viabilidad del sistema en producción:

Métrica	Descripción y relevancia
Coste por embedding	Coste monetario (USD) por vector generado, desglosado por tipo de input (texto, imagen, vídeo). Determina la viabilidad económica de la indexación masiva de documentos técnicos. Se reportan los precios de las APIs evaluadas.
Latencia de recuperación	Tiempo (ms) desde la emisión de la consulta hasta la obtención de los top-k resultados. Incluye el tiempo de generación del embedding de la query más el tiempo de búsqueda en el índice FAISS. Relevante para el requisito de latencia operativa definido en la sección 3.6.
Límites de API	Tokens por minuto (TPM), requests por minuto (RPM) y restricciones de tamaño de input. Condicionan el diseño del pipeline de ingestión y la estrategia de paralelización.

Tabla 1 Métricas operativas incorporadas al marco de evaluación del pipeline MRAG.

4.3 Arquitectura de referencia del pipeline experimental

El pipeline experimental implementado para la evaluación sigue una arquitectura modular de cuatro etapas que refleja la estructura canónica de los sistemas MRAG descritos en la literatura reciente. Esta arquitectura es deliberadamente modular para permitir la sustitución independiente de componentes, en línea con el requisito no funcional de modularidad arquitectónica definido en la sección 3.6.

Etapas 1: Ingestión y preprocesado

Los documentos de entrada (PDFs, imágenes, textos, vídeos y audios) se normalizan a un formato tratable por los modelos de *embedding*.

En el caso de documentos PDF, se adopta la estrategia de **página-como-imagen**: cada página se rasteriza a una imagen PNG mediante la librería PyMuPDF (*fitz*), con un factor de zoom configurable (por defecto 2.0) que produce imágenes de resolución suficiente para preservar la legibilidad del texto y el detalle de las figuras. Esta conversión se realiza mediante la función *pdf_page_to_image()* implementada en las clases de gestión de *embeddings*. Comienzan a aparecer modelos que ya tratan PDFs de manera nativa, aunque con limitaciones (un número máximo de imágenes por PDF, unos Mb máximos de espacio,...), aunque la técnica usada por estos modelos internamente no se diferenciará en gran medida de lo realizado aquí. Para el caso de documentos de texto extenso (como libros en formato TXT), el contenido se segmenta en fragmentos (*chunks*) de tamaño configurable utilizando *RecursiveCharacterTextSplitter* de LangChain, con tamaños de *chunk* adaptados a las limitaciones de cada modelo.





Las imágenes no necesitan un preprocesado elaborado, más allá de limitar el número de Mb/píxeles usados según el modelo.

Para los vídeos, al igual que para los audios, existen limitaciones (al menos en la fase de embedding), y se deben obtener clips de duración más corto, para lo que se ha creado un generador de clips basado en duración, aunque también se ha explorado la creación de clips no exclusivamente con duración, si no con duración máxima-mínima y detección de silencios para fragmentar dichos vídeos. Para los modelos que tiene vídeo pero sin tener en cuenta el audio, y que aceptan como input varios modos (vídeo sin audio + texto), la solución implementada es un Speech To Text.

Etap 2: Generación de embeddings multimodales

Cada unidad de contenido (página-imagen o *chunk* de texto) se transforma en un vector denso mediante el modelo de *embedding* multimodal seleccionado. Los vectores resultantes se almacenan en un índice FAISS (*Facebook AI Similarity Search*), una librería de código abierto desarrollada por Meta AI Research que implementa búsqueda de similitud y agrupamiento de vectores densos con alta eficiencia. FAISS soporta múltiples tipos de índice; en los experimentos del proyecto se utiliza **IndexFlatL2**, que realiza búsqueda exacta por fuerza bruta utilizando distancia euclidiana L2. Esta elección se justifica por dos razones: (a) el tamaño de los datasets experimentales (cientos a miles de vectores) no requiere índices aproximados, y (b) la búsqueda exacta elimina el error de aproximación como variable confundente en la evaluación de la calidad de los *embeddings*.

Junto al índice FAISS, se mantiene un fichero de metadatos en formato JSON que asocia cada vector con su documento de origen, número de página o *chunk*, ruta del fichero original y tipo de modalidad (imagen o texto). Esta asociación es esencial para la trazabilidad: cuando el sistema recupera un vector como resultado relevante, los metadatos permiten identificar exactamente de qué página de qué documento proviene la evidencia.




Ilustración 33 Implementación de las clases de gestión de embeddings con FAISS para ambos modelos evaluados.

Etap 3: Recuperación por similitud

Ante una consulta del usuario (textual o visual), se genera el *embedding* de dicha consulta utilizando el mismo modelo empleado durante la indexación, y se realiza una búsqueda de los *k* vectores más cercanos en el índice FAISS. Los resultados se

devuelven ordenados por distancia ascendente (menor distancia = mayor similitud) junto con sus metadatos asociados. El parámetro *top_k* es configurable y se evalúa típicamente con valores de 3, 5 y 9 según el experimento.

Un aspecto técnicamente relevante es la gestión de consultas multimodales combinadas. En el caso de Voyage AI o Gemini que soporta *embeddings* de texto e imagen (vídeo, audio y documentos pdf el de Gemini) intercalados en un único vector, se explora además la estrategia de combinar ambas modalidades en una sola consulta. En el caso de Vertex AI, donde los *embeddings* de texto e imagen se generan por separado, se investiga la fusión a posteriori mediante la media aritmética de los vectores, dimensión a dimensión, como mecanismo simple de combinación cross-modal.

Etapas 4: Generación de respuesta

Los documentos recuperados en la etapa anterior se proporcionan como contexto al modelo generador multimodal, junto con la consulta original del usuario. El modelo generador es responsable de razonar sobre la evidencia recuperada y producir una respuesta textual coherente, específica y fundamentada. En los experimentos del proyecto se han utilizado modelos de la familia Gemini de Google: inicialmente **gemini-2.0-flash-exp** y posteriormente **gemini-2.5-flash-preview-04-17**, aprovechando su capacidad de contexto largo para recibir múltiples páginas de PDF en formato nativo y su rendimiento competitivo en tareas de comprensión documental y visual.

La transferencia de contexto al generador se realiza de dos formas según el experimento: (a) proporcionando las imágenes de las páginas recuperadas directamente como input visual al modelo, aprovechando su capacidad multimodal nativa, o (b) proporcionando documentos PDF completos junto con indicaciones del rango de páginas relevantes. El modelo genera entonces una respuesta que, idealmente, referencia las páginas y elementos específicos donde se localiza la evidencia.






Ilustración 34 Arquitectura completa del pipeline experimental de RAG multimodal implementado en EMIE.

4.4 Selección de modelos y justificación

La selección de modelos no es una decisión arbitraria, sino el resultado de un proceso de evaluación que considera múltiples criterios técnicos, operativos y estratégicos. El espacio de opciones disponible a fecha de los experimentos incluía tanto modelos propietarios accesibles vía API como modelos de código abierto desplegados en infraestructura propia. La decisión de centrar la evaluación en tres modelos de *embedding* propietarios y un modelo generador propietario responde a la fase actual del proyecto, donde el objetivo prioritario es validar la viabilidad funcional del pipeline antes de optimizar costes mediante alternativas *on-premise*.

Modelos de embedding multimodal

Vertex AI – multimodalembd@001: este modelo, ofrecido por Google Cloud como parte de la plataforma Vertex AI, fue seleccionado por las siguientes razones técnicas. En primer lugar, soporta tres modalidades de entrada: texto, imagen y vídeo (sin audio), lo que proporciona la cobertura modal más amplia entre las opciones evaluadas. En segundo lugar, ofrece vectores de dimensión configurable (1.408, 512, 256 o 128), lo que permite explorar el *trade-off* entre riqueza representacional y eficiencia de almacenamiento/búsqueda. En tercer lugar, su

integración directa con el ecosistema de Google Cloud facilita la posterior migración a despliegues productivos sobre esta infraestructura.

Sin embargo, el modelo presenta limitaciones relevantes que deben tenerse en cuenta en la interpretación de los resultados. La más significativa es la **restricción de 1.024 caracteres (aproximadamente 32 tokens)** para el input textual, lo que impide generar *embeddings* de párrafos o páginas completas en modo texto. Esta limitación fue verificada empíricamente durante los experimentos, produciendo el error "*Text field must be smaller than 1024 characters*" cuando se intentaba indexar textos más largos. Esta restricción es precisamente uno de los factores que motivan la estrategia de página-como-imagen: dado que el *embedding* de imagen no tiene esta limitación de caracteres, resulta más práctico rasterizar la página completa y generar un *embedding* visual que capture tanto el contenido textual como el visual de forma integrada.

Modo	Cantidad máxima de incorporaciones por minuto	Intervalo de incorporación de video (valor mínimo)
Esencial	4	15
		Esto corresponde a: <code>intervalSec >= 15</code>
Estándar	8	8
		Esto corresponde a: <code>8 <= intervalSec < 15</code>
Plus	15	4
		Esto corresponde a: <code>4 <= intervalSec < 8</code>

Ilustración 35 Límites de API del modelo *multimodalemb@001* de Vertex AI.

Voyage AI – voyage-multimodal-3: este modelo, desarrollado por Voyage AI (adquirido por MongoDB), fue seleccionado como segunda opción de evaluación por su posicionamiento destacado en benchmarks independientes de *embedding* multimodal. En particular, en el benchmark MIEB (*Massive Image Embedding Benchmark*), voyage-multimodal-3 ocupa la primera posición en la categoría de modelos MLLM tanto en la versión completa (130 tareas, media de 62.5) como en la versión lite (51 tareas, media de 58.1), superando a alternativas como E5-V, SigLIP, CLIP y otros modelos de *embedding* dedicados. Estos resultados, publicados por Xiao et al. y disponibles en el leaderboard de HuggingFace MTEB, proporcionan una referencia empírica sólida para la selección.

Desde el punto de vista técnico, voyage-multimodal-3 aporta dos características diferenciales respecto al modelo de Vertex AI. En primer lugar, genera vectores de **dimensión fija de 1.024**, lo que simplifica la gestión del índice. En segundo lugar, y más relevantemente, soporta **inputs de texto e imagen intercalados** (*interleaved*) en una única llamada de *embedding*, produciendo un vector único que codifica conjuntamente ambas modalidades. La documentación del modelo lo expresa como la eliminación de la necesidad de *parsing* complejo de documentos, lo que resulta particularmente atractivo para el caso de uso Iberdrola, donde la evidencia documental está repartida entre texto, tablas y figuras dentro de las mismas páginas.



Además, voyage-multimodal-3 incorpora un mecanismo de *prompt engineering* transparente para el parámetro *input_type*: cuando se especifica *input_type="query"*, el modelo antepone internamente el prefijo "*Represent the query for retrieving supporting documents:* "; cuando se especifica *input_type="document"*, antepone "*Represent the document for retrieval:* ". Este mecanismo, basado en la técnica de *instruction-tuned embeddings*, busca mejorar la asimetría semántica entre consultas (cortas, interrogativas) y documentos (largos, declarativos) dentro del espacio de *embedding*.

MIEB-lite (51 tasks)													
Model Name (↓)	Model Type	Rtrv. (11)	Clus. (2)	ZS. (7)	LP. (8)	Cmp. (6)	VC. (5)	Doc. (6)	vSTS (en) (2)	Rtrv. (m) (2 (47))	vSTS (x&m) (2 (19))	Mean (en) (47)	Mean (m) (51)
Voyage-multimodal-3	MLLM	33.2	76.6	48.6	69.3	35.8	50.0	63.5	84.2	49.0	70.4	57.7	58.1
siglip-so400m-patch14-384	Enc.	32.4	75.9	73.8	78.8	32.8	48.0	46.9	69.6	35.4	41.4	57.3	53.5
siglip-large-patch16-384	Enc.	31.9	75.2	71.3	77.7	32.1	46.8	44.9	69.6	43.5	39.8	56.2	53.3
E5-V	MLLM	26.9	51.7	36.2	70.6	39.4	52.6	56.0	81.2	58.3	46.3	51.8	51.9
siglip-large-patch16-256	Enc.	31.0	76.5	70.3	76.3	33.4	46.5	31.9	67.6	42.6	38.1	54.2	51.4
CLIP-ViT-bigG-14-laion2B	Enc.	34.2	80.8	72.4	77.8	35.0	43.0	35.5	73.4	26.2	34.5	56.5	51.3
siglip-base-patch16-512	Enc.	30.8	69.7	66.3	74.6	29.7	55.5	42.6	67.1	34.8	38.1	54.5	50.9
EVA02-CLIP-bigE-14-plus	Enc.	35.2	87.3	74.0	80.0	38.9	38.8	26.2	73.7	26.0	28.2	56.8	50.8
siglip-base-patch16-384	Enc.	30.6	72.2	66.0	74.4	31.0	55.1	37.1	66.9	34.5	37.5	54.1	50.5
CLIP-ViT-L-14-DataComp.XL	Enc.	31.0	80.4	69.4	75.3	31.6	54.9	30.8	72.5	22.6	35.8	55.7	50.4
CLIP-ViT-H-14-laion2B	Enc.	32.8	79.3	69.4	76.8	34.8	46.8	33.7	68.3	23.9	33.9	55.2	50.0
EVA02-CLIP-bigE-14	Enc.	34.3	86.7	73.0	78.3	35.1	44.4	25.1	69.9	23.9	28.3	55.9	49.9
siglip-base-patch16-256(m)	Enc.	28.2	68.2	63.2	73.4	30.7	53.3	22.9	63.7	52.9	40.3	50.4	49.7
CLIP-ViT-g-14-laion2B	Enc.	33.5	76.8	69.6	77.3	34.7	45.0	29.9	71.6	24.2	31.7	54.8	49.4
siglip-base-patch16-256	Enc.	29.5	69.6	65.6	73.6	32.2	54.4	25.0	66.1	33.5	34.4	52.0	48.4
CLIP-ViT-L-14-laion2B	Enc.	31.1	76.4	67.8	75.9	33.6	46.9	28.7	68.7	21.4	26.0	53.6	47.6
clip-vit-large-patch14	Enc.	26.7	71.3	63.8	74.5	39.4	44.9	29.4	69.4	19.8	35.1	52.4	47.4
siglip-base-patch16-224	Enc.	29.3	68.4	65.0	73.5	32.5	53.0	20.9	64.2	33.6	33.5	50.8	47.4
CLIP-ViT-B-16-DataComp.XL	Enc.	28.3	73.6	61.9	73.2	31.4	56.9	22.7	69.7	19.9	28.5	52.2	46.6
VLM2Vec-LoRA	MLLM	21.0	66.3	32.1	64.8	29.4	65.3	42.7	70.9	24.8	42.2	49.1	46.0

Ilustración 36 Resultados del benchmark MIEB mostrando el rendimiento de voyage-multimodal-3 frente a alternativas.

Gemini Embedding 2 – gemini-embedding-2-preview: este modelo, introducido recientemente en fase *preview* por Google como la evolución de su oferta en Vertex AI y la API de Gemini, fue incorporado a la evaluación por representar el estado del arte en arquitecturas de *embedding* verdaderamente nativas y unificadas. En términos de rendimiento empírico, el modelo proporciona un salto cualitativo documentado, alcanzando la primera posición en el benchmark multilingüe MTEB y estableciendo nuevos estándares en la recuperación cruzada entre texto, imágenes y vídeo.

Desde el punto de vista técnico y operativo, gemini-embedding-2-preview aporta tres avances fundamentales que impactan directamente en el diseño del sistema de recuperación y resuelven las limitaciones de sus predecesores:

En primer lugar, abandona la estructura de *encoders* separados observada en multimodalembdding@001. Al estar construido sobre la arquitectura fundacional compartida de Gemini, el modelo proyecta texto, imágenes, vídeo, audio de forma nativa e incluso documentos complejos (como PDFs de hasta 6 páginas) en un único espacio de *embedding* conjunto. Al igual que Voyage AI, soporta el envío de inputs intercalados en una sola llamada de API, capturando las relaciones semánticas entre diferentes modalidades sin requerir un ensamblaje o preprocesamiento complejo por parte del pipeline.

En segundo lugar, resuelve de forma radical el cuello de botella del tamaño de entrada. La ventana de contexto textual se ha expandido drásticamente hasta los



8.192 tokens (frente a los limitados 1.024 caracteres de la versión anterior). Esta ampliación mitiga la necesidad estricta de recurrir a la estrategia de "página-como-imagen" puramente por restricciones de longitud, permitiendo indexar fragmentos de texto mucho más extensos y ricos en contexto, o procesar directamente el documento PDF completo si fuera necesario.

Por último, el modelo implementa una innovación estructural clave denominada **Matryoshka Representation Learning (MRL)**. Este enfoque de entrenamiento concentra la información semántica más importante en las primeras dimensiones del vector. Como resultado, el modelo devuelve por defecto vectores de gran tamaño (3.072 dimensiones) que el sistema puede truncar dinámicamente a dimensiones menores (por ejemplo, 1.536, 768 o 128) manteniendo una retención de información extraordinariamente alta. Esta característica proporciona una flexibilidad arquitectónica invaluable para balancear los costes de infraestructura (memoria RAM y almacenamiento en la base de datos vectorial) frente a la precisión y el *recall* del *retrieval* en el entorno productivo.

Metric type	Metric name	Gemini Embedding 2	gemini-embedding-001 Legacy text-only Google model	multimodalembembedding@001 Legacy multimodal Google model	Amazon Nova 2 Multimodal Embeddings	Voyage Multimodal 3.5
Text-Text	MTEB (Multilingual) Mean (Task)	69.9	68.4	—	63.8**	58.5***
	MTEB (Code) Mean (Task)	84.0	76.0	—	*	*
Text-Image	TextCaps recall@1	89.6	—	74.0	76.0	79.4
	Docci recall@1	93.4	—	—	84.0	83.8
Image-Text	TextCaps recall@1	97.4	—	88.1	88.9	88.6
	Docci recall@1	91.3	—	—	76.5	77.4
Text-Document	ViDoRe v2 ndcg@10	64.9	—	28.9	60.6	65.5**
Text-Video	Vatex ndcg@10	68.8	—	54.9	60.3	55.2
	MSR-VTT ndcg@10	68.0	—	57.9	67.0	63.0**
	Youcook2 ndcg@10	52.5	—	34.9	34.7	31.4**
Speech-Text	MSEB mrr@10	73.9	—	—	*	—
	MSEB (ASR)**** mrr@10	70.4	—	—	*	—

— task not supported
* score not available ** self-reported *** voyage-3.5 **** ASR model converts audio queries to text

Ilustración 37 Tabla comparativo de modelos y benchmarks reportados por Google

Modelo generador

Para la fase de generación se seleccionan modelos de la familia **Gemini** de Google. La justificación es triple. En primer lugar, Gemini es nativamente multimodal: puede recibir como input texto, imágenes, PDF completos, audio y vídeo dentro de un mismo contexto, lo que elimina la necesidad de transcribir o convertir las páginas recuperadas antes de proporcionarlas al generador. En segundo lugar, ofrece ventanas de contexto muy amplias (hasta 1 millón de tokens en Gemini 1.5 Pro y configuraciones extendidas), lo que permite proporcionar múltiples documentos PDF completos como contexto sin truncamiento. En tercer lugar, los modelos Gemini



Flash ofrecen un equilibrio competitivo entre calidad de generación, latencia y coste, lo que los sitúa como candidatos viables para un despliegue posterior en producción. Durante los experimentos se utilizaron dos versiones: **gemini-2.0-flash-exp** en la fase inicial de exploración, y **gemini-2.5-flash-preview-04-17** en la fase de evaluación más sistemática. La migración entre versiones se produjo de forma natural al estar disponibles versiones más recientes con mejor rendimiento en comprensión documental y visual, y evidenció una de las ventajas de la arquitectura modular: el cambio de modelo generador no requirió modificar ningún otro componente del pipeline.

Tabla comparativa de modelos

Característica	Vertex AI multimodalembd@001	Voyage AI voyage- multimodal-3	Gemini (generador)
Tipo	Embedding multimodal	Embedding multimodal	Generador multimodal
Modalidades input	Texto, imagen, vídeo (sin audio)	Texto, imagen, intercalados	Texto, imagen, PDF, audio, vídeo
Dimensión vector	1.408 / 512 / 256 / 128	1.024 (fija)	N/A
Límite texto	1.024 caracteres (~32 tokens)	32.000 tokens por input	1M+ tokens contexto
Input intercalado	No (cada modalidad por separado)	Sí (texto+imagen en un vector)	Sí (nativo)
Coste imagen	Incluido en plan GCP	\$0.60/1B píxeles (máx \$0.0012/img)	Variable por tokens
RPM básico	120 req/min	2.000 req/min	Variable por plan

Tabla 2 Comparativa técnica de los modelos seleccionados para el pipeline experimental.

4.5 Datasets y escenarios de prueba

La estrategia de validación experimental se basa en una **progresión de complejidad creciente** a través de cuatro escenarios de prueba que van desde tareas de validación elemental hasta escenarios próximos a los casos de uso industriales reales del proyecto. Esta progresión no es arbitraria: cada escenario está diseñado para validar una capacidad específica del pipeline y para aislar, en la medida de lo posible, las variables que influyen en el rendimiento.

Escenario 1 — Imágenes con texto visible (Experimento Perros)

El primer escenario es una prueba de validación elemental diseñada para verificar si el modelo de *embedding* visual es capaz de **reconocer texto presente dentro de imágenes** y codificarlo de forma semánticamente recuperable. Se utiliza un conjunto de 16 imágenes de perros donde cada animal lleva un collar con su nombre escrito de forma visible. Las consultas de prueba incluyen preguntas que referencian el nombre del perro (por ejemplo, "¿De qué raza es Diva?"), lo que obliga al sistema a localizar la imagen donde aparece ese nombre en el collar.

Este escenario valida una capacidad fundamental: la presencia de OCR implícito en el modelo de *embedding*. Si el modelo es capaz de codificar el texto visible en la imagen de forma que una consulta textual con ese mismo texto produzca alta



similitud vectorial, entonces la estrategia de página-como-imagen para PDFs tiene una base sólida, porque el texto de las páginas renderizadas como imagen será igualmente recuperable. Además, este escenario permite evaluar queries más abstractas ("¿Cuáles están sobre una cama?", "Me gustan los colores variopintos") que no referencian texto escrito sino contenido visual semántico.



Ilustración 38 Ejemplos del dataset de validación elemental (Experimento Perros) con texto visible en collares.

Escenario 2 — Imágenes industriales con texto (Experimento Grúas)

El segundo escenario traslada la evaluación hacia un contexto más próximo al dominio industrial: imágenes de grúas portuarias donde el nombre del puerto aparece en la parte inferior de la imagen. Este escenario introduce dos dificultades adicionales respecto al anterior: el texto es de menor tamaño relativo a la imagen total, y la calidad fotográfica es más variable (ángulos, iluminación, distancia). Los resultados de este escenario permiten calibrar las expectativas sobre la capacidad del modelo de reconocer texto en condiciones menos controladas, lo que es directamente relevante para escenarios de mantenimiento donde las fotografías capturadas por el técnico pueden tener calidad variable.

Escenario 3 — PDFs documentales heterogéneos (Experimento PDFs Financieros)

El tercer escenario constituye la primera prueba completa del pipeline de RAG multimodal. Se utilizan 2 documentos PDF de aproximadamente 25 páginas cada uno, correspondientes a cartas anuales de fondos de inversión. Estos documentos son especialmente adecuados como banco de pruebas porque contienen una mezcla heterogénea de **texto extenso**, **tablas numéricas**, **gráficas de rendimiento**, **imágenes de personas y logotipos**, lo que obliga al sistema a recuperar evidencia de naturaleza muy diversa.

Este escenario se evalúa mediante cuatro tipos de consulta que cubren las combinaciones posibles de modalidad query-documento:

Tipo de query	Tipo de evidencia	Ejemplo y objetivo
Texto → Texto	Texto en páginas-imagen	"¿Cuáles son las principales posiciones de la cartera?" — Valida la recuperación de texto indexado como imagen.
Texto → Imagen	Imágenes dentro de páginas	"¿En qué página aparecen los Simpson?" — Valida la recuperación de contenido visual mediante query textual.



Imagen → Imagen	Imágenes similares en páginas	Foto de Homer Simpson como query → Valida recuperación visual directa (image-to-image).
Texto-como-imagen vs. Texto puro	Mismo contenido, diferente modalidad	Mismo párrafo indexado como texto y como captura de pantalla → Detección directa del modality gap.

Tabla 3 Tipos de consulta evaluados en el Escenario 3 (PDFs Financieros).

Escenario 4 — Manuales técnicos de motos (Escenario cuasi-industrial)

El cuarto y más exigente escenario utiliza **25 manuales de servicio de motocicletas** como corpus documental. Este escenario es el más cercano al caso de uso de mantenimiento definido en la sección 3.3, ya que replica la situación de un técnico que necesita consultar documentación técnica para resolver una tarea. Los manuales contienen diagramas de despiece, tablas de especificaciones, procedimientos paso a paso ilustrados, y fotografías de los vehículos.

La prueba cuantitativa principal en este escenario consiste en proporcionar **fotografías de cada motocicleta** (obtenidas externamente, no del propio manual) como consulta de imagen y verificar si el sistema es capaz de recuperar las páginas del manual correspondiente a esa moto. De las 25 motos, se descartan 3 cuyos manuales no contienen ninguna imagen de la motocicleta completa, quedando 22 motos evaluables. De estas, 12 tienen fotografías completas en el manual, 8 solo tienen dibujos técnicos, y 3 muestran solo la mitad del vehículo. Esta heterogeneidad es intencionada porque refleja la variabilidad real de la documentación técnica industrial.

Adicionalmente, para Voyage AI se construye un escenario mixto que combina el libro de Harry Potter (347 páginas en formato texto) con 6 manuales de motos (total ~3.000 páginas como imágenes), creando una base de datos multimodal de gran tamaño que permite evaluar la capacidad del modelo para discriminar entre modalidades y entre dominios temáticos simultáneamente.

Escenario 5 – Vídeos, audios, imágenes y PDFs de temáticas lejanas

El quinto escenario se produce a modo introductorio para valorar los nuevos modelos de embedding que aceptan nuevas modalidades como son audio y vídeo (con audio), o nuevos formatos como es el de un PDF de manera nativa. Se utilizan así **3 vídeos con audio** (duración >5 minutos), uno donde la importancia reside tanto en las imágenes como en el propio audio sobre **divulgación biología y química** (uso de psicodélicos en medicina); otros dos vídeos de **goles de fútbol** donde el audio no es tan relevante. Los **2 audios** usados (duración > 5 minutos) tratan sobre **redes neuronales convolucionales** y **antropología filosófica**. Los **4 PDFs** usados son 2 temáticas: informes técnicos sobre **fondos de inversión** (3) y sobre **reparación de motos** (1, el de más páginas). Las **40 imágenes** usadas son de **platos de comida internacionales**. La elección de estas temáticas es arbitraria, pero se trata de buscar **temáticas claramente distintas** pues se probará a recuperar los distintos documentos con **preguntas** en **formato texto**, **evitando** una posible **relación semántica compartida** entre distintas temáticas.

4.6 Estrategia de indexación: página-como-imagen vs. parsing multimodal

Una de las decisiones de diseño más determinantes del pipeline experimental es la adopción de la estrategia de **página-como-imagen** como método principal de indexación de documentos PDF. Esta decisión merece una discusión técnica detallada porque afecta directamente a la calidad de la recuperación, al coste computacional y a la escalabilidad del sistema.

Justificación técnica

La estrategia convencional de indexación de PDFs en sistemas RAG consiste en extraer el texto mediante herramientas de *parsing* (PyPDF, pdfplumber, unstructured, etc.), segmentarlo en *chunks* de tamaño fijo o semántico, y generar un *embedding* textual por cada *chunk*. Este enfoque es maduro y eficaz cuando el documento es predominantemente textual. Sin embargo, presenta tres limitaciones fundamentales para los documentos técnicos típicos de EMIE:

Pérdida de información visual: las tablas, gráficas, diagramas, fotografías y esquemas se pierden completamente o se reducen a texto extraído (a menudo ruidoso) que no captura su contenido semántico. El benchmark MMDocIR (citado en la sección 3) demostró que en documentos visualmente ricos, las imágenes y tablas concentran una fracción informativa significativa que no es recuperable mediante *parsing* textual convencional.

Pérdida de contexto de layout: el *parsing* textual destruye la estructura espacial de la página. En documentos técnicos, la posición relativa de un texto respecto a una figura, una tabla o un diagrama aporta información semántica relevante (por ejemplo, un pie de figura que explica una imagen adyacente). Al extraer el texto plano, esta relación espacial se pierde.

Complejidad del pipeline: para capturar las diferentes modalidades de un PDF de forma convencional, es necesario implementar múltiples subpipelines: extracción de texto, detección y extracción de tablas (con herramientas como Camelot o Tabula), extracción de imágenes embebidas, generación de *captions* o descripciones de las imágenes mediante un modelo VLM, y posterior indexación conjunta. Esta complejidad introduce múltiples puntos de fallo y dificulta la mantenibilidad del sistema.

Frente a estas limitaciones, la estrategia de página-como-imagen ofrece una solución unificada: al tratar cada página como una imagen, se captura de forma nativa todo el contenido de la página (texto, tablas, figuras, layout) en una única representación vectorial. La viabilidad de esta estrategia depende crucialmente de que el modelo de *embedding* sea capaz de codificar no solo el contenido visual de la imagen sino también el texto presente en ella, lo que fue precisamente el objeto de validación del Escenario 1 (Experimento Perros) y del Escenario 3 (PDFs Financieros).

Esta estrategia está alineada con las tendencias recientes identificadas en la revisión de RAGFlow (2025), que identifica la "*página como unidad de recall*" como un enfoque común en la ingeniería de sistemas MRAG, con variantes que incluyen indexación híbrida (texto + tensor de imagen) y esquemas de *text-first*, *tensor*



reranking. La aproximación adoptada en EMIE se sitúa en el extremo más simple de este espectro: indexación puramente visual de la página, sin *reranking* posterior. Esta simplicidad es deliberada para esta fase del proyecto, con el objetivo de aislar la contribución del modelo de *embedding* sin variables confundentes introducidas por mecanismos de *reranking* o fusión.

Limitaciones conocidas

La estrategia de página-como-imagen presenta limitaciones que deben ser explicitadas para una correcta interpretación de los resultados:

Granularidad: la unidad mínima de recuperación es la página completa. Si la evidencia necesaria es un párrafo específico o una celda de una tabla, el sistema recuperará toda la página, delegando al modelo generador la tarea de localizar el elemento relevante dentro de ella. Esto es menos preciso que un sistema que indexa a nivel de fragmento o de elemento.

Coste de embedding: generar un embedding por página es más costoso que generar un embedding por chunk de texto, especialmente para documentos largos. Un manual de 1.200 páginas requiere 1.200 llamadas al API de embedding, con el correspondiente coste económico y temporal.

Dependencia del OCR implícito: la calidad de la recuperación textual depende enteramente de la capacidad del modelo de embedding para reconocer y codificar el texto renderizado en la imagen. Si el texto es pequeño, de baja resolución o en idiomas con soporte limitado, esta capacidad puede degradarse. La limitación de Vertex AI a inglés como idioma soportado para texto es relevante en este contexto, dado que la documentación de EMIE está predominantemente en español.

4.7 Metodología de validación

La metodología de validación empleada combina evaluación cuantitativa automatizada y evaluación cualitativa experta, ajustada a las limitaciones y objetivos de cada fase experimental.

Validación de la recuperación

Para cada escenario de prueba, la validación de la recuperación se realiza mediante un protocolo estructurado. En primer lugar, se define un conjunto de consultas de prueba con sus **documentos o páginas objetivo** conocidos (*ground truth* de recuperación). En el Escenario 4 (motos), este *ground truth* consiste en las páginas del manual que contienen una imagen de la motocicleta completa. En el Escenario 3 (PDFs financieros), se identifican manualmente las páginas donde aparece la información relevante para cada consulta. En los Escenarios 1 y 2, cada imagen tiene una asociación unívoca con la consulta.

Para cada consulta, se ejecuta la búsqueda y se registran los *top-k* resultados con sus distancias. Se calcula entonces el Recall@k verificando si al menos una de las páginas objetivo aparece entre los *k* resultados. Además, se registra la distribución completa de distancias para análisis posterior. Este protocolo permite no solo reportar tasas de éxito globales, sino también identificar patrones de fallo: ¿los fallos se concentran en ciertos tipos de documento? ¿Se asocian a distancias



uniformemente altas (indicando poca discriminación) o a competición con páginas similares (distancias muy próximas entre el resultado correcto y el incorrecto)?

Validación del *modality gap*

La validación del *modality gap* se realiza mediante dos técnicas complementarias. La primera es la **comparación directa de distancias** cuando el mismo contenido se presenta como texto y como imagen: se selecciona un párrafo de un documento, se genera su *embedding* textual y su *embedding* como captura de pantalla del mismo párrafo, y se compara la distancia de cada uno respecto a la página-imagen indexada que lo contiene. Si la distancia del *embedding* de imagen es significativamente menor que la del *embedding* de texto para la misma información, esto constituye evidencia directa de *modality gap*. En el caso de Vertex AI, este experimento reveló distancias de 0.54 (imagen) frente a 1.65 (texto) para el mismo contenido, lo que confirma un gap sustancial.

La segunda técnica es el **análisis PCA** del espacio completo de vectores indexados. Se proyectan todos los vectores sobre las dos primeras componentes principales y se colorean según su modalidad de origen. Si los puntos se segregan claramente por modalidad, el gap es estructural. En el caso de Voyage AI, el PCA mostró una segregación parcial con un 13.92% de varianza explicada por la primera componente, lo que indica un gap presente pero más moderado que el observado en Vertex AI.

Validación de la generación

La validación de la fase de generación se realiza bajo tres condiciones experimentales diferenciadas, diseñadas para aislar la contribución del RAG:

Condición A – Sin RAG: se presenta la consulta al modelo generador sin ningún contexto documental, confiando únicamente en su conocimiento paramétrico. Las respuestas producidas bajo esta condición sirven como *baseline* para medir el valor añadido de la recuperación.

Condición B – RAG erróneo: se presenta la consulta junto con documentos recuperados que no corresponden al contenido correcto (por ejemplo, páginas de un manual de moto diferente). Esta condición evalúa la robustez del generador ante contexto engañoso y la tendencia a producir respuestas que parezcan fundamentadas pero sean incorrectas.

Condición C – RAG exitoso: se presenta la consulta junto con las páginas correctas, verificadas manualmente como relevantes. Esta condición representa el *upper bound* del rendimiento del sistema y permite evaluar la calidad intrínseca del generador cuando dispone de evidencia adecuada.

La comparación entre estas tres condiciones permite construir un argumento empírico sobre el valor del pipeline completo: si la Condición C produce respuestas significativamente más específicas, precisas y operativas que las Condiciones A y B, el pipeline de RAG multimodal justifica su complejidad adicional. Los ejemplos concretos de respuestas bajo cada condición se presentan y analizan en detalle en la sección 6.

Sin RAG

Respuesta del modelo: ¡Excelente idea! Revisar los frenos y el aceite es fundamental para mantener tu nueva moto en óptimas condiciones y garantizar tu seguridad. Aquí tienes unos puntos clave para revisar: **Revisión de Frenos:** **Nivel de Líquido de Frenos:** Localiza los depósitos de líquido de frenos (generalmente en el manillar para el delantero y cerca del pedal para el trasero). Verifica que el nivel esté entre las marcas de mínimo y máximo. Si está bajo, podría indicar desgaste de pastillas o una fuga (menos probable en una moto nueva, pero posible). **Estado de las Pastillas de Freno:** Mira las pastillas de freno en cada rueda. Deberías ver la capa de material de fricción. Si se ve muy delgada o casi al metal, necesitan ser reemplazadas. El manual de tu moto te dirá el grosor mínimo permitido. **Estado de los Discos de Freno:** Examina los discos. Busca surcos profundos, rayones excesivos o decoloración (que podría indicar sobrecalentamiento). Pasa el dedo por el borde del disco; si notas un reborde prominente, el disco podría estar desgastado. **Sensación de la Maneta y el Pedal:** Acciona la maneta del freno delantero y el pedal del freno trasero. Deberían sentirse firmes, sin esponjosidad. Si se sienten blandos o llegan a fondo cerca del manillar/pie antes de frenar, podría haber aire en el circuito o un problema con el líquido. **Revisión de Aceite:** **Nivel de Aceite:** **Consulta el Manual:** Lo más importante es saber si tu moto usa una ventana de inspección o una varilla medidora, y si el nivel se mide con el motor frío o caliente, y si la moto debe estar recta o en la pata de cabra. **Cada moto es diferente.** **Procedimiento General (si tiene ventana):** Con la moto en posición vertical (no en la pata de cabra) y el motor a la temperatura recomendada por el manual (a menudo después de haber funcionado unos minutos y haber reposado otros), mira la ventana en el lado del cárter. El nivel de aceite debe estar entre las marcas de mínimo y máximo. **Procedimiento General (si tiene varilla):** Con la moto en la posición y temperatura correcta, desenrosca (o sácala si no es roscada) la varilla, límpiala, vuelve a introducirla sin enroscar (si es de rosca) o enroscando completamente (si el manual lo indica), sácala de nuevo y mira el nivel. Debe estar entre las marcas. **Color y Consistencia del Aceite:** El aceite debe verse limpio, de color miel o ligeramente oscuro si ya tiene algo de uso, pero no negro, espeso o con partículas metálicas visibles. **Fugas:** Revisa alrededor del motor y debajo de la moto en busca de manchas de aceite que puedan indicar una fuga. **Consejo Adicional:** **El Manual del Propietario es tu Mejor Amigo:** Para saber exactamente cómo revisar el aceite (temperatura, posición, varilla/ventana) y el grosor mínimo de las pastillas, consulta siempre el manual de tu nueva moto. **Primer Servicio:** Las motos nuevas tienen un primer servicio (generalmente a los 500-1000 km) que es crucial. En ese servicio se cambian aceite y filtro, se revisan tornillería, cadena, frenos, etc. Asegúrate de hacerlo para que la garantía sea válida y la moto tenga una buena vida útil. ¡Disfruta tu nueva moto!
Error RAG
Respuesta del modelo: Hola. Entendido, quieres cambiar los frenos de tu moto Kawasaki. Veo que has proporcionado un manual que parece ser para los modelos Kawasaki Z800 y Z800 ABS. Aunque mencionas una "Kawasaki Ninja", la imagen de la portada del manual es de una Z800, que es un modelo diferente de la familia Kawasaki. La otra imagen que muestras parece ser una ZX-10R. Es importante asegurarse de tener el manual correcto para tu modelo específico, ya que los procedimientos y especificaciones pueden variar. Si tu moto es efectivamente una **Kawasaki Z800 o Z800 ABS**, el manual que proporcionaste contiene información detallada sobre el sistema de frenos. Según la "Guía rápida" (página 3 del OCR), la sección de **frenos** comienza en la **página 12** del manual (página 423 en el OCR de las imágenes que enviaste). Dentro de esa sección, encontrarás procedimientos específicos como: **Inspección del desgaste de la pastilla de freno:** Página 12-27 (OCR 449) **Desmontaje/Instalación de las pastillas de freno:** Páginas 12-24 (OCR 446) y 12-26 (OCR 448) **Cambio del líquido de frenos:** Páginas 12-32 (OCR 454) **Purga del tubo del sistema de freno:** Página 12-32 (OCR 454) **Importante:** Cambiar los frenos es una tarea crítica para la seguridad. Asegúrate de seguir todos los pasos del manual, incluyendo los pares de apriete especificados (página 12-5 a 12-13 del manual / OCR 415), y utilizar el líquido de frenos correcto (DOT4 para la Z800/Z800 ABS según el manual). Si tu modelo de moto es diferente (por ejemplo, una Ninja ZX-10R), este manual podría no ser el adecuado y las piezas y procedimientos serían distintos. Por favor, confirma el modelo exacto si no estás seguro. ¿Necesitas ayuda con algún procedimiento específico del capítulo de frenos del manual de la Z800/Z800 ABS?
Éxito RAG
Respuesta del modelo: Claro, puedo ayudarte con eso utilizando el manual de servicio de tu Kawasaki Ninja ZX-10R. "Cambiar los frenos" puede referirse a varias tareas, como reemplazar las pastillas de freno, cambiar el líquido de frenos o incluso reemplazar los discos o las pinzas. Basándonos en el manual proporcionado, tienes información sobre estos procedimientos comunes: El capítulo principal sobre los frenos es el **Capítulo 12 - Frenos**. Allí encontrarás secciones detalladas con ilustraciones y procedimientos. **1. Sustitución de las pastillas de freno:** - Si quieres cambiar las pastillas debido al desgaste, consulta la sección **Inspección del desgaste de la pastilla de freno** en la **página 2-53** (Imagen 75) y en las **páginas 12-19 a 12-20** (Imágenes 391-392). - Encontrarás los grosores estándar y límites de servicio para las pastillas delanteras y traseras en las **páginas 2-13** (Imagen 35) y **12-8** (Imagen 380). - Las instrucciones para retirar e instalar las pastillas delanteras y traseras se encuentran en las **páginas 12-19 a 12-20** (Imágenes 391-392). - Después de cambiar las pastillas, hay una ADVERTENCIA importante en las **páginas 12-19** (Imagen 391) y **12-20** (Imagen 392) que indica que necesitarás bombear varias veces la maneta/pedal de freno para que las pastillas se asienten y obtengan una frenada firme. (No conduzcas la motocicleta hasta que hayas hecho esto!) **2. Cambio del líquido de frenos:** - Es una tarea de mantenimiento periódica importante. El procedimiento se describe en las **páginas 2-45 a 2-46** (Imágenes 67-68) y en las **páginas 12-26 a 12-28** (Imágenes 398-400). - El manual recomienda utilizar **líquido de frenos DOT4** (páginas 2-13 y 12-8). - Hay una ADVERTENCIA crucial en las **páginas 2-45** (Imagen 67) y **12-26** (Imagen 398) sobre **no mezclar marcas o tipos diferentes de líquido de frenos**, ya que puede reducir la eficacia del sistema. - No sabes que líquido hay, cambia completamente todo el líquido del circuito. - Un AVISO importante en las **páginas 2-47** (Imagen 69), **12-26** (Imagen 398) y **12-29** (Imagen 401) te recuerda que el líquido de frenos puede dañar las superficies pintadas y de plástico, y que debe limpiarse inmediatamente si se derrama. - El manual también incluye instrucciones para purgar el aire del sistema (**Purga del tubo del sistema de frenado**) en las páginas 12-32 a 12-34 / Imágenes 454-456). **3. Sustitución de discos de freno:** - Si los discos están desgastados o deformados, puedes cambiarlos. - La inspección del desgaste y deformación de los discos se encuentra en las **páginas 2-55** (Imagen 77) y **12-25** (Imagen 397). Los límites de servicio están en las **páginas 2-13** (Imagen 35) y **12-8** (Imagen 380). - Las instrucciones de desmontaje e instalación se encuentran en la **página 12-24** (Imagen 396). - El par de apriete para los tornillos de montaje de los discos de freno (delantero y trasero) es **28 N·m (2,9 kgf·m, 21 ft·lb)** (páginas 2-8 y 12-24). Estos tornillos requieren fijador no permanente (sin 'L' en las listas de pares de apriete). **Otras piezas de freno:** El manual también cubre el desmontaje y montaje de las pinzas de freno, las bombas de freno (cilindros maestros) y los tubos/mangueras, incluyendo la sustitución de piezas de goma si es necesario. Consulta las secciones correspondientes en el **Capítulo 12 - Frenos** (a partir de la página 12-14 / Imagen 386 para pinzas, página 12-28 / Imagen 450 para bombas y página 12-35 / Imagen 457 para tubos/mangueras). Recuerda que el manual sugiere que, si no tienes la experiencia o las herramientas adecuadas, el trabajo lo realice un mecánico cualificado (**página 1-2** / Imagen 10). También enfatiza la importancia de utilizar herramientas adecuadas y piezas originales Kawasaki (**página 1-2** / Imagen 10). Espero que esta información te sea útil para cambiar los frenos de tu Kawasaki Ninja ZX-10R. Si tienes alguna otra duda sobre un procedimiento específico, no dudes en preguntar.

Limitaciones metodológicas

Es importante explicitar las limitaciones de la metodología de validación empleada en esta fase del proyecto. En primer lugar, la evaluación de recuperación se basa en *ground truth* construido manualmente para cada escenario, lo que limita la escala de la evaluación y puede introducir sesgos en la selección de consultas. En segundo lugar, la evaluación de generación es cualitativa y no utiliza métricas automáticas estandarizadas, lo que dificulta la comparación cuantitativa rigurosa entre condiciones. En tercer lugar, los datasets utilizados son representativos pero no exhaustivos del dominio industrial objetivo de EMIE. Estas limitaciones son conocidas y aceptadas como propias de una fase exploratoria de la investigación,

CONFIDENCIAL

cuyo objetivo es demostrar viabilidad funcional y obtener *insights* sobre las fortalezas y debilidades de cada componente, no producir resultados estadísticamente definitivos sobre la superioridad de un enfoque sobre otro.

La construcción de un benchmark formal anotado, con métricas automáticas de generación y *ground truth* de recuperación a escala, se identifica como una línea de trabajo prioritaria para las fases posteriores del proyecto, en línea con las recomendaciones de la comunidad reflejadas en benchmarks como MRAG-Bench (Hu et al., 2024), REAL-MM-RAG (Wasserman et al., 2025) y Open RAG Benchmark (Vectara, 2025).



5. Exploración de Técnicas Innovadoras en Multimodalidad

El presente capítulo profundiza en las técnicas específicas que sustentan el pipeline experimental del proyecto EMIE, analizándolas desde una perspectiva técnica rigurosa y situándolas en el contexto de la literatura más reciente. Mientras que la sección 2 ofreció una panorámica amplia del estado del arte en modelos multimodales y la sección 4 definió el marco metodológico de la investigación, esta sección desciende al nivel de detalle necesario para comprender **por qué** cada decisión técnica se toma como se toma, **qué alternativas existen** y **cuáles son los fundamentos teóricos** que explican el comportamiento observado en los experimentos. La estructura sigue una progresión lógica que va desde las estrategias generales de RAG multimodal hasta las técnicas específicas de combinación de embeddings y las líneas prospectivas de evolución hacia voz, vídeo y tiempo real.

5.1 RAG multimodal: de la recuperación textual a la recuperación cross-modal

La técnica de Retrieval-Augmented Generation, formalizada por Lewis et al. (2020), supuso un cambio de paradigma en la forma de utilizar modelos de lenguaje para tareas que requieren conocimiento externo actualizado o específico de dominio. En su formulación original, RAG opera exclusivamente sobre texto: un retriever basado en embeddings textuales localiza pasajes relevantes en un corpus, y un generador produce una respuesta condicionada tanto por la consulta como por los pasajes recuperados. Esta arquitectura resolvía elegantemente dos problemas fundamentales de los LLMs: la tendencia a producir alucinaciones cuando el conocimiento paramétrico es insuficiente, y la incapacidad de acceder a información no presente en los datos de entrenamiento.

Sin embargo, la extensión de RAG al dominio multimodal introduce desafíos cualitativamente diferentes que trascienden la mera adición de otra modalidad al pipeline. El survey de Abootorabi et al. (2025), *"Ask in Any Modality"*, proporciona una taxonomía exhaustiva de estos desafíos y organiza el campo de MRAG en torno a cuatro ejes: datasets y benchmarks, métricas de evaluación, metodologías de retrieval multimodal, y estrategias de fusión y generación aumentada. Una de las contribuciones más valiosas de este survey para el contexto de EMIE es la identificación de tres paradigmas fundamentales de diseño que difieren en cómo se trata la heterogeneidad modal del corpus documental.

Paradigma A: Textualización completa

El primer paradigma consiste en convertir toda la información no textual a texto antes de indexarla. Las imágenes se describen mediante modelos de *captioning* (como BLIP-2 o LLaVA), las tablas se serializan a texto plano o Markdown, y los gráficos se transcriben mediante descripciones generadas. Una vez textualizado todo el contenido, el pipeline se reduce a un RAG textual convencional, con la ventaja de poder reutilizar toda la infraestructura de indexación, búsqueda y generación ya madura para texto. El paper de ColPali (Faysse et al., ICLR 2025) describe este paradigma como el enfoque estándar de la industria y lo critica precisamente por su

CONFIDENCIAL

fragilidad: cada paso de conversión (OCR, detección de layout, captioning, serialización de tablas) introduce errores que se propagan y se amplifican a lo largo del pipeline. Además, la textualización destruye información visual que puede ser semánticamente relevante: el layout de una tabla, el color de un gráfico, la posición relativa de un elemento en la página.




Ilustración 39 Esquema del framework de aprendizaje multimodal con encoders de imagen y texto mapeando a un espacio compartido y las funciones de pérdida asociadas. Fuente: Lin et al. (WACV 2023).

Paradigma B: Indexación multimodal separada con fusión de resultados

El segundo paradigma mantiene cada modalidad en su espacio de representación nativo pero construye índices separados que se consultan en paralelo. Por ejemplo, los fragmentos textuales se indexan con un modelo de embedding textual (como BGE-M3 o text-embedding-3-large), las imágenes se indexan con un modelo visual (como CLIP-ViT), y las tablas pueden indexarse como texto serializado o como imágenes renderizadas. Ante una consulta, se realiza la búsqueda en cada índice por separado y los resultados se fusionan mediante estrategias de *rank fusion* (como Reciprocal Rank Fusion o score normalization). Este paradigma ofrece mayor flexibilidad porque permite utilizar el mejor modelo disponible para cada modalidad, pero introduce complejidad en la fusión de resultados y no garantiza que las distancias entre modalidades sean comparables, precisamente debido al modality gap analizado en la sección 4.1.

Paradigma C: Indexación multimodal unificada

El tercer paradigma, adoptado en EMIE, utiliza un único modelo de embedding multimodal capaz de proyectar todas las modalidades a un espacio vectorial compartido. En este esquema, tanto las consultas como los documentos (independientemente de si son texto, imagen, tabla o combinación de ellos) se representan como vectores en el mismo espacio, y la búsqueda se realiza mediante una única operación de similitud vectorial. La principal ventaja es la simplicidad arquitectónica y la posibilidad de realizar recuperación cross-modal directa: una consulta textual puede recuperar una imagen, y viceversa, sin necesidad de pipelines separados ni fusión de rankings.

La viabilidad de este paradigma depende crucialmente de la calidad del alineamiento cross-modal del modelo de embedding. Si el modelo presenta un modality gap significativo, las consultas textuales tenderán a recuperar preferentemente documentos textuales incluso cuando la evidencia visual sea más relevante. Esta es precisamente la razón por la que la evaluación del modality gap constituye una de las preguntas de investigación centrales del proyecto.




Ilustración 40 Comparación entre el pipeline de retrieval documental estándar (múltiples pasos de extracción) y el enfoque visual directo de ColPali. Fuente: Faysse et al. (ICLR 2025).

5.2 Embeddings multimodales unificados: técnicas de alineamiento entre espacios latentes

El funcionamiento interno de los modelos de embedding multimodal se fundamenta en el aprendizaje contrastivo, una familia de técnicas de optimización cuyo objetivo es aprender representaciones en las que los pares semánticamente relacionados (positivos) queden próximos en el espacio latente y los pares no relacionados (negativos) queden distantes. La función de pérdida que ha definido el campo es la **InfoNCE** (*Information Noise-Contrastive Estimation*), propuesta por van den Oord et al. (2018) y adoptada como base por CLIP, SigLIP y la inmensa mayoría de los modelos de embedding multimodal actuales.

Formalmente, dado un batch de N pares (imagen, texto), la pérdida InfoNCE simétrica se define como la media de dos términos cross-entropy: uno que, para cada imagen, maximiza la similitud con su texto correspondiente frente a todos los demás textos del batch, y otro simétrico que opera desde el texto hacia las imágenes. Para un par positivo (i, i) y un parámetro de temperatura τ que controla la nitidez de la distribución de probabilidades:

$$L_{\text{InfoNCE}} = - \left(\frac{1}{N} \right) \sum_i \log \left[\frac{\exp\left(\frac{\text{sim}(v_i, t_i)}{\tau}\right)}{\sum_j \exp\left(\frac{\text{sim}(v_i, t_j)}{\tau}\right)} \right]$$

donde $\text{sim}(v, t)$ es la similitud coseno entre el embedding visual v y el embedding textual t . El denominador suma sobre todos los N textos del batch, tratando los $N-1$ restantes como negativos. La temperatura τ es un hiperparámetro crítico: valores pequeños ($\tau \rightarrow 0$) producen distribuciones más concentradas que penalizan más fuertemente los negativos duros, mientras que valores grandes ($\tau \rightarrow \infty$) suavizan la distribución y reducen la discriminación. Como demostraron Liang et al. (2022), este

CONFIDENCIAL

parámetro de temperatura influye directamente en la distancia del modality gap: temperaturas más bajas tienden a preservar gaps más amplios.




Ilustración 41 Esquema de la pérdida InfoNCE en el contexto de aprendizaje contrastivo multimodal. La matriz de similitud $N \times N$ se construye entre todos los embeddings de imagen y texto del batch. Fuente: Lilian Weng (2021).

Diferencias arquitectónicas entre los modelos evaluados

Los tres modelos de embedding evaluados en EMIE implementan el paradigma contrastivo con diferencias arquitectónicas significativas que afectan directamente a su comportamiento en las tareas de recuperación documental.

Vertex AI multimodalembd@001 opera con encoders separados por modalidad: un encoder visual procesa las imágenes y produce un vector, y un encoder textual procesa el texto y produce otro vector. Ambos vectores se proyectan al mismo espacio de dimensión configurable (1.408, 512, 256 o 128). La separación de encoders implica que el modelo hereda la estructura dual-encoder clásica de CLIP, con su fortaleza (eficiencia de indexación offline, ya que los documentos se codifican una vez y las queries se codifican en tiempo de consulta) y su debilidad principal (el modality gap inherente a la inicialización y entrenamiento de dos encoders independientes). La restricción de 1.024 caracteres para el input textual sugiere que el encoder de texto está optimizado para consultas cortas o frases descriptivas, no para párrafos extensos, lo cual es coherente con un diseño orientado a retrieval donde las queries son típicamente breves.

Voyage AI voyage-multimodal-3 introduce una innovación arquitectónica relevante: la capacidad de procesar **inputs intercalados de texto e imagen** en una única llamada de embedding, produciendo un vector único de dimensión 1.024 que codifica conjuntamente ambas modalidades. Esta capacidad sugiere una arquitectura interna más sofisticada que el dual-encoder puro: en lugar de procesar texto e imagen por separado y combinar al final, el modelo parece integrar la información multimodal en etapas más tempranas del procesamiento, lo que potencialmente mejora la captura de relaciones cross-modales dentro del documento.

Además, voyage-multimodal-3 implementa un mecanismo de **instruction-tuned embeddings** mediante prefijos automáticos. Cuando se especifica `input_type="query"`, el modelo antepone internamente el texto *"Represent the query for retrieving supporting documents: "*, y cuando se especifica

input_type="document", antepone *"Represent the document for retrieval: "*. Esta técnica, derivada de la literatura sobre text embeddings instruccionales (como E5-Instruct y GTE-Qwen), crea una asimetría controlada en el espacio de embedding que refleja la diferencia funcional entre una consulta (corta, interrogativa, con intención de búsqueda) y un documento (largo, declarativo, con contenido informativo). En la práctica, esta asimetría mejora la calidad del retrieval porque el modelo no trata de forma idéntica a queries y documentos, sino que optimiza la representación de cada uno para su rol funcional.

Gemini Embedding 2 gemini-embedding-2-preview representa la evolución de Google hacia una arquitectura de embedding de "frontera", diseñada para maximizar la eficiencia operativa sin sacrificar la precisión semántica. A diferencia de los modelos anteriores, Gemini introduce dos innovaciones clave que transforman la gestión de grandes volúmenes de datos: el aprendizaje de representaciones **Matryoshka (MRL)** y un sistema avanzado de **instrucciones por tipo de tarea**.

La implementación de **Matryoshka Representation Learning** es, quizás, su avance arquitectónico más disruptivo. Esta técnica permite que el modelo codifique la información de manera jerárquica dentro del vector de **3072 dimensiones**. En la práctica, esto significa que las dimensiones iniciales del vector contienen la información semántica más crítica, permitiendo "truncar" el embedding a dimensiones menores (como 1536 o 768) manteniendo una alta fidelidad en la recuperación. Esta flexibilidad estructural ofrece una solución elegante al compromiso entre costo de almacenamiento y rendimiento, permitiendo estrategias de búsqueda *coarse-to-fine* (búsqueda gruesa inicial con vectores pequeños y re-ranking posterior con el vector completo).

Siguiendo la tendencia de los modelos de última generación vistos en Voyage AI, Gemini Embedding 2 profundiza en el paradigma de **embeddings instruccionales**. El modelo no genera una representación estática, sino que adapta su espacio vectorial según el parámetro *task_type*. Al especificar tareas como RETRIEVAL_QUERY, RETRIEVAL_DOCUMENT, CLASSIFICATION o CLUSTERING, el modelo ajusta dinámicamente el peso de las características extraídas. Mientras que en la consulta (query) el modelo prioriza la intención y la brevedad, en el documento (document) optimiza la codificación del contenido informativo denso.

Además, su optimización para **más de 100 idiomas** y su entrenamiento específico en tareas de razonamiento complejo le permiten superar el rendimiento de modelos previos en el benchmark MTEB, consolidándose como una arquitectura versátil que no solo entiende el contenido, sino el propósito funcional de la información dentro de un ecosistema de búsqueda a gran escala.






Ilustración 42 Esquema del preentrenamiento contrastivo para retrieval cross-modal: los encoders de imagen y texto se entrenan para maximizar la similitud de pares positivos. Fuente: Jack Morris

Tokenización de imágenes y su impacto en la resolución

Un aspecto técnico frecuentemente subestimado pero de gran impacto práctico es cómo cada modelo tokeniza las imágenes de entrada antes de codificarlas. Vertex AI multimodalembd@001 redimensiona internamente todas las imágenes a **512 × 512 píxeles**, independientemente de su resolución original. Esto tiene implicaciones directas para la estrategia de página-como-imagen: si una página PDF se renderiza a alta resolución (por ejemplo, 1.700 × 2.200 píxeles con DPI=144), el modelo la comprimirá a 512 × 512 antes de codificarla, lo que puede degradar la legibilidad de texto pequeño, números en tablas o detalles finos en diagramas técnicos.

Voyage AI utiliza un esquema de tokenización diferente basado en **píxeles**: cada 560 píxeles de la imagen se cuentan como un token, y cada input no puede superar 32.000 tokens en total (sumando texto e imagen). Esto permite preservar mayor resolución para imágenes grandes, pero introduce una relación directa entre resolución y coste: una imagen de 2.000 × 2.000 píxeles (~4 millones de píxeles) consume aproximadamente 7.143 tokens, lo que deja margen para texto adicional dentro del mismo input. Las imágenes con menos de 50.000 píxeles se escalan hacia arriba, y las que superan 2 millones de píxeles se reducen, con un coste que varía entre \$0.00003 y \$0.0012 por imagen.

5.3 El problema del modality gap: análisis teórico y estrategias de mitigación

El modality gap constituye posiblemente el problema técnico más relevante para la calidad de un sistema de RAG multimodal basado en embeddings unificados. Este fenómeno, identificado y formalizado por Liang et al. en el trabajo "Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning"

(NeurIPS 2022), describe una propiedad geométrica sorprendente de los espacios de representación multimodal: los embeddings de diferentes modalidades ocupan regiones separadas del espacio latente, formando clusters disjuntos incluso cuando corresponden a pares semánticamente alineados. La importancia de este fenómeno para EMIE radica en que, si los vectores de imagen y texto viven en regiones separadas del espacio, una búsqueda por vecinos cercanos tenderá a favorecer documentos de la misma modalidad que la query, degradando la recuperación cross-modal que es precisamente el valor diferencial del RAG multimodal.

El cone effect y la geometría de las redes profundas

La explicación teórica del modality gap comienza con el denominado **cone effect** (efecto cono). Liang et al. demostraron, tanto empíricamente como teóricamente, que las representaciones producidas por redes neuronales profundas con activaciones no lineales tienden a concentrarse en un cono estrecho del espacio de alta dimensión, en lugar de distribuirse uniformemente. Formalmente, si $h_{\theta}(U)$ es la salida de una capa intermedia con input U y pesos aleatorios θ , la similitud coseno promedio entre pares de embeddings es sustancialmente mayor que cero, indicando que los vectores apuntan en direcciones mutuamente próximas en lugar de estar dispersos.

El **Teorema 1** del paper formaliza esta observación: bajo supuestos moderados sobre las distribuciones de los pesos, cada capa de red neuronal **reduce el ángulo** entre cualquier par de vectores de embedding con alta probabilidad, lo que produce conos progresivamente más estrechos en arquitecturas más profundas. Las activaciones no lineales (ReLU, GELU, etc.) son el ingrediente crítico: como muestran los experimentos del paper, un MLP sin activaciones no lineales no exhibe el cone effect, pero con activaciones, la similitud coseno promedio crece rápidamente con la profundidad.




Ilustración 43 El cone effect en redes neuronales profundas. (a) Histogramas de similitud coseno entre embeddings, mostrando conos estrechos. (b) Efecto de la profundidad y las activaciones no lineales. Fuente: Liang et al. (NeurIPS 2022).

El **Teorema 2** completa la explicación demostrando que diferentes inicializaciones aleatorias de los pesos producen conos en direcciones diferentes del espacio. En un modelo multimodal con dos encoders (imagen y texto), cada encoder se inicializa con pesos aleatorios independientes, produciendo dos conos distintos desde el

inicio del entrenamiento. Esto explica por qué el modality gap existe **incluso antes del entrenamiento**: la separación entre modalidades es una consecuencia de la geometría de las redes profundas, no del proceso de aprendizaje contrastivo. Los experimentos del paper confirman esto visualizando con UMAP los embeddings de 25 modelos inicializados aleatoriamente (sin ningún entrenamiento), observando que cada inicialización produce un cono orientado en una dirección diferente.



Ilustración 44 Cada inicialización aleatoria de una red neuronal profunda produce un cono de embeddings orientado en una dirección diferente del espacio. Fuente: Liang et al. (NeurIPS 2022).

Preservación del gap por el entrenamiento contrastivo

Una pregunta natural es si el entrenamiento contrastivo, al optimizar la similitud entre pares positivos, debería cerrar progresivamente el gap entre modalidades. El resultado sorprendente de Liang et al. es que **no**: el mínimo de la función de pérdida InfoNCE no coincide con el punto de alineamiento perfecto ($\text{gap} = 0$), sino que se encuentra a una distancia no nula que depende del parámetro de temperatura τ . Los autores demostraron esto mediante un experimento elegante de *embedding shift*: desplazaron manualmente los embeddings de imagen hacia los de texto (reduciendo artificialmente el gap) y calcularon la pérdida contrastiva para cada posición. El resultado muestra que la pérdida tiene su mínimo a una distancia positiva del centro de los embeddings textuales, no en el centro mismo. Además, la distancia óptima varía con la temperatura: temperaturas más bajas producen mínimos más alejados, es decir, preservan gaps más amplios.

Este resultado tiene una implicación práctica directa para EMIE: dado que los modelos de embedding utilizados han sido entrenados con objetivos contrastivos, exhibirán necesariamente un cierto grado de modality gap. La cuestión práctica no es si existe el gap (existe), sino cuán grande es y cómo afecta a la tarea específica de retrieval sobre documentación técnica.

Estrategias de mitigación recientes

La literatura posterior ha propuesto diversas estrategias para reducir el modality gap sin degradar el rendimiento en tareas downstream. La propuesta más relevante para el contexto de EMIE es **AlignCLIP** (ICLR 2025), que introduce dos mecanismos complementarios. El primero es **SharedCLIP**: compartir parámetros aprendibles entre los encoders de imagen y texto, de modo que ambos operen parcialmente en el mismo subespacio paramétrico. El segundo es **IMSep** (*Intra-Modality Separation*): añadir un objetivo de separación regularizada dentro de cada modalidad, de modo que los embeddings de imágenes diferentes y los embeddings de textos diferentes se alejen entre sí de forma semánticamente coherente. La combinación de ambos mecanismos redujo el ángulo medio entre pares imagen-

texto de ~70° a ~47°, una mejora sustancial que se tradujo en ganancias consistentes en tareas de zero-shot classification y fine-tuning.

MODEL	CC3M	MSCOCO	IMAGENET-1K	CIFAR-100	CIFAR-10
CLIP	0.42	0.47	0.41	0.38	0.40
SHAREDCLIP	0.59	0.62	0.57	0.54	0.54
IMSEP	0.61	0.64	0.59	0.58	0.6
ALIGNCLIP	0.64	0.67	0.63	0.62	0.64

Ilustración 45 Comparación de alignment scores entre CLIP original y variantes con mecanismos de mitigación del modality gap. AlignCLIP reduce el ángulo medio entre pares imagen-texto de ~70° a ~47°. Fuente: AlignCLIP (ICLR 2025).

Otra línea de mitigación es la técnica **C³** (*Connect, Collapse, Corrupt*), que propone un método post-hoc en tres pasos para cerrar el gap sin reentrenar el modelo: (1) conectar los centros de las distribuciones de cada modalidad, (2) colapsar las representaciones al centro común, y (3) añadir ruido controlado para preservar la diversidad representacional. Aunque prometedora, esta técnica requiere acceso a las distribuciones completas de embeddings, lo que la hace más aplicable a escenarios offline de reindexación que a pipelines de retrieval en tiempo real.




Ilustración 46 El modality gap es un fenómeno ubicuo en modelos multimodales contrastivos: la separación entre embeddings de imagen (azul) y texto (rojo) persiste incluso en modelos con pesos aleatorios. Fuente: Liang et al., repositorio GitHub

5.4 Estrategias de indexación de documentos visualmente ricos

La indexación de documentos visualmente ricos para RAG multimodal es un problema de ingeniería que conecta directamente la calidad del modelo de embedding con la utilidad del sistema completo. La decisión de cómo representar cada documento en el índice vectorial determina qué información es recuperable y qué información se pierde irreversiblemente. El paper de ColPali (Faysse et al., ICLR 2025) realizó una contribución decisiva al campo al demostrar empíricamente que **el cuello de botella principal del retrieval documental no es el modelo de embedding en sí, sino el pipeline de ingestión previo**. En sus experimentos, las diferencias entre modelos de embedding textual (BM25, BGE-M3) fueron mucho menores que las diferencias entre pipelines de preprocessing (solo texto, texto + OCR, texto + captioning, visual directo).



El enfoque ColPali: retrieval en el espacio visual

ColPali propone una ruptura radical con el paradigma de textualización: en lugar de extraer texto de los documentos y luego embeddear ese texto, ColPali **embeddea directamente la imagen de la página** utilizando un Vision Language Model (PaliGemma-3B) y produce representaciones multi-vector al estilo ColBERT. Cada parche de la imagen genera un vector, y la similitud documento-query se calcula mediante el operador MaxSim de *late interaction*: para cada token de la query, se busca el parche del documento con mayor similitud, y se suman las similitudes máximas.

Los resultados en el benchmark ViDoRe fueron contundentes: ColPali superó ampliamente a todos los sistemas basados en parsing textual, incluyendo los que incorporaban OCR y captioning, mientras que simultáneamente ofrecía latencias de indexación mucho menores (al eliminar todos los pasos de preprocessing). La ventaja fue especialmente pronunciada en documentos con contenido visual complejo: infografías, tablas, figuras y gráficos.




Ilustración 47 Latencias de indexación offline comparando pipelines tradicionales (Unstructured, OCR, captioning) con ColPali. El enfoque visual directo es significativamente más rápido. Fuente: Faysse et al. (ICLR 2025)

	ArxivQ	DocQ	InfoQ	TabF	TATQ	Shift	AI	Energy	Gov.	Health.	Avg.
Unstructured text-only											
- BM25	-	34.1	-	-	44.0	59.6	90.4	78.3	78.8	82.6	-
- BGE-M3	-	28.4 _{↓5.7}	-	-	36.1 _{↓7.9}	68.5 _{↑8.9}	88.4 _{↓2.0}	76.8 _{↓1.5}	77.7 _{↓1.1}	84.6 _{↑2.0}	-
Unstructured + OCR											
- BM25	31.6	36.8	62.9	46.5	62.7	64.3	92.8	85.9	83.9	87.2	65.5
- BGE-M3	31.4 _{↓0.2}	25.7 _{↓11.1}	60.1 _{↓2.8}	70.8 _{↑24.3}	50.5 _{↓12.2}	73.2 _{↑8.9}	90.2 _{↓2.6}	83.6 _{↓2.3}	84.9 _{↑1.0}	91.1 _{↑3.9}	66.1 _{↑0.6}
Unstructured + Captioning											
- BM25	40.1	38.4	70.0	35.4	61.5	60.9	88.0	84.7	82.7	89.2	65.1
- BGE-M3	35.7 _{↓4.4}	32.9 _{↓5.4}	71.9 _{↑1.9}	69.1 _{↑33.7}	43.8 _{↓17.7}	73.1 _{↑12.2}	88.8 _{↑0.8}	83.3 _{↓1.4}	80.4 _{↓2.3}	91.3 _{↑2.1}	67.0 _{↑1.9}
Contrastive VLMs											
Jina-CLIP	25.4	11.9	35.5	20.2	3.3	3.8	15.2	19.7	21.4	20.8	17.7
Nomic-vision	17.1	10.7	30.1	16.3	2.7	1.1	12.9	10.9	11.4	15.7	12.9
SigLIP (Vanilla)	43.2	30.3	64.1	58.1	26.2	18.7	62.5	65.7	66.1	79.1	51.4
Ours											
SigLIP (Vanilla)	43.2	30.3	64.1	58.1	26.2	18.7	62.5	65.7	66.1	79.1	51.4
BiSigLIP (+fine-tuning)	58.5 _{↑15.3}	32.9 _{↑2.6}	70.5 _{↑6.4}	62.7 _{↑4.6}	30.5 _{↑4.3}	26.5 _{↑7.8}	74.3 _{↑11.8}	73.7 _{↑8.0}	74.2 _{↑8.1}	82.3 _{↑3.2}	58.6 _{↑7.2}
BiPali (+LLM)	56.5 _{↓2.0}	30.0 _{↓2.9}	67.4 _{↓3.1}	76.9 _{↑14.2}	33.4 _{↑2.9}	43.7 _{↑17.2}	71.2 _{↓3.1}	61.9 _{↓11.7}	73.8 _{↓0.4}	73.6 _{↓8.8}	58.8 _{↑0.2}
ColPali (+Late Inter.)	79.1 _{↑22.6}	54.4 _{↑24.5}	81.8 _{↑14.4}	83.9 _{↑7.0}	65.8 _{↑32.4}	73.2 _{↑29.5}	96.2 _{↑25.0}	91.0 _{↑29.1}	92.7 _{↑18.9}	94.4 _{↑20.8}	81.3 _{↑22.5}

Ilustración 48 Resultados de retrieval en el benchmark ViDoRe. ColPali supera a todos los sistemas basados en parsing textual. Fuente: Faysse et al. (ICLR 2025).

Posicionamiento de la estrategia EMIE

La estrategia adoptada en EMIE comparte la filosofía fundamental de ColPali – tratar la página como imagen – pero difiere en un aspecto importante: mientras

CONFIDENCIAL

ColPali utiliza representaciones multi-vector (un vector por parche) con late interaction, EMIE utiliza **representaciones single-vector** (un vector por página) con búsqueda directa por distancia en FAISS. Esta simplificación reduce la complejidad de indexación y búsqueda, pero sacrifica la capacidad de late interaction para hacer matching fino entre tokens de query y parches del documento. La justificación de esta elección es triple: (a) FAISS con single-vector es la infraestructura de búsqueda vectorial más madura y ampliamente soportada, (b) la búsqueda single-vector es significativamente más rápida y escalable que late interaction para corpus grandes, y (c) el objetivo de esta fase del proyecto es validar la viabilidad del concepto, no optimizar el rendimiento hasta el límite.

El framework M3DocRAG (Cho et al., 2024) representa una arquitectura completa que combina lo mejor de ambos mundos: utiliza ColPali como retriever multimodal para la fase de recuperación de páginas, y Qwen2-VL como modelo de lenguaje multimodal para la fase de question answering sobre las páginas recuperadas. Los resultados de M3DocRAG en tres benchmarks (M3DocVQA, MMLongBench-Doc, MP-DocVQA) demuestran que la combinación de retrieval visual con generación multimodal constituye el estado del arte en comprensión documental multi-página. Esta arquitectura valida indirectamente la aproximación de EMIE, ya que comparte la misma intuición fundamental: recuperar páginas como imágenes y razonar sobre ellas con un modelo multimodal.




Ilustración 49 Comparación visual entre el pipeline de retrieval estándar (múltiples pasos de extracción) y el enfoque ColPali (screenshot directo). Fuente: Blog de Zilliz

5.5 Fusión de evidencias multimodales para generación aumentada

Una vez que el pipeline de retrieval ha localizado las páginas relevantes, el siguiente desafío técnico consiste en proporcionar esa evidencia al modelo generador de forma que maximice la calidad de la respuesta. Este paso, denominado **augmented generation** o **context injection**, es menos trivial de lo que parece, especialmente

CONFIDENCIAL

cuando las evidencias recuperadas son multimodales (páginas-imagen que contienen texto, tablas y figuras).

Estrategias de inyección de contexto

En los experimentos de EMIE se han explorado dos estrategias de inyección de contexto al modelo generador Gemini:

Estrategia directa de imágenes: las páginas recuperadas se proporcionan como imágenes directamente en el contexto del modelo. Gemini, al ser nativamente multimodal, puede procesar estas imágenes y razonar sobre su contenido visual y textual de forma integrada. Esta estrategia es la más directa y preserva toda la información visual de la página, incluyendo layout, formato, colores y elementos gráficos. Sin embargo, cada imagen consume tokens de contexto visual, lo que limita el número de páginas que pueden proporcionarse simultáneamente.

Estrategia de PDF nativo: los documentos PDF completos se proporcionan al modelo junto con indicaciones textuales sobre qué páginas o secciones consultar. Gemini soporta la ingestión de PDFs como input nativo, lo que permite proporcionar documentos de cientos de páginas aprovechando su ventana de contexto extendida (hasta 1 millón de tokens). Esta estrategia es más escalable pero delega al modelo la tarea de navegar y localizar la información relevante dentro del documento extenso.

El problema del cross-modal misalignment en generación aumentada

Un fenómeno técnicamente relevante y bien documentado en la literatura reciente es el **cross-modal misalignment** entre el contexto recuperado y el input del usuario durante la fase de generación. El paper MMed-RAG (ICLR 2025) demostró empíricamente este problema en el dominio médico: cuando se proporcionaba contexto RAG basado en una imagen médica, pero se sustituía la imagen del usuario por una imagen ruidosa con un ground truth diferente, el 55.08% de las respuestas incorrectas se corregían gracias al RAG. Sin embargo, el resultado más alarmante fue el inverso: el 43.31% de las preguntas que el modelo respondía correctamente **sin RAG** pasaban a responderse incorrectamente **con RAG**, indicando que el contexto recuperado podía interferir destructivamente con el razonamiento del modelo.

Este hallazgo tiene implicaciones directas para el diseño del pipeline de EMIE: la incorporación de RAG multimodal no es una mejora monotónica de la calidad; puede introducir interferencias cuando el contexto recuperado no está bien alineado con la consulta o cuando el modelo generador no sabe ponderar adecuadamente la evidencia recuperada frente a su propio conocimiento paramétrico. La evaluación experimental del proyecto (sección 6) aborda específicamente este riesgo comparando respuestas bajo tres condiciones (sin RAG, RAG erróneo, RAG exitoso) para cuantificar tanto el beneficio como el riesgo potencial del augmentation.






Ilustración 50 Comparación de pipelines de comprensión documental: (a) single-page, (b) text-RAG, (c) M3DocRAG multimodal con retrieval visual y generación con VLM. Fuente: Cho et al. (2024).

5.6 Técnicas de combinación de embeddings cross-modal

Una de las técnicas exploradas en los experimentos de EMIE es la **fusión de vectores de embedding** de diferentes modalidades como mecanismo para construir consultas multimodales combinadas. La idea es conceptualmente simple: dado un embedding textual v_t y un embedding visual v_i del mismo concepto (o de conceptos complementarios), construir un vector fusionado v_f que capture la semántica conjunta de ambas modalidades.

Media aritmética como operador de fusión

La estrategia más directa, y la explorada en los experimentos de EMIE, es la **media aritmética dimensión a dimensión**: $v_f = (v_t + v_i) / 2$. En un espacio de embedding normalizado (donde todos los vectores yacen sobre la hiperesfera unitaria), la media de dos vectores produce un vector que apunta en una dirección intermedia entre ambos, con una norma que depende del ángulo entre ellos. Si los vectores están perfectamente alineados (ángulo 0°), la media coincide con ambos y tiene norma 1. Si son ortogonales (ángulo 90°), la media tiene norma $\sqrt{2}/2 \approx 0.707$. Si son opuestos (ángulo 180°), la media es el vector nulo.

Para que la media aritmética funcione como operador de fusión en retrieval, es necesario que el espacio de embedding tenga la propiedad de **composicionalidad lineal**: que la dirección intermedia entre dos conceptos sea semánticamente coherente con la combinación de ambos. Esta propiedad no está garantizada en espacios de embedding contrastivos, pero se ha observado empíricamente en modelos tipo CLIP que la aritmética vectorial produce resultados semánticamente interpretables (de forma análoga a la famosa analogía 'king - man + woman = queen' de Word2Vec, pero extendida al dominio multimodal).

En los experimentos de EMIE con Voyage AI, se observó que la combinación de un input de texto y un input de imagen (usando la media de ambos vectores) producía

resultados de retrieval cualitativamente diferentes a los de cada modalidad por separado. Este comportamiento es consistente con la teoría: el vector fusionado busca documentos que sean relevantes para ambas modalidades simultáneamente, lo que puede mejorar la precisión cuando query y contexto visual son complementarios, pero también puede degradar los resultados cuando las modalidades apuntan en direcciones semánticas divergentes.



Ilustración 51 Visualización del espacio de embeddings bajo pérdida contrastiva, mostrando la distribución de pares positivos (ceranos) y negativos (distantes). Fuente: Abhik Sarkar.




Ilustración 52 Paisaje de la pérdida InfoNCE mostrando la superficie de optimización en función de la posición relativa de muestras positivas y negativas. Fuente: Repositorio info-nce-pytorch.

5.7 Hacia la multimodalidad operativa: voz, vídeo y tiempo real

Las técnicas exploradas en las secciones anteriores se centran en las modalidades de texto e imagen, que son las más directamente relevantes para los casos de uso actuales de EMIE (RAG documental y asistencia al mantenimiento basada en manuales). Sin embargo, la hoja de ruta del proyecto, definida en la sección 3.7, contempla una evolución progresiva hacia interacción vocal (fase 2), asistencia en campo con GMAO (fase 3) y realidad aumentada (fase 4). Esta evolución requiere incorporar modalidades adicionales – fundamentalmente **voz y vídeo** – al pipeline multimodal. La presente sección analiza las técnicas más relevantes para esta extensión y las sitúa en el contexto del estado del arte.

Incorporación de audio y voz

La incorporación de voz al pipeline MRAG puede abordarse desde dos paradigmas técnicos fundamentalmente diferentes. El primero, que podríamos denominar **speech-to-text-to-embedding**, consiste en transcribir la voz a texto mediante un sistema ASR (como Whisper) y luego procesar el texto resultante con el pipeline textual estándar. Este enfoque es pragmático y se beneficia de la madurez de los sistemas ASR actuales, pero introduce una pérdida irreversible: toda la información



prosódica, acústica y paralingüística del audio se descarta en el paso de transcripción.

El segundo paradigma, denominado **audio-native embedding**, codifica la señal de audio directamente en el espacio de embedding multimodal, sin pasar por texto intermedio. El modelo de referencia en esta línea es **CLAP** (*Contrastive Language-Audio Pretraining*, Elizalde et al., 2023), que aplica la misma lógica contrastiva de CLIP pero entre audio y texto: un encoder de audio y un encoder de texto se entrenan conjuntamente para producir representaciones alineadas. CLAP permite búsqueda semántica bidireccional entre audio y texto, clasificación zero-shot de eventos sonoros, y conditioning de modelos generativos de audio.




Ilustración 53 Arquitectura de CLAP (Contrastive Language-Audio Pretraining): encoders de audio y texto entrenados contrastivamente para producir un espacio compartido. Fuente: Elizalde et al. (2023).

Para el caso de uso de mantenimiento de EMIE, la elección entre ambos paradigmas depende del tipo de información que la voz aporta. Si la voz se utiliza únicamente como canal de entrada para formular consultas textuales ("¿cómo cambio el aceite de esta moto?"), el paradigma speech-to-text es suficiente y más simple. Si la voz aporta información acústica relevante por sí misma (por ejemplo, el sonido de una máquina para diagnóstico de averías), se necesitaría un embedding audio-nativo. En la fase actual del proyecto, la evolución natural apunta al primer paradigma, reservando el segundo para fases más avanzadas.

Modelos omni como horizonte de convergencia

La tendencia más reciente del estado del arte apunta hacia **modelos omni** capaces de recibir y generar en múltiples modalidades dentro de una única arquitectura. Qwen2.5-Omni, presentado en 2025, propone una arquitectura *Thinker-Talker* que acepta texto, imagen, audio y vídeo como inputs, y puede responder tanto en texto como en voz de forma streaming. El componente Thinker procesa todas las modalidades de entrada y genera una representación interna del razonamiento, mientras que el componente Talker convierte esa representación en habla natural con baja latencia de primera respuesta.




Ilustración 54 Arquitectura Thinker-Talker de Qwen2.5-Omni: un mismo modelo procesa texto, imagen, audio y vídeo, y responde en texto o voz streaming. Fuente: Xu et al. (2025).

Para EMIE, estos modelos omni representan el horizonte tecnológico hacia el que evoluciona el proyecto. La arquitectura modular adoptada (sección 4.3) facilita la transición futura: si un modelo omni como Qwen2.5-Omni o sus sucesores alcanza la madurez necesaria para producción, podría sustituir simultáneamente al modelo de embedding, al ASR/TTS y al modelo generador, simplificando drásticamente la arquitectura del sistema. Sin embargo, en el estado actual de la tecnología, estos modelos omni aún presentan limitaciones en precisión, latencia y disponibilidad que hacen que la arquitectura modular con componentes especializados siga siendo la opción más robusta para despliegues industriales.

Vídeo: segmentación temporal y embeddings

El vídeo introduce complejidades adicionales respecto a la imagen estática: temporalidad, redundancia entre frames, sincronización con audio, y volumen masivo de datos. Vertex AI multimodalembd@001 soporta vídeo mediante un esquema de segmentación temporal configurable con tres modos (Essential, Standard, Plus) que difieren en la densidad de embeddings generados por minuto. Sin embargo, los experimentos de EMIE con Gemini 2.0 Flash sobre vídeo revelaron limitaciones significativas en la comprensión de datos tabulares presentados en formato de vídeo: el modelo era incapaz de extraer cifras numéricas precisas de tablas que aparecían en los frames, inventando valores a pesar de indicarle la sección exacta del vídeo donde buscar. Esta observación es coherente con las limitaciones conocidas de los MLLMs en comprensión visual de datos numéricos densos, documentadas en benchmarks como Chart-MRAG Bench.




Ilustración 55 Estrategias de indexación multimodal para sistemas MRAG productivos: esquema híbrido con indexación de texto, vectores y tensores. Fuente: RAGFlow (2025).



6. Implementación y Evaluación Experimental

Introducción

En primer lugar, se tienen que diferenciar dos fases de estudio que necesitan de diferentes tipos de modelos para su implementación:

- a) Los modelos de **embedding** multimodal, que nos permiten realizar un RAG a partir de una consulta multimodal (por ejemplo, preguntar en texto sobre una imagen que se le proporciona “¿Cómo cambio el aceite de mi moto? -> Imagen de la moto). Estos modelos tienen como output un vector, que se comparará con el resto de documentos vectorizados mediante algoritmos de similarity search, recuperando los documentos más parecidos a dicha consulta y finalizando así la fase de recuperación de la información.
- b) Los modelos de **generación** multimodales, que nos permiten a partir de un input multimodal dar una salida, potencialmente multimodal. A este modelo, tendrá como inputs los mismos que los modelos de embedding + los documentos recuperados en el RAG.

Dado que los **modelos generadores dependen de los resultados de los modelos de embedding** (para evitar las conocidas alucinaciones de los LLMs o añadir conocimiento con el que el modelo no ha sido entrenado), la primera fase **se centra** en obtener **modelos de embedding multimodal** que permitan realizar la fase de RAG previa. Los modelos empleados para dicha tarea han sido:

- *multimodalembdding@001* de VertexAI (Google)
- *voyage-multimodal-3* de Voyage AI

en un primer momento. Más adelante también se estudian, sin obtener unos resultados sólidos:

- *amazon-nova-multimodal-embeddings* de Amazon
- *voyage-multimodal-3.5* de Voyage AI
- *qwen-3-vl-embedding* de Alibaba
- *gemini-embedding-2* de Google

Paralelamente, se han realizado las primeras pruebas de los modelos generadores, en este caso se han usado varios modelos de Gemini que se han ido actualizando con el paso del tiempo, como son *gemini-2.0-flash-exp* y *gemini-2.5-flash-preview-04-17*; aunque no se ha profundizado en estos modelos debido a lo comentado anteriormente.

Modelos de embedding

1. VertexAI- multimodalembdding@001

El primer modelo a estudiar es el de Vertex AI, concretamente *multimodalembdding@001* (*Obtén Incorporaciones Multimodales | Generative AI on Vertex AI | Google Cloud*, n.d.)

En este caso, dicho modelo tiene como características:



- Como inputs permitidos: **texto, imagen y vídeo sin audio**. Tiene como **limitación el número de tokens de entrada** para el input de texto, limitado a **1024 caracteres**, aproximadamente **32 tokens** o palabras.

400 Multimodal embedding failed with the following error: Text field must be smaller than 1024 characters.

Límites de API

Se aplican los siguientes límites cuando usas el modelo `multimodalembdding` para las incorporaciones de imagen y texto:

Límite	Valor y descripción
Datos de imágenes y texto	
Cantidad máxima de solicitudes a la API por minuto y por proyecto	120
Longitud máxima de texto	32 tokens (~32 palabras) La longitud máxima de texto es de 32 tokens (aproximadamente 32 palabras). Si la entrada supera los 32 tokens, el modelo acorta de forma interna la entrada a esta longitud.
Idioma	Inglés
Formatos de imagen	BMP, GIF, JPG y PNG
Tamaño de la imagen	Imágenes codificadas en base64: 20 MB (cuando se transcodifica a PNG) Imágenes de Cloud Storage: 20 MB (formato de archivo original) El tamaño máximo de imagen aceptado es de 20 MB. Para evitar una mayor latencia de red, usa imágenes más pequeñas. Además, el modelo cambia el tamaño de las imágenes a una resolución de 512 x 512 píxeles. Por lo tanto, no necesitas proporcionar imágenes de mayor resolución.
Datos de vídeo	
Audio compatible	N/A: El modelo no tiene en cuenta el contenido de audio cuando genera incorporaciones de vídeo
Formatos de vídeo	AVI, FLV, MKV, MOV, MP4, MPEG, MPG, WEBM y WMV
Duración máxima del vídeo (Cloud Storage)	Sin límites. Sin embargo, solo se pueden analizar dos minutos de contenido a la vez.

- Las **dimensiones de los vectores** aceptan valores de **1.408, 512, 256 o 128**.
- En el vídeo, tiene particularidades como que fragmenta los vídeos completos en clips más cortos dependiendo del modo usado



Modos de incorporaciones de video ⇄

Existen tres modos que puedes usar con incorporaciones de video: Essential, Standard o Plus. El modo corresponde a la densidad de las incorporaciones generadas, que se puede especificar con la configuración `interval_sec` en la solicitud. Para cada intervalo de video con duración `interval_sec`, se genera una incorporación. La duración mínima del intervalo de video es de 4 segundos. Los intervalos superiores a 120 segundos pueden afectar de forma negativa la calidad de las incorporaciones generadas.

Los precios de las incorporaciones de videos dependen del modo que uses. Para obtener más información, consulta [Precios](#).

En la siguiente tabla, se resumen los tres modos que puedes usar para las incorporaciones de video:

Modo	Cantidad máxima de incorporaciones por minuto	Intervalo de incorporación de video (valor mínimo)
Esencial	4	15 Esto corresponde a: <code>intervalSec >= 15</code>
Estándar	8	8 Esto corresponde a: <code>8 <= intervalSec < 15</code>
Plus	15	4 Esto corresponde a: <code>4 <= intervalSec < 8</code>

Para evaluar el comportamiento de este modelo, se realizan una serie de experimentos de complejidad creciente:

- a. **Experimento 1:** para verificar si el modelo, al realizar el embedding de una imagen, y ver si es capaz de **reconocer texto dentro de imágenes**. Para este caso, se usan fotos de perros (16 imágenes) que tenga su nombre escrito en un collar de manera visible. Un ejemplo sería el siguiente:




Ilustración 56 Ejemplo de imágenes usadas que incorporan texto



```
import os
import numpy as np
import faiss
import json

import PIL
import io
import fitz # PyMuPDF
import pickle
import base64
import pathlib

from typing import List, Dict, Tuple, Optional, Any, Union
import vertexai
from vertexai.vision_models import MultiModalEmbeddingModel, Image as VertexImage

from google.genai import Client, types

class EmbeddingMultimodal:
    """
    Clase para manejar embeddings multimodales y búsquedas con FAISS.

    Esta clase implementa funcionalidades para:
    - Crear embeddings de imágenes y texto
    - Gestionar índices FAISS
    - Realizar búsquedas por similitud
    - Gestionar metadatos asociados
    """

    def __init__(self,
                 vector_dim: int = 1408,
                 index_path: str = "faiss_index.bin",
                 metadata_path: str = "metadata.json",
                 project_id: str = "hazitek-emie",):
        """
        Inicializa el gestor de embeddings multimodales.

        Args:
            vector_dim: Dimensión de los vectores de embedding
            index_path: Ruta al archivo del índice FAISS
            metadata_path: Ruta al archivo de metadatos
            project_id: ID del proyecto de Google Cloud
        """
        self.vector_dim = vector_dim
        self.index_path = index_path
        self.metadata_path = metadata_path

        PROJECT_ID = project_id
        REGION = "us-central1" # <--- Es la región recomendada
        vertexai.init(project=PROJECT_ID, location=REGION)
        GEMINI_API_KEY = os.getenv("GEMINI_API_KEY")

        self.model = MultiModalEmbeddingModel.from_pretrained("multimodalembd@001")
        self.index, self.num_vectors = self._load_index()
        self.metadata = self._load_metadata()
        self.client = Client(api_key=GEMINI_API_KEY)
        self.model_id = "gemini-2.5-flash-preview-04-17"
```



```
def get_text_embedding(self, text: str) -> np.ndarray:
    """
    Genera el embedding de un texto.

    Args:
        text: Texto para generar el embedding

    Returns:
        Numpy array con el embedding del texto
    """
    try:
        embedding = self.model.get_embeddings(contextual_text=text, dimension=self.vector_dim)
        return np.array(embedding.text_embedding, dtype='float32').reshape(1, -1)
    except Exception as e:
        raise ValueError(f"Error al generar embedding para el texto: {e}")

def get_image_embedding(self, image_path: str) -> np.ndarray:
    """
    Genera el embedding de una imagen.

    Args:
        image_path: Ruta completa a la imagen

    Returns:
        Numpy array con el embedding de la imagen
    """
    try:
        image = VertexImage.load_from_file(image_path)
        embedding = self.model.get_embeddings(image=image, dimension=self.vector_dim)
        return np.array(embedding.image_embedding, dtype='float32')
    except Exception as e:
        raise ValueError(f"Error al generar embedding para {image_path}: {e}")

def _save_metadata(self) -> None:
    """Guarda los metadatos en el archivo JSON."""
    metadata_dir = os.path.dirname(self.metadata_path)
    if metadata_dir and not os.path.exists(metadata_dir):
        os.makedirs(metadata_dir, exist_ok=True)

    with open(self.metadata_path, "w") as f:
        json.dump(self.metadata, f, indent=4)

def _save_index(self) -> None:
    """Guarda el índice FAISS en el archivo binario."""
    index_dir = os.path.dirname(self.index_path)
    if index_dir and not os.path.exists(index_dir):
        os.makedirs(index_dir, exist_ok=True)

    faiss.write_index(self.index, self.index_path)
```



```
def search(self, query: str, top_k: int = 4) -> List[Dict]:
    """
    Busca elementos similares a un texto en el índice.

    Args:
        query: Texto de consulta
        top_k: Número máximo de resultados a devolver

    Returns:
        Lista de diccionarios con los resultados y sus metadatos
    """
    if self.num_vectors == 0:
        return []

    # Limitar top_k al número de vectores disponibles
    top_k = min(top_k, self.num_vectors)

    # Generar embedding para la consulta
    query_vector = self.get_text_embedding(query)

    # Realizar búsqueda
    distances, indices = self.index.search(query_vector, top_k)

    # Preparar resultados
    results = []
    metadata_keys = list(self.metadata.keys())

    for i, idx in enumerate(indices[0]):
        # Buscar la clave correspondiente al índice
        item_key = None
        for key, meta in self.metadata.items():
            if meta.get('faiss_index') == idx:
                item_key = key
                break

        if item_key:
            results.append({
                "item": item_key,
                "metadata": self.metadata[item_key],
                "distance": float(distances[0][i])
            })
        else:
            print(f"ADVERTENCIA: No se encontró metadato para el índice {idx}")

    return results
```

Un ejemplo concreto del flujo embedding+respuesta es:
“¿De qué raza es Diva?”:

Aquí están las respuestas a tus preguntas:

- * **Raza:** Por su apariencia, Diva parece ser un Border Terrier.
- * **Reconocimiento de raza:** Sí, reconozco esta raza.
- * **Acción:** Diva está descansando o echada, mirando a la distancia con una expresión reflexiva.

En este ejemplo se incluye la respuesta, pues en un primer momento se desconocía si esta generación de respuestas era de calidad o no. Concretamente, se usó *gemini-2.0-flash-exp*. Dado que las respuestas de estos primeros ejemplos fueron realmente buenas, se pasa a ver la calidad del RAG. Se realizan preguntas cortas que incluyan el texto que aparecía en las imágenes, como “¿Qué hace Coco?” y otras más genéricas como “¿Cuáles están sobre una cama?” o “Me gustan muchos los colores



variopintos. En concreto, el arcoiris.", que aunque puedan no ser interesantes a nivel de respuestas, sí lo son para valorar la calidad del RAG.

- b. **Experimento_grúas:** el mismo tipo de problema, pero aplicado más a un **caso de uso de empresa**. En este, se tienen grúas de distintos puertos que vienen el nombre del puerto en la parte inferior de la imagen. Se obtienen resultados no tan satisfactorios, pero se debe principalmente al tamaño del texto y la calidad de la foto.



Ilustración 57 Ejemplo de grúas con texto

- c. **Experimento_pdf:** una vez se ha visto que se pueden usar tanto imágenes como texto, se buscará su eficiencia en archivos más comunes en donde se almacena mucha de la **documentación** como son los archivos **pdf**. En estos, se tendrán texto e imágenes, tablas o gráficas. Se usan 2 pdfs de 25 páginas aproximadamente, que son de fondos de inversión. Para evitar tener que extraer por una parte texto y por otras imágenes y tablas, se decide pasar **cada página del pdf como imagen** dada la capacidad de entender el texto dentro de una imagen, siguiendo la metodología que siguen en la **arquitectura ColPali**. Se realizan consultas tanto en texto como en imagen, con el fin de verificar el comportamiento en ambos escenarios:
 - i. **Queries de texto sobre el texto de los pdfs:** el RAG funciona bastante bien, en un porcentaje elevado se recuperan las páginas adecuadas, aunque aparecen en el top algunas que no debería. En la generación de respuesta, sigue siendo buena cuando el RAG previo lo ha sido. Se usa gemini-2.0-flash-exp como primer modelo generador, pero se comienza a usar gemini-2.5-flash-preview-04-17; y como las respuestas son realmente buenas cuando el RAG funciona, nos centramos nuevamente en el RAG (para esto, se le pasan simplemente el top de páginas recuperadas (3 o 5 según conveniencia). Es decir, **el modelo de embedding está capturando la parte semántica tanto del embedding de texto como del texto que aparece en las imágenes usando embedding de imagen.**

Basándome en las imágenes proporcionadas de las cartas anuales de Numantia Patrimonio Global:

****1. Sobre Tesla en la Carta Anual de 2022:****

La carta de 2022 dedica una sección importante a Tesla (páginas 21 y 22, con introducción en la 20). Los puntos clave son:

- * ****Inicio de la Inversión (2018):**** Comenzaron a invertir en Tesla en 2018, vendiendo posiciones en BMW y Porsche Holding para financiarla. La decisión fue controvertida en su momento.
- * ****Controversia Inicial:**** Reconocen que la decisión fue polémica porque Tesla tenía margen operativo negativo, flujo de caja libre negativo, necesitaba financiación externa y parecía una "absurda burbuja". Admiten que inicialmente la tecnología no parecía tener una ventaja competitiva clara y existía riesgo de quiebra.
- * ****Cambio de Opinión y Resultados:**** Tras 4 años, analizaron los resultados y constataron una mejora drástica: el flujo de caja operativo se multiplicó por 5 y el flujo de caja libre por 4. Los márgenes operativos y la rentabilidad del capital invertido eran similares o superiores a los de Toyota. Ya no necesitaban ampliaciones de capital.
- * ****Ventaja Competitiva:**** Argumentan que la verdadera ventaja competitiva de Tesla no está solo en el producto, sino en su ****ritmo de innovación en la fabricación y la ingeniería****. Mencionan la obsesión de Elon Musk por el diseño y la manufactura (comparándolo con Steve Jobs, pero destacando la implicación de Musk en las fábricas), lo que les permite fabricar de forma eficiente y disruptiva. Citan la reacción de Toyota al despiezar un Model Y ("no podemos competir") y la respuesta de Tesla indicando que lo que Toyota considera "obra de arte" ya es pasado para ellos.
- * ****Futuro:**** Mencionan que el diseño de la nueva plataforma, la conducción autónoma y los robots serán aún más valiosos para el negocio.
- * ****Tamaño de la Posición:**** Se menciona (en pág. 20) que Tesla representaba el 25% del fondo ("Teníamos 25 como él en el fondo").

Ilustración 58 Ejemplo respuesta correcta

Basándome en las páginas proporcionadas de las cartas anuales de Numantia Patrimonio Global:

****1. Tesla en la Carta Anual de 2022:****

En la carta de 2022 (principalmente en la página 21), se comenta sobre Tesla:

- * ****Inicio de la Inversión y Dudas Iniciales:**** Empezaron a invertir en Tesla en ****2018****, vendiendo posiciones en BMW y Porsche. Fue una decisión polémica en su momento porque Tesla tenía margen operativo negativo, flujo de caja libre negativo, necesitaba financiación externa, incumplía plazos y parecía una "absurda burbuja".
- * ****Reconocimiento de Error:**** Admiten que su tesis inicial, basada en que Tesla no tenía ventaja competitiva y que los fabricantes tradicionales la superarían, ****fue errónea**** ("me equivocaba").
- * ****Situación (hacia finales de 2022):**** Se destaca un cambio radical. Mencionan que estaban invirtiendo una suma equivalente a ****4 veces el flujo de caja operativo actual y 5 veces el flujo de caja libre****. La empresa seguía creciendo y reinvertiendo a un ritmo muy elevado.
- * ****Fortaleza Financiera y Operativa:**** Se compara favorablemente con Toyota **(que produce 4 veces más coches)**, señalando que Tesla tiene beneficios similares, márgenes operativos y rentabilidad sobre el capital invertido similares, a pesar de las fuertes inversiones. Ya no necesitan financiación externa, tienen caja neta elevada y márgenes altos.
- * ****Lealtad del Cliente (mencionado en pág 25):**** Se usa a Tesla como ejemplo de altísima lealtad, indicando que el 95% de los propietarios pensaban cambiar por otro Tesla si decidiesen cambiar de coche, lo cual es inaudito en la industria y contrasta con los desafíos de Meta en ese aspecto.

En resumen, la carta de 2022 describe una evolución desde el escepticismo inicial hasta el reconocimiento de la fortaleza operativa, financiera y la capacidad de reinversión de Tesla, admitiendo que la visión inicial sobre la compañía fue incorrecta.

****2. Composición de la Cartera Actual (según Carta 2022):****

La tabla de contenidos de la carta de 2022 indica que la "Cartera actual, movimientos y errores" se detalla en la ****página 10****. ****Esa página no está incluida en las imágenes proporcionadas.****

Sin embargo, basándonos en las secciones dedicadas y menciones específicas en las páginas disponibles de la carta 2022:

- * ****Tesla**** (p. 21) es una posición.
- * ****Meta Platforms**** (p. 25) es una posición.
- * ****FRP Holdings**** (p. 19) se menciona como una posición principal en la que se ha convertido el fondo, poseyendo casi el 1% de las acciones de ****esa**** empresa (FRP Holdings).

No se puede determinar la composición completa de la cartera de finales de 2022 solo con las páginas facilitadas.

****3. Primeras 5 Posiciones y Porcentajes (según Carta 2022):****

Esta información normalmente se encontraría en la sección de la cartera (página 10, que falta). ****Las páginas proporcionadas de la carta de 2022 no especifican cuáles son las 5 primeras posiciones ni sus porcentajes**** en la cartera global del fondo a cierre de 2022. Solo se menciona que FRP Holdings es una "posición principal", pero sin indicar su ranking o peso exacto en el portafolio.

Ilustración 59 Ejemplo respuesta con algún error

Hay otras que debería recuperar, por ejemplo, "¿Quién es Bradley Jacobs?", y no la encuentra correctamente a pesar de aparecer textualmente el nombre completo en un par de páginas -> textualmente aparece en las páginas 14 y 1 del pdf 01:

```
query_bradleyj = "¿Quién es Bradley Jacobs?"

results_bradleyj = embedding_manager.search(query = query_bradleyj,
✓ for result in results_bradleyj:
    print(f"{os.path.split(result['metadata']['filename'])[-1]} ; p

pdf_00.pdf ; página 19 (distancia de 1.9)
pdf_00.pdf ; página 16 (distancia de 1.9)
pdf_01.pdf ; página 19 (distancia de 1.91)
pdf_01.pdf ; página 22 (distancia de 1.91)
pdf_01.pdf ; página 7 (distancia de 1.92)
pdf_01.pdf ; página 17 (distancia de 1.93)
pdf_01.pdf ; página 18 (distancia de 1.93)
pdf_00.pdf ; página 24 (distancia de 1.93)
pdf_00.pdf ; página 17 (distancia de 1.93)
pdf_01.pdf ; página 23 (distancia de 1.93)
pdf_00.pdf ; página 5 (distancia de 1.93)
pdf_00.pdf ; página 21 (distancia de 1.94)
pdf_00.pdf ; página 12 (distancia de 1.94)
pdf_01.pdf ; página 25 (distancia de 1.94)
pdf_01.pdf ; página 6 (distancia de 1.94)
```

Ilustración 60 Ejemplo query textual, su top y distancias

- ii. **Queries de texto sobre las imágenes de los pdfs:** en este apartado, los resultados **no fueron tan buenos**. Se preguntaba sobre los Simpson/Homer Simpson (solo aparece una imagen) y en algunas la recupera correctamente y en otras no. Otra pregunta más ambigua, como era sobre “hombres calvos” la hacía bastante bien.
- iii. **Queries de imagen sobre imágenes:** Se les pasa distintas imágenes (Fotos de Homer Simpson y del señor Bradley Jacobs con una camion o texto de su empresa XPO detrás) y los resultados son **realmente buenos**. De hecho, la distancia desciende considerablemente (antes los mejores estaban en torno a 1.7-1.9 y ahora descienden a 1.2-1.3



```
image_path = "./PdfRAG/ImagenesMatch/00.jpg"
image_vector = embedding_manager.get_image_embedding(image_path)

results_image = embedding_manager.search_vector(vector=image_vector)
# results_image = embedding_manager.search_image(image_path)
for result in results_image:
    print(f"{os.path.split(result['metadata']['filename'])[-1]} ; p

✓ 0.6s

pdf_01.pdf ; página 9 (distancia de 1.21)
pdf_01.pdf ; página 7 (distancia de 1.26)
pdf_01.pdf ; página 26 (distancia de 1.29)
pdf_00.pdf ; página 7 (distancia de 1.29)
pdf_01.pdf ; página 13 (distancia de 1.31)
```

Ilustración 61 Ejemplo query de imagen, top y distancias

Lo peor fue este error, debería haber recuperado claramente como primera la 15.



```
image_path = "./PdfRAG/ImagenesMatch/04.png"
image_vector = embedding_manager.get_image_embedding(image_path)

results_image = embedding_manager.search_vector(image_vector)
# results_image = embedding_manager.search_image(image_path)
for result in results_image:
    print(f"{os.path.split(result['metadata'])['filename']}")
```

✓ 2.5s

```
pdf_00.pdf ; página 17 (distancia de 1.29)
pdf_00.pdf ; página 12 (distancia de 1.32)
pdf_00.pdf ; página 19 (distancia de 1.33)
pdf_01.pdf ; página 10 (distancia de 1.33)
pdf_01.pdf ; página 7 (distancia de 1.36)
pdf_01.pdf ; página 13 (distancia de 1.36)
pdf_00.pdf ; página 3 (distancia de 1.36)
pdf_00.pdf ; página 15 (distancia de 1.38)
pdf_00.pdf ; página 7 (distancia de 1.39)
pdf_00.pdf ; página 4 (distancia de 1.42)
```

Ilustración 62 Ejemplo query imagen que aparece en el top 8

Debido a que parecía que las queries de imagen eran de menor distancia respecto a las queries de texto, se trata de verificar esto. Para ello:

- iv. Ver **diferencias** pasar texto como **input de texto** o como **imagen del texto**: no se puede pasar una página entera dada la **limitación de caracteres**, así que se usa un párrafo y la captura de dicho párrafo. Esto confirma el problema de los modelos multimodales recogido en algunos artículos como “**modality gap**”. Si usamos el embedding de texto, la distancia es de 1.65 frente a la distancia de 0.54 en input imagen (y que las top5 restantes de imagen están más “cercanas” que la correcta en texto).



```
pdf_00.pdf ; página 18 (distancia de 1.65)
pdf_00.pdf ; página 8 (distancia de 1.68)
pdf_01.pdf ; página 10 (distancia de 1.69)
pdf_01.pdf ; página 4 (distancia de 1.69)
pdf_01.pdf ; página 17 (distancia de 1.69)

image_path = "./PdfRAG/ImagenesMatch/06.png"

image_vector = embedding_manager.get_image_embedding(image_path= image_path)

results_image = embedding_manager.search_vector(vector=image_vector, top_k=5)
# results_image = embedding_manager.search_image(image_path, top_k=5)
for result in results_image:
    print(f"{os.path.split(result['metadata']['filename'])[-1]} ; página {result['page']}")

✓ 0.8s

pdf_00.pdf ; página 18 (distancia de 0.54)
pdf_00.pdf ; página 24 (distancia de 0.64)
pdf_00.pdf ; página 7 (distancia de 0.65)
pdf_00.pdf ; página 27 (distancia de 0.71)
pdf_01.pdf ; página 9 (distancia de 0.71)

text_vector = embedding_manager.get_text_embedding(text = pag_18_00_pdf)
from sklearn.metrics import euclidean_distances

✓ 1.0s

distancia = euclidean_distances(image_vector, text_vector)[0][0]
print(distancia)

✓ 0.0s

1.2848388
```

Ilustración 63 Diferencias embedding de texto pasado como input texto vs imagen respecto a una imagen

En esta línea, se busca ver las diferencias entre una página de pdf escrita con diferente tipo de letra, diferente color de la letra o diferente color de fondo, a la que también se añade una hoja en blanco en dicha comparativa. Los resultados son buenos en el sentido de que la distancia es bastante menor que los mejores resultados en otras, pero también es mejor en el caso de la **página en blanco**, y esto sí es un **inconveniente**.



Ilustración 64 Páginas modificando tipo y color de letra, fondo y página en blanco

```
for i in range(len(vectores)):
    print(f"\nComparar página {i+1} con las demás páginas:")
    for j in range(len(vectores)):
        if i != j:
            dist = euclidean_distances([vectores[i]], [vectores[j]])
            print(f"Distancia entre página {i+1} y página {j+1}: {dist[0][0]}")
```

✓ 0.1s

Comparar página 1 con las demás páginas:
 Distancia entre página 1 y página 2: 0.3814746141433716
 Distancia entre página 1 y página 3: 0.40961262583732605
 Distancia entre página 1 y página 4: 1.069821193084717

Comparar página 2 con las demás páginas:
 Distancia entre página 2 y página 1: 0.3814746141433716
 Distancia entre página 2 y página 3: 0.28945717215538025
 Distancia entre página 2 y página 4: 0.990876317024231

Comparar página 3 con las demás páginas:
 Distancia entre página 3 y página 1: 0.40961262583732605
 Distancia entre página 3 y página 2: 0.28945717215538025
 Distancia entre página 3 y página 4: 1.0342488288879395

Comparar página 4 con las demás páginas:
 Distancia entre página 4 y página 1: 1.069821193084717
 Distancia entre página 4 y página 2: 0.990876317024231
 Distancia entre página 4 y página 3: 1.0342488288879395

Ilustración 65 Resultados comparando vectores de páginas

Tras esta primera fase, donde se han visto un buen comportamiento en líneas generales en el uso de imágenes y pdfs tratados como imágenes, se va a llevar un caso de uso más cercano al proyecto.

En la segunda fase, teniendo un caso de uso **más industrial**, se usan como pdfs 25 **manuales de motos**.

Este es un caso muy concreto, donde los inputs de texto no serán casi nunca relevantes. Por ejemplo, un mecánico de un taller pregunta sobre como cambiar el aceite, desmontar una parte específica de la moto o sobre alguna pieza concreta de una motocicleta. El mencionado texto, para la primera parte del RAG (es decir, del embedding), resultará más relevante el caso en el que esa pieza o parte de la moto sea consultada como imagen del tipo (¿Qué discos puedo usar?,...). Por ello, es más necesario el RAG de imágenes (si nos dijera el modelo de la moto directamente, solo haría falta pasarle dicho documento al modelo generativo).

Así, como una prueba más cuantitativa, se prueban a pasar **imágenes de** las 25 motos en una posición similar a la que se encuentran en dicho manual. Hay 3 motos que no tienen una imagen de la motocicleta entera, que se descartan de dicho estudio, y del resto, 8 de ellas no tienen una imagen real de dicha moto, tan solo un dibujo y partes de la moto, y 3 de ellas que la motocicleta solo aparece la mitad de la moto (la parte delantera y la trasera), es decir, 8 con solo dibujo, 3 con la mitad y 12 con la imagen de la moto completa en al menos 1 página del manual. Así, teniendo en cuenta estas **22 motos**, se realiza el embedding y los resultados son los siguientes:




Ilustración 66 Resultados experimentos de motos

Recuperamos el manual y las páginas objetivo como **primer resultado en el 68%** de las veces, **81% entre los 3 primeros** y un, no ex86% en el top 5.

Respecto a los modelos generadores multimodales, en el caso de no realizar RAG, o que este no sea exitoso, las respuestas son más genéricas y de menor calidad-concreción. Aunque no era el objetivo de esta primera aproximación, se tienen los siguientes resultados.

Respuestas sin RAG:

```
Respuesta del modelo: ¡Excelente idea! Revisar los frenos y el aceite es fundamental para mantener tu nueva moto en óptimas condiciones y garantizar tu seguridad.

Aquí tienes unos puntos clave para revisar:

**Revisión de Frenos:**

1. **Nivel de Líquido de Frenos:** Localiza los depósitos de líquido de frenos (generalmente en el manillar para el delantero y cerca del pedal para el trasero). Verifica que el nivel esté entre las marcas de mínimo y máximo. Si está bajo, podría indicar desgaste de pastillas o una fuga (menos probable en una moto nueva, pero posible).
2. **Estado de las Pastillas de Freno:** Mira las pastillas de freno en cada rueda. Deberías ver la capa de material de fricción. Si se ve muy delgada o casi al metal, necesitan ser reemplazadas. El manual de tu moto te dirá el grosor mínimo permitido.
3. **Estado de los Discos de Freno:** Examina los discos. Busca surcos profundos, rayones excesivos o decoloración (que podría indicar sobrecalentamiento). Pasa el dedo por el borde del disco; si notas un reborde prominente, el disco podría estar desgastado.
4. **Sensación de la Maneta y el Pedal:** Acciona la maneta del freno delantero y el pedal del freno trasero. Deberían sentirse firmes, sin esponjosidad. Si se sienten blandos o llegan muy cerca del manillar/pie antes de frenar, podría haber aire en el circuito o un problema con el líquido.

**Revisión de Aceite:**

1. **Nivel de Aceite:**
   * **Consulta el Manual:** Lo más importante es saber si tu moto usa una ventana de inspección o una varilla medidora, y si el nivel se mide con el motor frío o caliente, y si la moto debe estar recta o en la pata de cabra.
   * **Cada moto es diferente.**
   * **Procedimiento General (si tiene ventana):** Con la moto en posición vertical (no en la pata de cabra) y el motor a la temperatura recomendada por el manual (a menudo después de haber funcionado unos minutos y haber reposado otros), mira la ventana en el lado del cárter. El nivel de aceite debe estar entre las marcas de mínimo y máximo.
   * **Procedimiento General (si tiene varilla):** Con la moto en la posición y temperatura correcta, desenrosca (o sácala si no es roscada) la varilla, límpiala, vuelve a introducirla sin enroscar (si es de rosca) o enroscando completamente (si el manual lo indica), sácala de nuevo y mira el nivel. Debe estar entre las marcas.
2. **Color y Consistencia del Aceite:** El aceite debe verse limpio, de color miel o ligeramente oscuro si ya tiene algo de uso, pero no negro, espeso o con partículas metálicas visibles.
3. **Fugas:** Revisa alrededor del motor y debajo de la moto en busca de manchas de aceite que puedan indicar una fuga.

**Consejo Adicional:**

* **El Manual del Propietario es tu Mejor Amigo:** Para saber exactamente cómo revisar el aceite (temperatura, posición, varilla/ventana) y el grosor mínimo de las pastillas, consulta siempre el manual de tu nueva moto.
* **Primer Servicio:** Las motos nuevas tienen un primer servicio (generalmente a los 500-1000 km) que es crucial. En ese servicio se cambian aceite y filtro, se revisan tornillería, cadena, frenos, etc. Asegúrate de hacerlo para que la garantía sea válida y la moto tenga una buena vida útil.

¡Disfruta tu nueva moto!
```

```
Respuesta del modelo: Claro, puedo ayudarte con información general sobre cómo reparar los frenos de tu moto, pero es importante entender que:

1. **No puedo diagnosticar el problema exacto** solo con la imagen o la descripción "reparar los frenos". Hay muchas posibles fallas.
2. **Los frenos son un componente CRÍTICO de seguridad.** Un error puede ser muy peligroso. Si no tienes experiencia en mecánica de motos, es *altamente* recomendable llevarla a un taller profesional.

Para darte una mejor orientación, necesito que me digas:

* **¿Cuál es el problema específico con los frenos?** (Ej: la palanca/pedal se siente esponjoso, hace ruido al frenar, frena poco, pierde líquido, etc.)
* **¿Qué moto tienes?** (Marca, modelo y año, ya que la imagen puede no ser tu moto exacta).
* **¿Qué experiencia tienes en mecánica?** ¿Has hecho mantenimiento básico antes? ¿Tienes las herramientas adecuadas?

Mientras tanto, aquí hay algunas reparaciones comunes relacionadas con los frenos:

* **Cambio de pastillas de freno:** Es una de las reparaciones más habituales cuando las pastillas están gastadas.
* **Cambio de líquido de frenos:** El líquido de frenos pierde propiedades con el tiempo y debe cambiarse periódicamente.
* **Purga del circuito de frenos:** Si hay aire en el sistema, la palanca/pedal se sentirá esponjoso. Purgar elimina el aire.
* **Revisión o cambio de discos de freno:** Si los discos están muy desgastados o dañados, deben ser reemplazados.
* **Revisión o reparación de la bomba de freno (cilindro maestro):** Si no genera la presión adecuada.
* **Revisión o reparación de la pinza de freno:** Los pistones pueden atascarse o tener fugas.

**Si quieres intentar la reparación tú mismo:**

1. **Investiga a fondo:** Busca tutoriales específicos para tu modelo de moto.
2. **Consigue las herramientas adecuadas:** Necesitarás herramientas métricas, posiblemente una llave dinamométrica, un kit de purga, etc.
3. **Compra los repuestos correctos:** Asegúrate de comprar pastillas, líquido de frenos y otros componentes compatibles con tu moto.
4. **Trabaja en un área limpia y bien iluminada.**
5. **Sigue las instrucciones cuidadosamente.**
6. **La seguridad primero!** Si no estás seguro de un paso, detente y busca ayuda.

**Mi recomendación principal:** Si no estás seguro de la causa del problema o no tienes experiencia reparando frenos, lo más seguro es que llesves tu moto a un mecánico de confianza. La seguridad en la carretera depende directamente de que tus frenos funcionen perfectamente.

Dime más sobre el problema para ver si puedo darte información más específica.
```

RAG erróneo:

```
Respuesta del modelo:
Hola. Entendido, quieres cambiar los frenos de tu moto Kawasaki.

Veo que has proporcionado un manual que parece ser para los modelos Kawasaki Z800 y Z800 ABS. Aunque mencionas una "Kawasaki Ninja", la imagen de la portada del manual es de una Z800, que es un modelo diferente de la familia Kawasaki. La otra imagen que muestras parece ser una ZX-10R.

Es importante asegurarse de tener el manual correcto para tu modelo específico, ya que los procedimientos y especificaciones pueden variar.

Si tu moto es efectivamente una **Kawasaki Z800 o Z800 ABS**, el manual que proporcionaste contiene información detallada sobre el sistema de frenos.

Según la "Guía rápida" (página 3 del OCR), la sección de **Frenos** comienza en la **página 12** del manual (página 423 en el OCR de las imágenes que enviaste).

Dentro de esa sección, encontrarás procedimientos específicos como:

* **Inspección del desgaste de la pastilla de freno:** Página 12-27 (OCR 449)
* **Desmontaje/Instalación de las pastillas de freno:** Páginas 12-24 (OCR 446) y 12-26 (OCR 448)
* **Cambio del líquido de frenos:** Página 12-32 (OCR 454)
* **Purga del tubo del sistema de frenado:** Página 12-32 (OCR 454)


**Importante:** Cambiar los frenos es una tarea crítica para la seguridad. Asegúrate de seguir todos los pasos del manual, incluyendo los pares de apriete especificados (página 12-5 a 12-13 del manual / OCR 427 435), y utilizar el líquido de frenos correcto (DOT4 para la Z800/Z800 ABS según el manual).

Si tu modelo de moto es diferente (por ejemplo, una Ninja ZX-10R), este manual podría no ser el adecuado y las piezas y procedimientos serían distintos. Por favor, confirma el modelo exacto si no estás seguro.

¿Necesitas ayuda con algún procedimiento específico del capítulo de frenos del manual de la Z800/Z800 ABS?
```

RAG exitoso:





Como acalaración, a los modelos , dado el amplio contexto que permiten, se les está pasando hasta 2 manuales PDF completos (en formato .pdf), no exclusivamente las páginas recuperadas.

2. VoyageAI - voyage-multimodal-3

i. Introducción

Tal como se cita en (Xiao et al., n.d.), el modelo de embedding multimodal de Voyage AI (by MongoDB) obtiene unos resultados excelentes para diferentes tareas y benchmarks, en concreto para la tarea de Document Understanding es el que mejor resultado obtiene.

MIEB Full (130 tasks)													
Model Name (↓)	Model Type	Rtrv. (45)	Clus. (5)	ZS. (23)	LP. (22)	Cmp. (7)	VC. (6)	Doc. (10)	vSTS (en) (7)	Rtrv. (m) (3 (55))	vSTS (x&m) (2 (19))	Mean (en) (125)	Mean (m) (130)
Voyage-multimodal-3	MLLM	38.8	82.4	58.2	71.3	43.5	48.6	71.1	81.8	58.9	70.4	62.0	62.5
E5-V	MLLM	34.0	70.0	50.0	74.5	46.3	51.9	62.7	79.3	66.6	46.3	58.6	58.2
siglip-so400m-patch14-384	Enc.	40.8	82.1	70.8	84.6	40.4	46.3	56.4	68.0	40.2	41.4	61.2	57.1
siglip-large-patch16-384	Enc.	39.9	79.9	68.0	83.7	39.7	45.4	53.3	69.5	51.1	39.8	59.9	57.0
siglip-large-patch16-256	Enc.	38.8	82.1	67.7	82.5	40.8	44.9	39.4	67.4	49.8	38.1	57.9	55.2
siglip-base-patch16-512	Enc.	38.1	74.7	64.1	80.9	37.5	53.2	52.1	67.7	43.2	38.1	58.5	54.9
CLIP-ViT-bigG-14-laion2B	Enc.	41.5	85.6	69.4	83.6	42.4	43.2	43.2	70.9	28.0	34.5	60.0	54.2
siglip-base-patch16-384	Enc.	37.7	76.3	64.1	80.6	38.5	52.8	45.0	67.0	42.5	37.5	57.8	54.2
EVA02-CLIP-bigE-14-plus	Enc.	40.1	92.4	70.8	86.0	45.7	39.4	32.3	72.0	27.8	28.2	59.8	53.5
CLIP-ViT-L-14-DataComp.XL	Enc.	38.1	86.4	68.4	82.0	39.1	52.3	38.6	69.9	23.8	35.8	59.4	53.4
siglip-base-patch16-256(m)	Enc.	35.6	74.6	61.2	78.9	38.1	51.3	26.4	65.5	59.2	40.3	53.9	53.1
CLIP-ViT-H-14-laion2B	Enc.	39.7	83.9	67.5	82.5	42.0	45.8	40.4	65.5	25.5	33.9	58.4	52.7
CLIP-ViT-g-14-laion2B	Enc.	39.8	82.7	67.9	82.8	41.9	44.2	37.6	69.1	25.9	31.7	58.3	52.4
EVA02-CLIP-bigE-14	Enc.	39.0	89.4	69.3	84.5	42.4	43.6	31.6	68.8	25.5	28.3	58.6	52.2
siglip-base-patch16-256	Enc.	36.6	75.2	63.1	79.7	39.5	52.2	31.7	66.2	41.3	34.4	55.5	52.0
siglip-base-patch16-224	Enc.	36.3	74.5	62.6	79.3	39.8	51.1	26.2	64.3	41.2	33.5	54.3	50.9
CLIP-ViT-L-14-laion2B	Enc.	38.0	83.5	65.8	81.2	40.8	45.9	36.3	65.8	23.0	26.0	57.2	50.6
VLM2Vec-LoRA	MLLM	27.7	72.6	46.3	62.0	34.6	62.0	49.7	72.6	34.9	42.2	53.4	50.5
VLM2Vec-Full	MLLM	27.6	70.7	46.3	62.0	35.4	62.1	49.8	72.6	35.0	42.2	53.3	50.4
clip-vit-large-patch14	Enc.	33.7	76.4	62.1	80.1	44.8	44.1	38.0	64.5	20.2	35.1	55.4	49.9

Ilustración 67 Comparativa Voyage vs otros benchamrk MIEB Full

MIEB-lite (51 tasks)													
Model Name (↓)	Model Type	Rtrv. (11)	Clus. (2)	ZS. (7)	LP. (8)	Cmp. (6)	VC. (5)	Doc. (6)	vSTS (en) (2)	Rtrv. (m) (2 (47))	vSTS (x&m) (2 (19))	Mean (en) (47)	Mean (m) (51)
Voyage-multimodal-3	MLLM	33.2	76.6	48.6	69.3	35.8	50.0	63.5	84.2	49.0	70.4	57.7	58.1
siglip-so400m-patch14-384	Enc.	32.4	75.9	73.8	78.8	32.8	48.0	46.9	69.6	35.4	41.4	57.3	53.5
siglip-large-patch16-384	Enc.	31.9	75.2	71.3	77.7	32.1	46.8	44.9	69.6	43.5	39.8	56.2	53.3
E5-V	MLLM	26.9	51.7	36.2	70.6	39.4	52.6	56.0	81.2	58.3	46.3	51.8	51.9
siglip-large-patch16-256	Enc.	31.0	76.5	70.3	76.3	33.4	46.5	31.9	67.6	42.6	38.1	54.2	51.4
CLIP-ViT-bigG-14-laion2B	Enc.	34.2	80.8	72.4	77.8	35.0	43.0	35.5	73.4	26.2	34.5	56.5	51.3
siglip-base-patch16-512	Enc.	30.8	69.7	66.3	74.6	29.7	55.5	42.6	67.1	34.8	38.1	54.5	50.9
EVA02-CLIP-bigE-14-plus	Enc.	35.2	87.3	74.0	80.0	38.9	38.8	26.2	73.7	26.0	28.2	56.8	50.8
siglip-base-patch16-384	Enc.	30.6	72.2	66.0	74.4	31.0	55.1	37.1	66.9	34.5	37.5	54.1	50.5
CLIP-ViT-L-14-DataComp.XL	Enc.	31.0	80.4	69.4	75.3	31.6	54.9	30.8	72.5	22.6	35.8	55.7	50.4
CLIP-ViT-H-14-laion2B	Enc.	32.8	79.3	69.4	76.8	34.8	46.8	33.7	68.3	23.9	33.9	55.2	50.0
EVA02-CLIP-bigE-14	Enc.	34.3	86.7	73.0	78.3	35.1	44.4	25.1	69.9	23.9	28.3	55.9	49.9
siglip-base-patch16-256(m)	Enc.	28.2	68.2	63.2	73.4	30.7	53.3	22.9	63.7	52.9	40.3	50.4	49.7
CLIP-ViT-g-14-laion2B	Enc.	33.5	76.8	69.6	77.3	34.7	45.0	29.9	71.6	24.2	31.7	54.8	49.4
siglip-base-patch16-256	Enc.	29.5	69.6	65.6	73.6	32.2	54.4	25.0	66.1	33.5	34.4	52.0	48.4
CLIP-ViT-L-14-laion2B	Enc.	31.1	76.4	67.8	75.9	33.6	46.9	28.7	68.7	21.4	26.0	53.6	47.6
clip-vit-large-patch14	Enc.	26.7	71.3	63.8	74.5	39.4	44.9	29.4	69.4	19.8	35.1	52.4	47.4
siglip-base-patch16-224	Enc.	29.3	68.4	65.0	73.5	32.5	53.0	20.9	64.2	33.6	33.5	50.8	47.4
CLIP-ViT-B-16-DataComp.XL	Enc.	28.3	73.6	61.9	73.2	31.4	56.9	22.7	69.7	19.9	28.5	52.2	46.6
VLM2Vec-LoRA	MLLM	21.0	66.3	32.1	64.8	29.4	65.3	42.7	70.9	24.8	42.2	49.1	46.0

Ilustración 68 Comparativa voyage vs otros benchmrk MIEB-lite

De forma resumida, se tienen las siguientes características:

- Vectores de **dimensión 1024**.
- Permiten **input de imágenes y/o de texto** .
- Capaz de vectorizar **texto e imágenes intercaladas**, tal como mencionan, “eliminating the need for complex document parsing”. Permite recibir como input un par imagen-texto y obtener un vector (a diferencia de otros embeddings, donde se realizaba un embedding para cada input de entrada).
- Recomendado por Anthropic, desarrollado por MongoDB.




Ilustración 69 Comparativa modelos modalidad cruzada por ratio de capturas de pantalla

Respecto a limitaciones en cuanto a número de tokens, solicitudes por minuto y precios, se tienen lo siguiente:



Rate Limits

Rate limits are restrictions that we impose on the number of times and tokens a user can access our API services within a specified period of time.

Models	Basic TPM	Basic RPM
voyage-3-large voyage-code-3 voyage 18&2 Series embedding models	3M	2000
voyage-3.5	8M	2000
voyage-3.5-lite	16M	2000
voyage-multimodal-3	2M	2000
rerank-lite-1 , rerank-2-lite	4M	2000
rerank-1 , rerank-2	2M	2000

Usage tiers

You can view your organization’s rate limits in the organization [Rate Limits](#) section of the Voyage dashboard. As your usage and spending of the Voyage API increase, we automatically graduate you to the next usage tier, raising rate limits across all models. The table below summarizes the qualification criteria for each usage tier.

Usage Tier	Qualification	Rate Limits
1	Payment method added.	See table above.
2	≥ \$100 paid	2x Tier 1
3	≥ \$1000 paid	3x Tier 1

Multimodal Embeddings

We charge for requests to the Voyage multimodal endpoint based on the number of tokens in the text and the number of pixels in images. The first 200M text tokens and 150B pixels for `voyage-multimodal-3` are free for every account. Subsequent usage is priced per token and per pixel, as shown in the following table.

Model	Price per million tokens	Price per billion pixels	Number of free tokens and pixels
<code>voyage-multimodal-3</code>	\$0.12	\$0.60	200M text tokens and 150B pixels



An image with fewer than 50,000 pixels will be upsampled, processed, and charged as a 50,000-pixel image. Images containing over 2 million pixels will be downsampled and charged as 2 million-pixel images. Therefore, the minimum and maximum costs per image are \$0.00003 and \$0.0012, respectively. The following table provides examples of image pricing.

Image resolution	Number of pixels	Price per image	Price per thousand images
200px x 200px	40,000	\$0.00003	\$0.03
1000px x 1000px	1 million	\$0.0006	\$0.60
2000px x 2000px	4 million	\$0.0012	\$1.20
4000px x 4000px	16 million	\$0.0012	\$1.20

For example, the cost to vectorize a single input with 1000 text tokens (\$0.00012) and two 4 million-pixel images (2 x \$0.0012) would be \$0.00252.

Además, en la documentación vienen lo siguiente:

Python API

Voyage multimodal embeddings are accessible in Python through the `voyageai` package. Please install the `voyageai` package, [set up](#) the API key, and use the `voyageai.Client.multimodal_embed()` function to vectorize your inputs.

```
voyageai.Client.multimodal_embed (inputs : List[dict] or List[List[Union[str, PIL.Image.Image]]],
model : str, input_type : Optional[str] = None, truncation : Optional[bool] = True)
```

Parameters

- **inputs** (List[dict] or List[List[Union[str, PIL.Image.Image]]]) - A list of multimodal inputs to be vectorized.
 - Each input is a sequence of text and images, which can be represented in either of the following two ways:
 - (1) A list containing text strings and/or PIL image objects (List[Union[str, PIL.Image.Image]]), where each image is an instance of the [Pillow Image class](#). For example: `["This is a banana.", PIL.Image.open("banana.jpg")]`.

▼ PIL Image Object

[Pillow](#) is a widely used Python library for image processing. In the above example, `PIL.Image.open()` opens an image file and returns a PIL Image. Please see our [FAQ](#) for more details about Pillow.
 - (2) A dictionary that contains a single key `"content"`, whose value represents a sequence of text and images. The dictionary schema is identical to that of an input in the `inputs` parameter of the [REST API](#).
- The following constraints apply to the `inputs` list:
 - The list must not contain more than 1,000 inputs.
 - Each image must not contain more than 16 million pixels or be larger than 20 MB in size.
 - With every 560 pixels of an image being counted as a token, each input in the list must not exceed 32,000 tokens, and the total number of tokens across all inputs must not exceed 320,000.



- **input_type** (str, optional, defaults to `None`) - Type of the input. Options: `None`, `query`, `document`.
 - When `input_type` is `None`, the embedding model directly converts the `inputs` into numerical vectors. For retrieval/search purposes, where a "query", which can be text or image in this case, is used to search for relevant information among a collection of data referred to as "documents," we recommend specifying whether your `inputs` are intended as queries or documents by setting `input_type` to `query` or `document`, respectively. In these cases, Voyage automatically prepends a prompt to your `inputs` before vectorizing them, creating vectors more tailored for retrieval/search tasks. Since `inputs` can be multimodal, "queries" and "documents" can be text, images, or an interleaving of both modalities. Embeddings generated with and without the `input_type` argument are compatible.
 - For transparency, the following prompts are prepended to your input.
 - For `query`, the prompt is "Represent the query for retrieving supporting documents:".
 - For `document`, the prompt is "Represent the document for retrieval:".

Lo cual nos explica que hay cierto **prompt engineering** para obtener el vector.

ii. Pruebas

Se testean de manera inicial los límites. Se ha de comentar que en la primera fase, la limitación de tokens era todavía mayor debido a que inicialmente la limitación era de 10K Tokens por minuto y 3 peticiones por minuto, que se aumentan a los de la tabla (2M TPM y 2000 RPM) una vez se introduce una tarjeta de pago.

```
class EmbeddingVoyageAI:
    """
    Clase para manejar embeddings multimodales usando VoyageAI y búsquedas con FAISS.

    Esta clase implementa funcionalidades para:
    - Crear embeddings de imágenes y texto usando VoyageAI
    - Gestionar índices FAISS
    - Realizar búsquedas por similitud
    - Gestionar metadatos asociados
    - Procesar PDFs como imágenes
    """

    def __init__(self,
                 vector_dim: int = 1024,
                 index_path: str = "faiss_index_voyage.bin",
                 metadata_path: str = "metadata_voyage.json"):
        """
        Inicializa el gestor de embeddings multimodales con VoyageAI.

        Args:
            vector_dim: Dimensión de los vectores de embedding (1024 para voyage-multimodal-3)
            index_path: Ruta al archivo del índice FAISS
            metadata_path: Ruta al archivo de metadatos
        """
        self.vector_dim = vector_dim
        self.index_path = index_path
        self.metadata_path = metadata_path
        VOYAGE_API_KEY = os.getenv("VOYAGE_API_KEY")

        self.index, self.num_vectors = self._load_index()
        self.client = voyageai.Client(api_key=VOYAGE_API_KEY)
        self.metadata = self._load_metadata()
        self.model_id = "voyage-multimodal-3"
```



```
def get_chunks_with_langchain(self, text:str, chunk_size:int=10000*3.5, chunk_overlap:int=0): #chunk_size = 1024 si fuera Embedding de VertexAI
    """
    Divide un texto en chunks usando RecursiveCharacterTextSplitter de LangChain.

    Args:
        text: Texto a dividir en chunks
        chunk_size: Tamaño máximo de cada chunk (por defecto 35000 caracteres)
        chunk_overlap: Solapamiento entre chunks (por defecto 0)

    Returns:
        Lista de strings con los chunks de texto
    """
    splitter = RecursiveCharacterTextSplitter(chunk_size=chunk_size, chunk_overlap=chunk_overlap)
    return splitter.split_text(text)

def get_text_embedding(self, lista_chunks: List[str]):
    """
    Obtiene los embeddings de una lista de chunks de texto utilizando el modelo VoyageAI.

    Implementa control de rate limiting para respetar los límites de API de VoyageAI.
    Procesa cada chunk con una espera de 60 segundos entre requests.

    Args:
        lista_chunks: Lista de strings con los chunks de texto a procesar

    Returns:
        numpy.ndarray: Array con los embeddings de todos los chunks
    """
    lista_chunks_format = [[chunk] for chunk in lista_chunks]
    print(f"Total de chunks: {len(lista_chunks_format)}. Procesando (aprox {len(lista_chunks_format)} minutos)...")

    lista_resultados = []
    for chunk in lista_chunks_format[:-1]:
        start_time = time.time()
        resultado = self.client.multimodal_embed(
            inputs=[chunk],
            model="voyage-multimodal-3",
            input_type="document"
        )
        end_time = time.time()
        # print(f"Chunk procesado en {end_time - start_time:.2f} segundos")
        lista_resultados.append(resultado)
        tiempo_espera = 60 - int((end_time - start_time)) + 1
        time.sleep(tiempo_espera)
    resultado = self.client.multimodal_embed(
        inputs=[lista_chunks_format[-1]],
        model="voyage-multimodal-3",
        input_type="document"
    )
    lista_resultados.append(resultado)

    lista_resultados_np = [np.array(resultado.embeddings[0], dtype='float32') for resultado in lista_resultados]
    return np.array(lista_resultados_np, dtype='float32')

def get_image_embedding(self, image_path: str):
    """
    Genera el embedding de una imagen usando VoyageAI.

    Args:
        image_path: Ruta completa a la imagen

    Returns:
        Tuple[numpy.ndarray, Tuple]: Embedding de la imagen y sus dimensiones (ancho, alto)
    """
    image = PIL.Image.open(image_path)
    result = self.client.multimodal_embed(
        inputs=[image],
        model=self.model_id,
        input_type="document"
    )
    return np.array(result.embeddings[0], dtype='float32'), image.size
```

```
def pdf_page_to_image(self, doc, page_num: int, zoom: float = 2.0) -> Optional[PIL.Image.Image]:
    """
    Convierte una página de un PDF a una imagen PIL.

    Args:
        doc: Objeto PDF abierto con PyMuPDF (resultado de fitz.open)
        page_num: Número de la página a convertir (0-indexed)
        zoom: Factor de zoom para la conversión a imagen (por defecto 2.0)

    Returns:
        PIL.Image.Image: Imagen de la página del PDF, o None si hay un error
    """
    try:
        page = doc.load_page(page_num)
        mat = fitz.Matrix(zoom, zoom)
        pix = page.get_pixmap(matrix=mat)
        img_bytes = pix.tobytes("png")
        pil_image = PIL.Image.open(io.BytesIO(img_bytes))
        return pil_image
    except Exception as e:
        print(f"Error al convertir la página {page_num} del PDF: {e}")
        return None
```

Así, primeramente, se vectoriza un libro de 357 páginas en 14 chunks (como prueba del máximo número de tokens de texto que permite el modelo). Se hacen pruebas de realizar input de imagen, y también pruebas de imagen-texto en un solo vector. Posteriormente, se realiza un ejemplo más concreto: construir una **bbdd multimodal** con:

- el libro (de Harry Potter) de **347 páginas en formato txt**
- **6 manuales de motos** (401,320,359,176, 540 y 1209 páginas) **pdf**.

Para el libro se realiza embedding de input texto de **1 vector/página**, mientras que para los pdfs se pasan como imágenes nuevamente de 1 vector/página. Así, a la hora de hablar de vectores, se puede hablar directamente de páginas en los resultados siguientes.

Para **verificar** que no tiene **modality gap**, se trata de verificar con preguntas/inputs de texto que tengan que ver con las motos (pasados como inputs de imágenes) y preguntas/inputs de imagen que están relacionados con el libro (pasado como input de texto), además del resto (preguntas de texto sobre libro e preguntas de imágenes sobre los manuales de motos). Se observa que no solo recupera las páginas correctas, sino que la distancia no se observa el modality gap de otros modelos.

a) Preguntas input texto sobre libro de texto:

	top_1	top_2	top_3	top_4	top_5	top_6	top_7	top_8	top_9
¿Cuáles son los profesores de Harry Potter?	harrypotter_caliz.txt - 140	harrypotter_caliz.txt - 145	harrypotter_caliz.txt - 203	harrypotter_caliz.txt - 150	harrypotter_caliz.txt - 147	harrypotter_caliz.txt - 127	harrypotter_caliz.txt - 117	harrypotter_caliz.txt - 141	harrypotter_caliz.txt - 258
La navidad es una época del año muy especial.	harrypotter_caliz.txt - 215	harrypotter_caliz.txt - 216	harrypotter_caliz.txt - 237	harrypotter_caliz.txt - 218	harrypotter_caliz.txt - 224	harrypotter_caliz.txt - 225	harrypotter_caliz.txt - 255	harrypotter_caliz.txt - 17	harrypotter_caliz.txt - 343
What is the least liked teacher?	harrypotter_caliz.txt - 140	harrypotter_caliz.txt - 127	harrypotter_caliz.txt - 150	harrypotter_caliz.txt - 145	harrypotter_caliz.txt - 61	harrypotter_caliz.txt - 117	harrypotter_caliz.txt - 86	harrypotter_caliz.txt - 10	harrypotter_caliz.txt - 336
¿Cuál es la estación de tren más famosa?	harrypotter_caliz.txt - 81	harrypotter_caliz.txt - 104	harrypotter_caliz.txt - 122	harrypotter_caliz.txt - 106	harrypotter_caliz.txt - 71	harrypotter_caliz.txt - 98	harrypotter_caliz.txt - 145	harrypotter_caliz.txt - 103	harrypotter_caliz.txt - 140
Este castillo es de hace muchos años.	Aprili dorsoduro 750 2009 a 2011.pdf - 5	Aprilia shiver 2007.pdf - 5	harrypotter_caliz.txt - 283	harrypotter_caliz.txt - 48	Aprili dorsoduro 750 2009 a 2011.pdf - 391	harrypotter_caliz.txt - 124	Aprilia shiver 2007.pdf - 352	harrypotter_caliz.txt - 218	harrypotter_caliz.txt - 332

	top_1	top_2	top_3	top_4	top_5	top_6	top_7	top_8	top_9
¿Cuáles son los profesores de Harry Potter?	0.868212	0.959821	0.966003	0.974723	0.977912	0.979882	0.983648	0.991519	1.004512
La navidad es una época del año muy especial.	1.335305	1.370965	1.382056	1.401335	1.413738	1.452920	1.461590	1.468165	1.479004
What is the least liked teacher?	1.093304	1.203521	1.218222	1.230245	1.249915	1.254174	1.254635	1.257538	1.261739
¿Cuál es la estación de tren más famosa?	1.345899	1.350516	1.378514	1.379591	1.388818	1.398982	1.400061	1.405111	1.435470
Este castillo es de hace muchos años.	1.542199	1.542199	1.575106	1.581359	1.592790	1.594101	1.595246	1.600310	1.600864

Ilustración 70 Resultados recuperación textual sobre vectores de texto

Las preguntas aparecen en la primera columna (a la izquierda de la imagen), mientras que las páginas recuperadas aparecen en las restantes columnas de izquierda a derecha desde la primera a la última página recuperada.

Las primeras 4 preguntas recuperan en el top 9 páginas del libro donde se hacen menciones sobre lo dicho, salvo la última, que era más ambigua, cosa que se refleja en las distancias. El **resultado es satisfactorio**.

b) Preguntas input texto sobre manuales de motos

Las preguntas de motos muestran que **no hay modality gap**, pues **no emparejan el texto con los inputs de texto**, y se puede ver que las distancias son similares al ejemplo anterior dependiente del detalle.



¿Cómo cambio los frenos de mi moto?	BMW R 1200 gs (2011).pdf - 108	BMW R 1200 gs (2011).pdf - 171	BMW R 1200 gs (2011).pdf - 64	BMW R 1200 gs (2011).pdf - 76	BMW R 1200 gs (2011).pdf - 104	Ducati Monster S2R1000.pdf - 533	BMW R 1200 gs (2011).pdf - 68	BMW R 1200 gs (2011).pdf - 58	Aprilia dorsoduro 750 2009 a 2011.pdf - 338
Para cambiar los frenos, es necesario tener cuidado durante el proceso. Existen tornillos sensibles a los cambios hay sistemas eléctricos y se debe realizar con bastante precaución.	Ducati Monster S2R1000.pdf - 201	Ducati Monster S2R1000.pdf - 183	Ducati Monster S2R1000.pdf - 155	Ducati Monster S2R1000.pdf - 151	Ducati Monster S2R1000.pdf - 92	Ducati Monster S2R1000.pdf - 182	Ducati Panigale (2012).pdf - 104	Ducati Panigale (2012).pdf - 361	Ducati Panigale (2012).pdf - 352
La horquilla es un componente crucial	Ducati Panigale (2012).pdf - 450	Ducati Panigale (2012).pdf - 230	Aprilia dorsoduro 750 2009 a 2011.pdf - 286	Ducati Panigale (2012).pdf - 229	Aprilia dorsoduro 750 2009 a 2011.pdf - 198	Ducati Panigale (2012).pdf - 337	Ducati Panigale (2012).pdf - 236	Ducati Monster S2R1000.pdf - 483	Aprilia dorsoduro 750 2009 a 2011.pdf - 134
Con un simple destornillador se puede realizar el cambio	Ducati Panigale (2012).pdf - 437	BMW R 1200 gs (2011).pdf - 132	Ducati Monster S2R1000.pdf - 160	Aprilia dorsoduro 750 2009 a 2011.pdf - 286	Aprilia dorsoduro 750 2009 a 2011.pdf - 70	Ducati Monster S2R1000.pdf - 201	Aprilia dorsoduro 750 2009 a 2011.pdf - 254	Ducati Panigale (2012).pdf - 119	Aprilia shiver 2007.pdf - 266
Las yamahas son mi marca favorita	Aprilia shiver 2007.pdf - 3	BMW R 1200 gs (2011).pdf - 0	Ducati Monster S2R1000.pdf - 153	Aprilia dorsoduro 750 2009 a 2011.pdf - 3	Ducati Panigale (2012).pdf - 171	Ducati Panigale (2012).pdf - 172	Ducati Panigale (2012).pdf - 173	Ducati Panigale (2012).pdf - 174	Ducati Panigale (2012).pdf - 413

¿Cómo cambio los frenos de mi moto?	1.167215	1.169381	1.170473	1.185793	1.196477	1.222061	1.224972	1.240319	1.251546
Para cambiar los frenos, es necesario tener cuidado durante el proceso. Existen tornillos sensibles a los cambios hay sistemas eléctricos y se debe realizar con bastante precaución.	0.889031	0.918616	0.952636	1.000022	1.002026	1.012007	1.018440	1.027888	1.036442
La horquilla es un componente crucial	1.305699	1.312128	1.312913	1.319132	1.322932	1.325098	1.331274	1.335787	1.336651
Con un simple destornillador se puede realizar el cambio	1.208451	1.298893	1.327201	1.343121	1.350870	1.351224	1.353400	1.355338	1.356750
Las yamahas son mi marca favorita.	1.264907	1.309361	1.375587	1.382714	1.418373	1.418373	1.418373	1.418373	1.418373

Ilustración 71 Resultados recuperación textual sobre vectores de documentos

c) Preguntas input imágenes sobre libros de texto

Las imágenes son las siguientes:



Ilustración 72 Imágenes usadas para la recuperación de textos

Recupera correctamente las 3 primeras imágenes y la última, asignando páginas del libro, además de que los valores de las distancias están en un rango similar al input de texto (es decir, **sin modality gap**). La cuarta imagen, que era un fantasma algo más genérico, no lo recupera bien.



	top_1	top_2	top_3	top_4	top_5	top_6	top_7	top_8	top_9
image_mixta_00.jpg	harrypotter_caliz.txt - 8	harrypotter_caliz.txt - 113	harrypotter_caliz.txt - 18	harrypotter_caliz.txt - 104	harrypotter_caliz.txt - 145	harrypotter_caliz.txt - 236	harrypotter_caliz.txt - 322	harrypotter_caliz.txt - 331	harrypotter_caliz.txt - 108
image_mixta_01.jpg	harrypotter_caliz.txt - 211	harrypotter_caliz.txt - 337	harrypotter_caliz.txt - 207	harrypotter_caliz.txt - 290	harrypotter_caliz.txt - 321	harrypotter_caliz.txt - 165	harrypotter_caliz.txt - 175	harrypotter_caliz.txt - 249	harrypotter_caliz.txt - 62
image_mixta_02.jpg	harrypotter_caliz.txt - 321	harrypotter_caliz.txt - 202	harrypotter_caliz.txt - 243	harrypotter_caliz.txt - 290	harrypotter_caliz.txt - 201	harrypotter_caliz.txt - 337	harrypotter_caliz.txt - 184	harrypotter_caliz.txt - 286	harrypotter_caliz.txt - 73
image_mixta_03.jpg	Ducati Monster S2R1000.pdf - 9	Ducati Monster S2R1000.pdf - 23	Ducati Monster S2R1000.pdf - 163	Ducati Monster S2R1000.pdf - 305	Ducati Monster S2R1000.pdf - 459	Ducati Monster S2R1000.pdf - 529	Ducati Monster S2R1000.pdf - 539	Aprilia dorsoduro 750 2009 a 2011.pdf - 391	Aprilia shiver 2007.pdf - 352
image_mixta_04.jpg	harrypotter_caliz.txt - 113	harrypotter_caliz.txt - 59	harrypotter_caliz.txt - 8	harrypotter_caliz.txt - 91	harrypotter_caliz.txt - 281	harrypotter_caliz.txt - 193	harrypotter_caliz.txt - 283	harrypotter_caliz.txt - 49	harrypotter_caliz.txt - 90

	top_1	top_2	top_3	top_4	top_5	top_6	top_7	top_8	top_9
image_mixta_00.jpg	1.184897	1.185266	1.255446	1.257914	1.261798	1.263046	1.271789	1.279027	1.285982
image_mixta_01.jpg	1.076116	1.125874	1.155532	1.160798	1.162968	1.164536	1.168768	1.170617	1.173225
image_mixta_02.jpg	1.178687	1.206696	1.211962	1.225386	1.231549	1.240558	1.245321	1.248253	1.256749
image_mixta_03.jpg	1.281022	1.281022	1.281022	1.281022	1.281022	1.281022	1.281022	1.367868	1.368487
image_mixta_04.jpg	1.215302	1.334133	1.339252	1.359061	1.388394	1.398513	1.399045	1.400141	1.403439

Ilustración 73 Resultados recuperación de imágenes sobre vectores de texto

d) Preguntas input imágenes sobre manuales de motos



Ilustración 74 Imágenes a recuperar

Las imágenes son bastante ambiguas, algunas de baja calidad.

image_mixta_05.jpg	Aprilia shiver 2007.pdf - 3	BMW R 1200 gs (2011).pdf - 11	Ducati Panigale (2012).pdf - 481	BMW R 1200 gs (2011).pdf - 0	BMW R 1200 gs (2011).pdf - 13	Ducati Panigale (2012).pdf - 159	Aprilia shiver 2007.pdf - 0	Aprili dorsoduro 750 2009 a 2011.pdf - 0	Ducati Panigale (2012).pdf - 36
image_mixta_06.jpg	Ducati Panigale (2012).pdf - 159	Ducati Panigale (2012).pdf - 536	Ducati Panigale (2012).pdf - 664	Ducati Panigale (2012).pdf - 860	Ducati Panigale (2012).pdf - 112	Ducati Panigale (2012).pdf - 232	Ducati Panigale (2012).pdf - 346	Ducati Panigale (2012).pdf - 359	Ducati Panigale (2012).pdf - 163
image_mixta_07.jpg	Ducati Panigale (2012).pdf - 667	Ducati Panigale (2012).pdf - 1136	Ducati Panigale (2012).pdf - 408	Ducati Panigale (2012).pdf - 1201	Ducati Panigale (2012).pdf - 1018	Ducati Panigale (2012).pdf - 860	Ducati Panigale (2012).pdf - 502	Ducati Panigale (2012).pdf - 1185	Ducati Panigale (2012).pdf - 1052
image_mixta_08.jpg	BMW R 1200 gs (2011).pdf - 161	BMW R 1200 gs (2011).pdf - 0	BMW R 1200 gs (2011).pdf - 164	BMW R 1200 gs (2011).pdf - 163	BMW R 1200 gs (2011).pdf - 165	BMW R 1200 gs (2011).pdf - 162	BMW R 1200 gs (2011).pdf - 158	BMW R 1200 gs (2011).pdf - 160	BMW R 1200 gs (2011).pdf - 11
image_mixta_09.jpg	Ducati Panigale (2012).pdf - 824	Ducati Panigale (2012).pdf - 909	Ducati Panigale (2012).pdf - 432	Ducati Panigale (2012).pdf - 681	Ducati Panigale (2012).pdf - 670	Ducati Panigale (2012).pdf - 790	Ducati Panigale (2012).pdf - 453	Ducati Panigale (2012).pdf - 1010	Ducati Panigale (2012).pdf - 1191

image_mixta_05.jpg	0.791689	0.889016	0.969417	0.976273	0.983225	1.010879	1.019765	1.029345	1.032621
image_mixta_06.jpg	0.646296	0.713414	0.713548	0.717669	0.733842	0.737165	0.739007	0.740599	0.743237
image_mixta_07.jpg	0.830426	0.844908	0.849027	0.861643	0.875732	0.877381	0.879198	0.882240	0.905695
image_mixta_08.jpg	1.194487	1.210289	1.233211	1.234856	1.235900	1.239123	1.325009	1.338409	1.352827
image_mixta_09.jpg	0.825842	0.855593	0.871356	0.872511	0.873852	0.883874	0.887059	0.892422	0.910345

Ilustración 75 Resultados recuperación de imágenes sobre vectores de documentos

Muestra **resultados positivos**, donde recupera páginas de los manuales de motos, y por ejemplo, la cuarta imagen, asocia bien el manual de BMW con la imagen de un concesionario de BMW.

PCA sobre la base de datos multimodal

Con estas pruebas se observa que **el modelo funciona bien y consigue superar el mencionado modality gap** que es una de las grandes dificultades y retos de la multimodalidad (a nivel de embedding).



Se realiza ahora una prueba más específica, y se **repite el experimento** de usar **imágenes de alta calidad de las motos** de los diferentes manuales y ver si recupera alguna de las páginas en las que aparece la moto entera o la mitad de ella al menos. Los **resultados no son buenos**, a diferencia de lo realizado en el experimento del embedding de Vertex AI.




Ilustración 76 Resultados Voyage AI en RAG imágenes sobre Documentos

A pesar de este comportamiento negativo, el modelo parece ser el que tiene **mayor potencial**, pero no se puede descartar el uso de este modelo en posteriores tareas. En este **caso concreto**, el modelo de embedding de Voyage AI **no parece el mejor**, al menos en estas pruebas.

Con el fin de entender qué sucede internamente en el modelo de embedding de VoyageAI y debido a que en otras pruebas el uso de la combinación de un input de texto y un input de imagen (se usa la media de ambos vectores ,dimensión a dimensión), se trata de ver si existen diferencias entre los vectores que vienen del formato imagen y los que vienen del formato texto. Así, en la base de datos en la que se encuentran las páginas de los PDFs de las motos (input de imagen) y las páginas de un libro de Harry Pottter (input de texto), se trata de ver si hay grandes diferencias. Para ello, se usa un PCA y se obtiene lo siguiente:




Ilustración 77 PCA sobre vectores de texto e imágenes

Y la varianza explicada por la primera componente corresponde a un 13.92%. Esto nos hace pensar que el modelo no tiene un modality gap en el sentido de que no prioriza inputs de imagen al pasarle una imagen frente a los de texto ni viceversa, pero internamente sí que se aprecia algo de modality gap (aunque “solo” retiene el 13.92% de varianza la primera componente).

3. Otros modelos multimodales

Hasta principios de 2026, continúan saliendo modelos multimodales de embedding. Se destacan 3:

- Amazon Nova Multimodal Embeddings (*Amazon Nova Multimodal Embeddings: Technical Report and Model Card Amazon Artificial General Intelligence Figure 1: Amazon Nova Multimodal Embeddings Model*, n.d.)
- Voyage-multimodal-3.5 (*Voyage-Multimodal-3.5: A New Multimodal Retrieval Frontier with Video Support – Voyage AI*, n.d.)
- Qwen-3-vl-embedding (y reranker) (Li et al., 2026)

El modelo de Amazon no pasó el primer filtro de pruebas debido al bajo rendimiento mostrado en la métrica de Visual Document Retrieval:

	Amazon Nova Multimodal Embeddings	TwelveLabs Marengo 2.7	TwelveLabs Marengo 3.0	Google Vertex AI Multimodal Embeddings	Cohere Embed 4	Amazon Titan Multimodal Embeddings	Amazon Titan Text Embeddings V2	Google Gemini Embedding
VIDEO RETRIEVAL								
ActivityNet Avg (recall@1, recall@5, recall@10)	81.2	51.0	72.6	55.7	—	—	—	—
DiDeMo Avg (recall@1, recall@5, recall@10)	80.6	64.6	65.9	54.3	—	—	—	—
AUDIO RETRIEVAL								
AudioCaps Avg (recall@1, recall@5, recall@10)	69.9	54.3	52.0	—	—	—	—	—
VISUAL DOCUMENT RETRIEVAL								
ViDoRe V2 nDCG@5	58.7	—	—	—	53.6	—	—	—
IMAGE RETRIEVAL								
MSCOCO Avg (recall@1, recall@5, recall@10)	76.7	78.9	71.3	70.1	22.9	74.8	—	—
TextCaps Avg (recall@1, recall@5, recall@10)	88.9	75.7	89.2	*	69.7	84.7	—	—
TEXT RETRIEVAL								
MTEB (Multilingual) nDCG@10	63.8	—	*	—	61.6	—	58.3	67.7 ¹

Ilustración 78 Comparativa en diferentes benchmarks proporcionada por Amazon

En el caso del modelo de Qwen-3-vl-embedding, se hicieron algunas pruebas con el modelo de 2B, pero las dificultades técnicas de dichos modelos impidieron continuar las pruebas.

Para el modelo de Voyage, que era una mejora del anterior modelo multimodal del que sí se tenía mayor volumen de pruebas, se tiene la siguiente información técnica([Multimodal Embeddings](#)):

- Posibilidad de incluir hasta 1000 inputs diferentes (texto + imagen + texto + imagen + ...).
- Cada imagen no debe pesar más de 20MB o 16M de píxeles.
- Cada vídeo no debe ser más largo de 20MB.
- Cada elemento de la lista no debe superar 32K tokens, siendo el máximo de los inputs 320K.
- Uno de los parámetros del modelo es input_type, que puede ser Sin especificar, Query o Documents. Para el caso de Query, simplemente se le pasa como input el texto: “Represent the query for retrieving supporting documents:” y para Documents “Represent the document for retrieval.”






Ilustración 79 Comparativa de modelos en RAG de Documentos Visuales hecha por Voyage AI




Ilustración 80 Comparativa de modelos en la Recuperación Textual proporcionada por Voyage AI


Las métricas reportadas por Voyage mejoran consistentemente Amazon Nova 2 tanto en tareas puramente de texto como en documentos visuales, al igual que al anterior modelo de voyage-multimodal-3.

En estos modelos se han realizado experimentos no concluyentes y por ello no se reflejan ningún resultado en forma de representación o métrica.



4. Gemini embedding 2

El modelo de Gemini (*Gemini Embedding 2: Our First Natively Multimodal Embedding Model*, n.d.) permite como **inputs texto, imágenes, audio, vídeo** (incluyendo audio) y **pdf** (nativamente). Las dimensiones de los vectores son de **3072**, pero permite también la **reducción MRL a 1536 o 768** de dimensión.



Tiene **limitaciones** de tokens, concretamente **8.192 tokens** y también del:

- Número de **imágenes** : **6**
- Longitud de **vídeo**: **80 segundos con audio** y 120 sin audio
- Longitud de **audio**: **80 segundos**
- **Páginas** de documentos **pdf**: **6**

Especificaciones técnicas	Imágenes	• Cantidad máxima de imágenes por instrucción: 6 • Tamaño máximo de archivo por archivo para datos intercalados o cargas directas a través de la consola: Sin límite • Tamaño máximo de archivo por archivo de Google Cloud Storage: Sin límite • Cantidad máxima de imágenes de salida por instrucción: N/A • Tipos de MIME admitidos: <code>image/png</code>, <code>image/jpeg</code>
	Documentos	• Cantidad máxima de archivos por instrucción: 1 • Cantidad máxima de páginas por archivo: 6 • Tamaño máximo del archivo: N/A • Tipos de MIME admitidos: <code>application/pdf</code>
	Video	• Duración máxima del video (con audio): 80 segundos • Duración máxima del video (sin audio): 120 segundos • Cantidad máxima de videos por instrucción: 1 • Tipos de MIME admitidos: <code>video/mpeg</code>, <code>video/mp4</code>
	Audio	• Duración máxima de audio por instrucción: 80 segundos • Cantidad máxima de archivos de audio por instrucción: 1 • Tipos de MIME admitidos: <code>audio/mp3</code>, <code>audio/wav</code>
	Valores predeterminados de los parámetros	

Ilustración 81 Especificaciones técnicas de Gemini Embedding 2

Respecto al modelo, Google reporta una **mejora respecto a sus competidores** (Voyage Multimodal 3.5 y Amazon Nova 2 Multimodal Embeddings).

Debido a la novedad de las modalidades de audio y vídeo (que incluye audio), además del pdf de manera nativa, se realiza un experimento inicial que trate de verificar lo que enuncian los reportes y benchmarks mostrados. Previo a este experimento, se debe realizar un pipeline que:



- Transforme cada pdf de más de 6 páginas en pdfs más pequeños, de máximo 6 páginas. En una primera fase, se dividirán el pdf inicial en pdfs de 6 páginas con un overlap de 1 páginas, es decir, un pdf de 13 páginas se dividirá en 3 pdfs de páginas 1-6, 6-11 y 11-13.
- Transforme cada vídeo y audio de duración mayor a 60 segundos en clips de 60 segundos, con overlap del 10%, es decir, 6 segundos. Por ejemplo, un clip de 2 minutos 30 segundos se transforma en clips de los segundos 0 a 60, 54 a 114, 108 a 150.

Otro aspecto técnico con relevancia, en analogía con lo que ofrecía el modelo voyage, se puede decir el tipo de tarea a realizar, entre las que destacan *RETRIEVAL_DOCUMENT* para almacenar los vectores en una base de datos, y *RETRIEVAL_QUERY* para recuperar dicho vector por similarity search.

Se propone realizar un **experimento** en el cual se incluyan en la **base de datos** todas las modalidades salvo el texto, es decir, **audio, vídeo, imagen y pdf** “nativo”, y se le hagan **preguntas** (queries) en formato **solo texto**. Para evitar entrar en conflicto en preguntas que puedan ser respondidas por varios modos, se toma **para cada modalidad alguna temática lo más independiente de las anteriores**:

- Vídeo
 - Clips de Vídeo sobre biología y el uso de psicodélicos
 - Clips de 2 vídeos con goles de fútbol
- PDF
 - Páginas de 3 PDFs relacionados con fondos de inversión
 - Páginas de 1 PDF con explicación sobre reparación de motos
- Audio
 - Clips de Audio sobre Redes Neuronales Convolucionales
 - Clips de Audio de Antropología Filosófica
- Imágenes
 - Imágenes de platos de comida mundiales

Como ya se ha mencionado, las queries de texto servirán para verificar si las recupera correctamente. Las preguntas serán:



```
lista_queries = [
    # Psicodélicos (material audiovisual)
    "¿Qué sustancias psicodélicas se mencionan explícitamente (LSD, psilocibina, DMT, mescalina) y en qué contexto se describe cada una?",
    "Extrae afirmaciones sobre efectos a corto plazo y sepáralas por categorías: perceptivos, emocionales y cognitivos.",
    "¿Qué advertencias de riesgo aparecen sobre dosis, set and setting, contraindicaciones o salud mental previa?",

    # Goles de fútbol (material audiovisual)
    "Identifica acciones de gol y clasifícalas por tipo de finalización: remate de cabeza, disparo lejano, mano a mano, penalti o falta.",
    "¿Qué equipos o selecciones se pueden reconocer por narración, marcador, camisetas o contexto visual?",
    "Resume cada gol con la secuencia táctica inmediatamente anterior: recuperación, pase clave, desmarque y definición.",

    # PDFs de fondos de inversión
    "¿Qué tipologías de fondos aparecen (renta fija, variable, mixtos, indexados) y qué perfil de inversor se asocia a cada una?",
    "Extrae métricas financieras mencionadas (volatilidad, TER/comisiones, horizonte temporal, drawdown, rentabilidad histórica) con sus valores.",
    "¿Qué criterios de selección se recomiendan para comparar fondos y qué umbrales o reglas concretas se proponen?",

    # PDF de reparación de motos
    "¿Cuál es el procedimiento de diagnóstico paso a paso para fallos de arranque, encendido o alimentación?",
    "Lista piezas y sistemas mencionados (batería, bujía, carburación/inyección, transmisión, frenos) e indica síntomas asociados.",
    "¿Qué herramientas y pares de apriete, si aparecen, se especifican para mantenimiento preventivo o correctivo?",

    # Audio sobre CNN
    "Define la arquitectura CNN descrita: tipo y orden de capas (conv, pooling, batch norm, dense, softmax).",
    "¿Qué hiperparámetros se mencionan (kernel size, stride, padding, learning rate, batch size, epochs) y con qué propósito?",
    "Resume casos de uso citados para CNN y el tipo de dato de entrada en cada caso (imagen médica, visión industrial, etc.).",

    # Audio de Antropología Filosófica
    "¿Qué tesis sobre la naturaleza humana se presentan y qué conceptos clave las sostienen?",
    "Identifica autores o corrientes mencionadas y vincula cada una con su idea central sobre persona, libertad o cultura.",
    "Extrae contrastes explícitos entre perspectivas (biologicista, existencial, personalista, materialista) y su argumento principal.",

    # Imágenes de comida
    "¿Qué categorías gastronómicas predominan (plato principal, entrante, postre, bebida) y con qué evidencias visuales?",
    "Infiera ingredientes probables visibles (proteínas, vegetales, salsas, cereales) indicando nivel de certeza por elemento.",
    "¿Qué técnicas culinarias se pueden deducir por la apariencia (frito, horneado, asado, cocción al vapor) y qué señales lo sugieren?"
]
```

Ilustración 82 Ejemplo de queries en texto para las distintas temáticas-modos

Con este experimento, el resultado objetivo sería obtener, para cada trío de preguntas textuales, vectores referentes a la temática preguntada.

En total, se tiene un dataset de 121 vectores en total. Al vectorizar las queries listadas, el top 10 de resultados en todas las consultas (salvo 1) **recupera vectores del modo audio**, aunque no sean queries pensadas para dicha tarea. Los resultados en audio son correctos:

```
Resultados para la consulta: 'Define la arquitectura CNN descrita: tipo
Score: 0.6248 | data_type: audio | !Redes Neur_clip_013_audio.mp3
Score: 0.6118 | data_type: audio | !Redes Neur_clip_009_audio.mp3
Score: 0.5943 | data_type: audio | !Redes Neur_clip_006_audio.mp3
```

```
Resultados para la consulta: '¿Qué tesis sobre la naturaleza humana se
Score: 0.6528 | data_type: audio | Que es la Antro_clip_004_audio.mp3
Score: 0.6403 | data_type: audio | Que es la Antro_clip_002_audio.mp3
Score: 0.6300 | data_type: audio | Que es la Antro_clip_003_audio.mp3
```

Ilustración 83 Ejemplo RAG textual sobre audio

Esto **no es** algo **positivo**, pero viendo este proceso, se procede a **prescindir de los vectores de audio** del dataset y ver cómo es la recuperación sin ellos. En este caso, sí se recuperan correctamente los documentos de las temáticas mencionadas (salvo en las imágenes, que es donde no es tan consistente). A modo ilustrativo:

```
Resultados para la consulta: '¿Qué sustancias psicodélicas se menciona
Score: 0.5202 | data_type: audio | Que es la Antro_clip_001_audio.mp3
Score: 0.5131 | data_type: audio | Que es la Antro_clip_002_audio.mp3
Score: 0.5097 | data_type: audio | !Redes Neur_clip_014_audio.mp3
```

```
Resultados para la consulta: '¿Qué sustancias psicodélicas se me
Score: 0.4886 | data_type: video | PSICODELICOS en_clip_000.mp4
Score: 0.4834 | data_type: video | PSICODELICOS en_clip_001.mp4
Score: 0.4763 | data_type: video | PSICODELICOS en_clip_010.mp4
```

Ilustración 86 Ejemplo RAG textual sobre vídeo con y sin audio

```
Resultados para la consulta: '¿Qué tipologías de fondos aparecen (renta
Score: 0.5351 | data_type: audio | !Redes Neur_clip_014_audio.mp3
Score: 0.5292 | data_type: audio | Que es la Antro_clip_002_audio.mp3
Score: 0.5185 | data_type: audio | !Redes Neur_clip_002_audio.mp3
```

```
Resultados para la consulta: '¿Qué tipologías de fondos aparecen (renta fija,
Score: 0.4324 | data_type: pdf | Avantage Fund FI(16-21).pdf
Score: 0.4289 | data_type: pdf | Diversificación y Alfa Estructural(6-11).pdf
Score: 0.4273 | data_type: pdf | Avantage Fund FI(11-16).pdf
```

Ilustración 85 Ejemplo RAG textual sobre pdfs con y sin audio

```
Resultados para la consulta: 'Infiera ingredientes probables visibles (proteínas
Score: 0.5353 | data_type: audio | !Redes Neur_clip_014_audio.mp3
Score: 0.5182 | data_type: audio | !Redes Neur_clip_003_audio.mp3
Score: 0.5151 | data_type: audio | !Redes Neur_clip_013_audio.mp3
```

```
Resultados para la consulta: 'Infiera ingredientes probables visibles (proteínas
Score: 0.3449 | data_type: image | Pho_00001.jpg
Score: 0.3369 | data_type: pdf | Return Stacked Offroad Report(11-16).pdf
Score: 0.3314 | data_type: image | Stir-fried Noodles_00070.jpg
```

Ilustración 84 Ejemplo de RAG textual sobre imágenes con y sin audio

Cabe destacar que los resultados de distancias (se usa la distancia coseno) también cuentan con cierta interpretación. Para el caso de los audios, tienen una distancia

CONFIDENCIAL

más elevada que el resto. Concretamente, si se estudian exclusivamente el top 3 de las queries relacionadas con las temáticas de audio, se obtienen como valor máximo 0.62, valor mínimo 0.586 y 0.615 de media.

En cambio, tal como se observan ya en los ejemplos sobre vídeo, pds e imágenes, estos valores se reducen (para todos los ejemplos, oscilan entre 0.56 y 0.44 el top 3).

Por otra parte, si se excluyen el audio de la base de datos, los valores del top 3 oscilan entre 0.488 y 0.326, siendo el promedio 0.399 y los recupera adecuadamente por temática (salvo en las imágenes, como muestra *Ilustración 84 Ejemplo de RAG textual sobre imágenes con y sin audio* recupera un pdf en la segunda posición).

Si realizamos un PCA sobre los vectores de la base de datos, junto con los vectores de texto, se obtienen:




Ilustración 87 Gráfico de las 2 primeras componentes del PCA según modalidad

Como era de esperar, se observa que para la componente 1, los vectores de audio y de texto están muy cercanos, y esto puede indicar la problemática mencionada anteriormente. Las dos componentes principales absorben respectivamente el 20.73% y el 11.2% de la varianza total.






Ilustración 88 Gráfico de las 2 primeras componentes del PCA según modalidad-temática

Se observa a su vez separación entre vectores de vídeo y esto se debe a la temática (Psicodélicos diferenciado de los de fútbol Top 10 y Unforgett). También en audio (Qué es la antropología frente a ¡Redes N se agrupan por temática), e incluso en pdf los manuales de motos frente a los otros 3 pdfs de inversión.

En el caso de la representación UMAP, se obtienen resultados similares:




Ilustración 89 Gráfica de UMAP según modo

Y de manera más clara sucede de nuevo la diferencia en los vídeos (psicodélicos alejados de los de fútbol), los audios separados, y los pdfs de inversión frente al de motos.




Ilustración 90 Gráfica de UMAP según modo-temática


A pesar de que estas representaciones gráficas, sobre todo la última, sugieren que puede haber un **modality gap** claro respecto al audio-texto, es necesario recalcar dos aspectos relevantes:

- 1) La **naturaleza del experimento** parece favorecer este comportamiento (**temáticas muy distintas** entre modos). De hecho, dentro de la imagen, son todas de la misma temática y se encuentran juntas, en cambio en el caso de videos, pdfs y audios, había 2 subdivisiones temáticas, que parecen reflejarse en la dimensiones
- 2) Las **distancias** que se muestran en los ejemplos no son tan “extremas” como parecen indicar los gráficos de reducción de la dimensionalidad: para el top 3 de la distancia, el **audio aparece priorizado** (en torno a 0.58 en su temática y 0.49 en otras temáticas; mientras que los resultados correctos están en el entorno de 0.4), pero no de manera tan notable como en experimentos pasados (donde aparecía una diferencia 3:1), en este caso **no supera el doble en ninguno de los casos**.

Modelos generadores

Los modelos de generación multimodales se encuentran en una fase temprana de desarrollo y cuentan con ciertas limitaciones. Por ejemplo, la mayoría de estos modelos tienen solamente un tipo de output, que suele ser texto, imagen, audio o vídeo, pero no una combinación de estos.

Para el caso concreto de los vídeos, se hicieron pruebas con el modelo gemini-2.0-flash desde la plataforma de google AIStudio. Se le pasa un vídeo de análisis de depósitos, cuentas corrientes y fondos monetarios; y se le pregunta sobre cuestiones que aparecen en el vídeo, tanto en formato de imagen como de audio. Para ello, se realiza la pregunta en cuestión, y si la respuesta no es correcta, se le informa en formato texto en qué parte del vídeo puede estar:



Mejores depósitos, Cuentas corrientes, Letras del tesoro, Fondos Monetarios

Ideas con monetarios y ETFs monetarios. Comisiones hasta 0,15%

ISIN	FONDO O ETF	NOMBRE Fondo/ETF	COSTES (TER MORNINGSTAR)	RENDIMIENTO ULTIMO MES (MORNINGSTAR)	RENDIMIENTO ULTIMOS 3 MESES (MORNINGSTAR)	RENDIMIENTO ULTIMOS 12 MESES (MORNINGSTAR)	LIQUIDEZ, TAMAÑO (MM) MAR 25 (MORNINGSTAR)	CALIDAD DEL CREDITO (FONDO)	DURACION/MADEUREZ (FONDO)	POSICIONES (FONDO O MORNINGSTAR)	REPORTE PERSONAL (JOSAN)
LU0000227943	Fondo	DWS Euro Ultra Short Fixed Income Fund	0,15%	0,33%	0,88%	4,27%	745,11	A	180	238	85/100
ES0270156048	Fondo	SANTALUCIA RENTA FIJA CORTO PLAZO EURO, FI	0,14%	0,46%	0,90%	4,32%	231,6	BBB	306	53	80/100
FR0000447823	Fondo	AXA Trésoir Court Terme Capitalization EUR	0,05%	0,24%	0,79%	3,71%	1124	A+	75	195	80/100
FR0000991390	Fondo	La Française Trésorerie ISR R	0,17%	0,24%	0,75%	3,61%	2974	A2	120	84	75/100
FR0000909626	Fondo	Groupama Trésorerie IC	0,11%	0,25%	0,78%	3,74%	7718	A	14,6	130	85/100
LU0000855873	Fondo	Aberdeen Standard Liquidity Fund - Euro Fund	0,17%	0,23%	0,70%	3,49%	4226	A+	35	97	80/100
Promedio			0,15%	0,30%	0,80%	3,86%	17000,71				



Suma

BE0000104462	ETF	JPMorgan EUR Ultra-Short Income UCITS ETF - EUR (Acc)	0,18	0,42%	0,88%	4,80%	922	A+	180	162	70/100
LU0226305497	ETF	Xtrackers II EUR Overnight Rate Swap UCITS ETF	0,10%	0,21%	0,73%	3,56%	15386	TRIS Deutsche Bank Euro Overnight Rate	1	25 SWAP	85/100
LU1130417899	ETF	Lycor Smart Overnight Return UCITS ETF C-EUR	0,05%	0,28%	0,88%	3,90%	7353	TRIS Selective Euro Overnight Return TR EUR Index	163	25 SWAP	80/100
IE000810Y0R4	ETF	iShares EUR UltraShort Bond UCITS ETF EUR (Acc)	0,09%	0,36%	0,87%	3,98%	4092	AA	161	524	70/100
FR0000510600	ETF	Amondur EUR Overnight Return UCITS ETF Acc CSH	0,10%	0,25%	0,75%	3,52%	2238	AA			
Promedio			0,10%	0,30%	0,82%	3,79%	29991				

Herramienta Recortes

Captura de pantalla copiada en el portapapeles. Guardado automáticamente en la carpeta de capturas de pantalla.

La primera respuesta es incorrecta. A pesar de obtener una respuesta en el segundo intento, esta respuesta no es buena y se inventa parte de la respuesta. En preguntas continuadas, sigue inventando las cifras:



Como se observa, estos modelos no están preparados para el análisis de vídeo donde aparecen tablas con números.

7. Análisis Crítico y Discusión

Mientras que la sección 6 presentó los resultados experimentales de forma descriptiva, esta sección los somete a un escrutinio crítico que persigue tres objetivos: en primer lugar, interpretar los hallazgos en el contexto de la teoría y la literatura revisadas en las secciones 2 y 5; en segundo lugar, identificar las fortalezas y las debilidades del pipeline implementado con la honestidad necesaria para orientar las decisiones de las fases siguientes del proyecto; y en tercer lugar, situar los resultados de EMIE dentro del panorama del estado del arte para calibrar su significatividad real. La discusión se organiza en siete apartados que avanzan desde la síntesis de hallazgos hasta las recomendaciones técnicas concretas.

7.1 Síntesis de hallazgos experimentales

Antes de entrar en la discusión propiamente dicha, es necesario consolidar los resultados principales de la experimentación en una visión unificada que permita identificar patrones transversales. Los experimentos se ejecutaron sobre cuatro escenarios de complejidad creciente, dos modelos de embedding multimodal y dos versiones del modelo generador, produciendo un volumen considerable de observaciones que, tomadas individualmente, pueden parecer dispares pero que, analizadas en conjunto, revelan varias conclusiones estructurales.

La primera conclusión estructural es que **la estrategia de página-como-imagen es viable para RAG multimodal sobre documentación técnica**, pero su rendimiento varía significativamente según el modelo de embedding y el tipo de consulta. Vertex AI multimodalembd@001 demostró una capacidad notable para reconocer texto dentro de imágenes (validado en el Escenario 1 con imágenes de perros y en el Escenario 3 con PDFs), y alcanzó tasas de recuperación competitivas en el escenario cuasi-industrial de manuales de motos (68.2% Recall@1, 81.8% Recall@3, 86.4% Recall@5). Voyage AI voyage-multimodal-3, a pesar de su liderazgo en benchmarks publicados (MIEB) y de presentar un modality gap más moderado, obtuvo resultados significativamente inferiores en la tarea de identificación visual de motos (22.7% Recall@1, 40.9% Recall@3, 45.5% Recall@5).

La segunda conclusión estructural es que **el modality gap existe y es medible en ambos modelos**, pero se manifiesta de formas diferentes. En Vertex AI, el gap se expresó como una diferencia de distancia de 3:1 (1.65 vs 0.54) cuando el mismo contenido se consultaba como texto frente a como imagen. En Voyage AI, el análisis PCA reveló una separación parcial con un 13.92% de varianza explicada por la primera componente principal, un gap estructuralmente presente pero más moderado que el de Vertex AI.

La tercera conclusión estructural es que **la calidad del RAG determina directamente la calidad de la generación**, con una diferencia cualitativa dramática entre las tres condiciones evaluadas. Sin RAG, las respuestas de Gemini eran genéricas y no específicas del documento. Con RAG erróneo, las respuestas citaban documentos incorrectos con aparente seguridad, generando un riesgo potencial de desinformación. Con RAG exitoso, las respuestas eran específicas, referenciaban páginas concretas y proporcionaban procedimientos operativos detallados.

La cuarta conclusión estructural atañe a la integración nativa de modalidades dinámicas (audio y vídeo) y su impacto en el espacio latente, evaluada específicamente con el modelo gemini-embedding-2. Los experimentos revelaron un problema de "dominancia modal" imprevisto: al incluir audios y vídeos nativos junto con imágenes y PDFs en la base de datos vectorial, las consultas de texto recuperaron predominantemente vectores de la modalidad de audio en el Top-10, independientemente del objetivo semántico de la consulta. El análisis de componentes principales (PCA) confirmó esta anomalía, mostrando una excesiva proximidad y solapamiento entre los vectores de audio y texto en la primera componente (20.73% de varianza explicada). Esto indica que, si bien la capacidad de indexar audio y vídeo de forma nativa representa un avance técnico reseñable frente a arquitecturas previas, el espacio latente multimodal de este modelo aún carece del equilibrio necesario para evitar que ciertas modalidades "parasiten" a otras en un entorno de recuperación puramente *cross-modal* (consulta de texto hacia un corpus mixto), forzando, por el momento, a prescindir de la modalidad de audio para estabilizar la recuperación de las demás. Por consiguiente, se deberá estudiar en mayor profundidad si la implementación de este modelo resulta conveniente frente a otras alternativas para aquellos casos de uso concretos donde la modalidad de audio no tenga cabida.

Dimensión	Vertex AI multimodalembding@001	Voyage AI voyage- multimodal-3	Observación clave
Recall@1 motos	68.2% (15/22)	22.7% (5/22)	Vertex AI claramente superior en identificación visual
Recall@5 motos	86.4% (19/22)	45.5% (10/22)	La brecha se mantiene en top-5
Modality gap (distancia)	1.65 texto vs 0.54 imagen (ratio 3:1)	Gap moderado (PCA 13.92%)	Vertex AI: gap grande pero buen retrieval visual
OCR implícito en PDFs	Bueno en general, falla en nombres propios	Bueno para texto+imagen intercalado	Ambos capturan semántica de texto en imagen
Dimensión del vector	1.408 (máx)	1.024 (fija)	Mayor dimensión en Vertex AI
Límite texto input	1.024 caracteres (~32 tokens)	32.000 tokens	Voyage AI mucho más flexible para texto largo
Input intercalado	No soportado	Sí (texto+imagen en 1 vector)	Ventaja arquitectónica de Voyage AI

Tabla 4 Síntesis comparativa de los resultados experimentales de ambos modelos de embedding multimodal.

7.2 El modality gap como factor determinante del rendimiento cross-modal

El hallazgo técnico más importante de los experimentos es la confirmación empírica del modality gap y su impacto directo sobre la calidad de la recuperación cross-modal. Este resultado no es sorprendente a la luz de la teoría – Liang et al. (2022)



predijeron exactamente este comportamiento – pero su cuantificación en el contexto específico de documentos técnicos indexados como imágenes aporta evidencia original que complementa los resultados publicados.

Interpretación del gap en Vertex AI

La observación de que el mismo contenido produce una distancia de 0.54 cuando se consulta como imagen pero de 1.65 cuando se consulta como texto es una manifestación directa del fenómeno descrito por Liang et al.: los embeddings de imagen y los embeddings de texto habitan regiones separadas del espacio, y las distancias **intra-modalidad** son sistemáticamente menores que las distancias **inter-modalidad** para el mismo contenido semántico. En términos prácticos, esto significa que cuando un usuario formula una consulta textual, los resultados del retrieval están sesgados hacia documentos que fueron indexados como texto (si los hubiera) frente a documentos indexados como imagen, incluso cuando estos últimos contienen exactamente la información buscada.

Este sesgo explica algunos de los fallos observados en los experimentos. El caso más ilustrativo es la consulta "*¿Quién es Bradley Jacobs?*", donde el nombre aparecía textualmente en dos páginas del PDF, pero el sistema no las recuperó en las primeras posiciones. La hipótesis más plausible es que el embedding textual de la consulta (generado por el encoder de texto) buscaba vectores en la región textual del espacio, mientras que las páginas estaban indexadas como imágenes y sus vectores residían en la región visual, a una distancia inter-modal estructuralmente mayor que la que existiría si las páginas se hubieran indexado como texto.


Paradójicamente, este mismo modelo obtuvo los mejores resultados en la tarea de identificación visual de motos, donde las consultas eran imágenes y los documentos también estaban indexados como imágenes. En este escenario, la búsqueda opera **dentro de la misma modalidad** (imagen → imagen), evitando el modality gap. Las distancias observadas en estas consultas fueron significativamente menores (1.2-1.3 frente a 1.7-1.9 para consultas texto → imagen), confirmando que la similitud intra-modal es más discriminativa que la inter-modal.

La paradoja de Voyage AI: menos gap, peor retrieval visual

El resultado más contraintuitivo de los experimentos es que Voyage AI, a pesar de presentar un modality gap más moderado (13.92% de varianza en PC1, distancias cross-modal en rangos similares a las intra-modal), obtuvo rendimientos significativamente inferiores en la tarea de identificación visual de motos. Este resultado obliga a cuestionar la asunción simplista de que "*menos modality gap = mejor retrieval cross-modal*".

Una explicación plausible reside en la distinción entre **alineamiento global** y **capacidad perceptual específica**. El modality gap mide una propiedad geométrica global del espacio de embedding: la separación media entre las distribuciones de vectores de imagen y texto. Pero la calidad del retrieval depende también de la capacidad del encoder para capturar detalles finos dentro de cada modalidad. Es posible que Vertex AI, a pesar de tener un gap mayor, posea un encoder visual con mayor capacidad de discriminación perceptual para distinguir entre imágenes

visualmente similares (como diferentes motocicletas de marcas distintas). Voyage AI, al optimizar para minimizar el gap y para procesar inputs intercalados texto+imagen, podría haber sacrificado parte de esa discriminación visual fina. Esta interpretación es coherente con el análisis teórico alternativo de Schrodì et al. (2024), que investigaron el papel del desbalance informativo entre modalidades en la formación del gap. Los autores sugieren que el gap puede actuar como un mecanismo regulador que preserva información específica de cada modalidad que se perdería si el alineamiento fuera perfecto. En otras palabras, un cierto grado de separación modal puede ser **funcionalmente útil** porque protege representaciones discriminativas que son específicas de la modalidad visual o textual. Forzar un alineamiento perfecto podría producir representaciones más "genéricas" pero menos capaces de discriminar dentro de cada modalidad.



Análisis teórico alternativo del modality gap como consecuencia del desbalance informativo entre modalidades. Fuente: Dai et al. (2024).




Ilustración 91 Distribución acumulada de similitudes coseno entre pares positivos imagen-texto, mostrando la mejora de alineamiento de AlignCLIP frente a CLIP original. Fuente: AlignCLIP (ICLR 2025).

Reducción del gap en gemini embedding 2

A pesar de que se ha observado en la base de datos multimodal de temáticas independientes, la modalidad audio y texto están más relacionadas que el resto; y que en la reducción de dimensión tienden a encontrarse agrupadas las mismas temáticas, no siempre es así (véase en el vídeo por ejemplo).

Además, relación audio-texto no es tan diferente, y entre temáticas de distintas modalidades también existen claras diferencias, como en la representación de UMAP. Por lo tanto, habrá que explorar y ajustar dichos detalles al caso de uso concreto para obtener un RAG satisfactorio.

CONFIDENCIAL

Implicaciones para el diseño del pipeline

La discusión anterior sugiere que la selección del modelo de embedding para un sistema MRAG no debe basarse únicamente en métricas globales de alineamiento o en posiciones de benchmark, sino que debe considerar la **tarea específica** y el **patrón dominante de consulta**. Si el caso de uso principal es texto → imagen (el usuario pregunta en texto y la evidencia está en páginas-imagen), entonces el modality gap es el factor limitante y deberían priorizarse modelos con gap reducido o implementarse estrategias de mitigación post-hoc. Si el caso de uso principal es imagen → imagen (el usuario aporta una foto y se buscan documentos con imágenes similares), entonces la capacidad de discriminación visual intra-modal es más importante que el alineamiento global.

En el contexto de EMIE, ambos patrones son relevantes: el caso Iberdrola es predominantemente texto → imagen/tabla (el usuario pregunta sobre documentación), mientras que el caso de mantenimiento puede involucrar imagen → imagen (el técnico fotografía una pieza y busca el manual correspondiente). Esta dualidad sugiere que la arquitectura óptima podría combinar diferentes modelos o estrategias de retrieval según el tipo de consulta, una línea que se retoma en las recomendaciones de la sección 7.7.

7.3 Evaluación crítica de la estrategia página-como-imagen

La estrategia de indexar cada página de PDF como imagen es la decisión de diseño más determinante del pipeline experimental, y los resultados permiten una evaluación matizada de sus fortalezas y debilidades.

Fortalezas confirmadas

La primera fortaleza confirmada es la **simplicidad radical del pipeline**. Frente a las cadenas de procesamiento descritas en ColPali – que incluyen OCR, detección de layout, extracción de tablas, captioning de imágenes, serialización y chunking –, la estrategia de página-como-imagen reduce todo a una operación: rasterizar la página y generar un embedding. Esta simplicidad no es solo una ventaja estética; reduce los puntos de fallo, facilita el mantenimiento, y hace el sistema más predecible. En un contexto empresarial como el de EMIE, donde los documentos pueden tener formatos muy heterogéneos (manuales técnicos, informes corporativos, diagramas de despiece, tablas de especificaciones), evitar un pipeline de extracción frágil tiene valor operativo real.

La segunda fortaleza es la **captura nativa de información visual y de layout**. Los experimentos confirmaron que los modelos de embedding son capaces de codificar no solo el texto presente en las páginas sino también el contenido gráfico: las consultas de imagen sobre imágenes (Escenario 3, PDFs financieros) produjeron las distancias más bajas (1.2-1.3), indicando que el encoder visual captura efectivamente el contenido visual de las páginas. Además, el experimento de comparación de páginas con diferente formato (fuente, color, fondo) en Vertex AI mostró que el modelo codifica características visuales del layout que van más allá del contenido textual.



Debilidades identificadas

La debilidad más significativa es la **fragilidad de la recuperación textual específica**. El caso "*¿Quién es Bradley Jacobs?*" demostró que cuando la consulta busca un nombre propio o una cadena textual específica que aparece literalmente en el documento, el sistema puede fallar porque el embedding visual de la página no codifica el texto con la misma granularidad léxica que un embedding textual directo. Este tipo de fallo es especialmente preocupante para el caso de uso Iberdrola, donde las consultas pueden referenciar nombres de componentes, códigos de referencia, números de procedimiento u otros identificadores textuales que requieren matching léxico preciso.

Esta observación es coherente con los resultados de ColPali, que demostró que la estrategia de late interaction multi-vector supera a los enfoques single-vector precisamente porque permite matching fino a nivel de parche: cada token de la query puede encontrar su parche correspondiente en la imagen del documento. En un enfoque single-vector como el de EMIE, toda la información de la página se comprime en un único vector, lo que inevitablemente produce una pérdida de granularidad léxica. Las similarity maps de ColPali ilustran visualmente esta capacidad: ante la query "*hourly*", el modelo identifica no solo la palabra escrita sino también el eje X de un gráfico temporal que representa horas, demostrando una comprensión semántica que va más allá del OCR.




Ilustración 92 Similarity maps de ColPali: el late interaction permite localizar información visual y textual a nivel de parche dentro de la página. Fuente: Faysse et al. (ICLR 2025).

La segunda debilidad es la **granularidad limitada a nivel de página**. Cuando la evidencia necesaria es un párrafo, una celda de una tabla o un detalle de una imagen, el sistema recupera la página completa y delega al generador la tarea de localizar el elemento relevante. Esto funciona razonablemente bien cuando el generador tiene buena capacidad de comprensión visual (como se observó con Gemini en el Escenario 4), pero introduce una dependencia fuerte del generador que podría degradarse en documentos más densos o complejos.




Ilustración 93 Resultados comparativos de retrieval multimodal con y sin dependencia de OCR en documentos reales. Fuente: Wasserman et al. (ACL 2025).

7.4 Limitaciones de los modelos generadores en comprensión visual de datos estructurados

Los experimentos con Gemini 2.0 Flash sobre vídeo revelaron una limitación que merece discusión específica por su relevancia para los casos de uso industriales de EMIE: la **incapacidad del modelo para extraer datos numéricos precisos de tablas presentadas en formato visual**. Cuando se le proporcionó un vídeo con tablas de fondos de inversión y se le preguntó por cifras específicas (rentabilidades a 3 y 12 meses de fondos concretos), el modelo produjo valores inventados de forma consistente. Incluso después de recibir feedback explícito indicando la ubicación exacta de la información dentro del vídeo y correcciones parciales, continuó fabricando cifras para los valores que no podía leer con precisión. Este comportamiento no se corrigió a lo largo de múltiples turnos de diálogo, lo que descarta la explicación de un simple error aislado y apunta hacia una limitación sistémica.

Este hallazgo es coherente con resultados recientes publicados en la literatura. El benchmark Chart-MRAG Bench (Yang et al., 2025) evaluó modelos MLLM de última generación en tareas de RAG basadas en gráficos y documentó tres hallazgos críticos que resuenan directamente con las observaciones de EMIE. En primer lugar, los métodos de retrieval basados en embeddings multimodales unificados (como los utilizados en EMIE) **tienen dificultades en escenarios basados en gráficos y tablas**. En segundo lugar, incluso proporcionando al modelo las evidencias correctas (*ground-truth retrieval*), los mejores MLLMs solo alcanzaron un **58.19% de corrección** y un **73.87% de cobertura** en las respuestas generadas. En tercer lugar, los MLLMs exhiben un **sesgo consistente a favor de la modalidad textual sobre la visual** durante el razonamiento sobre información multimodal combinada: cuando

hay conflicto o ambigüedad entre la información visual y la textual, el modelo tiende a confiar más en el texto.




Ilustración 94 Resultados de Chart-MRAG Bench: incluso con retrieval perfecto, los MLLMs solo alcanzan 58% de corrección en escenarios con gráficos. Fuente: Yang et al. (2025).

Esta limitación se enmarca dentro del problema más amplio de las **alucinaciones multimodales** en modelos de visión-lenguaje. El survey de Liu et al. (2024), "A Survey on Hallucination in Large Vision-Language Models", clasifica las alucinaciones de LVLMs en tres categorías principales: alucinaciones de objeto (el modelo describe objetos inexistentes en la imagen), alucinaciones de atributo (asigna propiedades incorrectas a objetos existentes) y alucinaciones de relación (describe relaciones incorrectas entre objetos). Los fallos observados en EMIE corresponden predominantemente a **alucinaciones de atributo**: el modelo identifica correctamente que la tabla existe y qué información contiene conceptualmente, pero asigna valores numéricos incorrectos a las celdas. Este tipo de alucinación es particularmente peligroso en entornos industriales porque produce respuestas que son *estructuralmente correctas pero factualmente erróneas*, lo que las hace difíciles de detectar sin verificación cruzada.




Ilustración 95 Taxonomía de alucinaciones en modelos de visión-lenguaje: de objeto, de atributo y de relación. Los fallos observados en EMIE corresponden a alucinaciones de atributo. Fuente: Liu et al. (2024).

Implicaciones para los casos de uso EMIE

Para el caso de uso Iberdrola, donde la documentación contiene abundantes tablas con datos numéricos (especificaciones técnicas, medidas, parámetros operativos), esta limitación implica que el sistema no puede tratarse como una fuente fiable de datos cuantitativos extraídos de evidencia visual. Las respuestas que citen números específicos de tablas o gráficos deben tratarse como **aproximaciones que requieren verificación**, no como hechos. Esto tiene implicaciones directas para el diseño de la interfaz de usuario: el sistema debería mostrar la página fuente junto con la respuesta para permitir al usuario verificar visualmente los datos citados, y posiblemente implementar indicadores de confianza que señalen cuándo la respuesta se basa en información visual de alta densidad numérica.

Para el caso de uso de mantenimiento, donde los manuales contienen tablas de pares de apriete, tolerancias, especificaciones de fluidos y presiones, la misma limitación se traduce en un riesgo operativo: una especificación técnica incorrecta (un par de apriete erróneo, una presión de neumático inventada) podría traducirse en un fallo mecánico o un riesgo de seguridad. La mitigación más inmediata es complementar la generación con un **paso de extracción estructurada de tablas** previo o posterior, utilizando herramientas especializadas (como Camelot, Tabula o modelos de detección de tablas) que extraigan los datos numéricos de forma precisa antes de que el generador los interprete.

7.5 Comparación con el estado del arte y posicionamiento de los resultados

Situar los resultados de EMIE en el contexto del estado del arte requiere reconocer las diferencias en datasets, tareas y métricas que hacen que la comparación directa sea metodológicamente imprecisa, pero también identificar las señales cualitativas que permiten calibrar el nivel de rendimiento alcanzado.

El pipeline de EMIE (embedding single-vector + FAISS + Gemini) ocupa un punto específico en el espacio de diseño de sistemas MRAG. Es más sofisticado que un RAG textual puro (que ignoraría completamente la información visual de los documentos), pero más simple que los sistemas de última generación como M3DocRAG (que combina ColPali multi-vector + FAISS con indexación aproximada + Qwen2-VL). Los resultados de Recall@1=68.2% y Recall@5=86.4% con Vertex AI en el escenario de motos son competitivos para un sistema sin ningún fine-tuning sobre el dominio específico y sin mecanismos de re-ranking, pero inferiores a los reportados por ColPali en el benchmark ViDoRe, donde los nDCG@5 superan el 80% en la mayoría de tareas.

Sin embargo, la comparación más relevante para EMIE no es con los mejores sistemas de investigación, sino con la alternativa práctica más directa: un RAG textual convencional. Los resultados del benchmark MRAG-Bench (Hu et al., 2024) proporcionan evidencia directa a favor del enfoque multimodal de EMIE. Este benchmark evaluó 10 modelos open-source y 4 propietarios en 9 escenarios donde la evidencia visual es más beneficiosa o más accesible que la textual. El resultado principal fue que **todos los LVLMs exhibieron mejoras mayores cuando se les aumentó con imágenes que cuando se les aumentó con texto**, confirmando que

en dominios documentales con contenido visual rico, la indexación multimodal aporta valor real que un RAG textual no puede proporcionar. Esta validación externa refuerza la premisa fundamental del enfoque adoptado en EMIE.



Ilustración 96 MRAG-Bench: todos los modelos se benefician más del augmentation con imágenes que con texto, validando la premisa de RAG multimodal visual. Fuente: Hu et al. (2024).

Otro punto de comparación relevante es la evolución productiva de los sistemas MRAG descrita por RAGFlow en su revisión de fin de 2025. El análisis identifica que los sistemas MRAG productivos en 2025 no han alcanzado la madurez esperada, citando como razón principal las dificultades de ingeniería para determinar unidades de recall y estrategias de retrieval cross-modal estables. La recomendación de RAGFlow apunta hacia esquemas **híbridos** que combinan indexación full-text, vectorial y tensorial, con retrieval por etapas (recall textual inicial + re-ranking visual). Esta recomendación es directamente aplicable a la evolución del pipeline de EMIE y se retoma en la sección 7.7.

7.6 Discusión sobre reproducibilidad, validez y generalización

La honestidad intelectual exige explicitar las limitaciones metodológicas de los resultados experimentales y las cautelas necesarias para su interpretación y generalización.

Limitaciones de validez interna

La primera limitación es la **ausencia de ground truth formal anotado**. Las páginas objetivo para cada consulta se identificaron manualmente por el equipo de investigación, lo que introduce un posible sesgo en la selección de consultas (tendencia a probar consultas cuya respuesta se conoce) y en la definición de lo que cuenta como "respuesta correcta" (una página puede contener información parcialmente relevante sin ser la página óptima). La construcción de un benchmark formal con anotaciones por múltiples evaluadores y métricas inter-anotador es una necesidad para las fases siguientes.

CONFIDENCIAL

La segunda limitación es el **tamaño modesto de los datasets**. Los 25 manuales de motos, aunque representativos del tipo de documentación, constituyen un corpus pequeño comparado con benchmarks publicados: M3DocVQA opera sobre 3.000+ PDFs con 40.000+ páginas, ViDoRe incluye documentos de múltiples dominios y lenguas, y Open RAG Benchmark utiliza 1.000 papers de arXiv. Los resultados porcentuales obtenidos (68%, 86%) deben interpretarse con la cautela propia de muestras de 22 observaciones, donde la adición o eliminación de un solo caso modifica los porcentajes en ~4.5 puntos.

La tercera limitación es que la **evaluación de generación es cualitativa**. No se emplearon métricas automáticas (BLEU, ROUGE-L, METEOR, Accuracy) porque no se disponía de respuestas de referencia anotadas. La evaluación se basó en el juicio experto del equipo, lo que, aunque informativo, no permite comparaciones cuantitativas rigurosas ni reproducibilidad automática.

Limitaciones de validez externa

Los resultados pueden no generalizar directamente a otros contextos documentales. Los manuales de motos tienen características específicas (fotografías de productos, diagramas de despiece, texto técnico estandarizado) que pueden no ser representativas de otros tipos de documentación industrial como informes de inspección, planos técnicos, documentación normativa o registros de sensores. Además, los experimentos se realizaron predominantemente sobre documentación en inglés, mientras que los casos de uso de EMIE operan principalmente en español. Dado que Vertex AI documenta explícitamente soporte para inglés en su encoder de texto, y que el reconocimiento de texto en imágenes depende de la capacidad OCR del modelo para cada idioma, los resultados podrían variar significativamente en español.

Elementos generalizables

No obstante, varios hallazgos tienen validez que trasciende los datasets específicos utilizados. La confirmación empírica del modality gap y su cuantificación aportan evidencia original que complementa los resultados teóricos de Liang et al. (2022) en un contexto aplicado. La demostración de que la estrategia página-como-imagen es viable para RAG sobre documentos técnicos es un resultado de diseño generalizable. Y la verificación de que la calidad del RAG determina la calidad de la generación es un principio arquitectónico que se aplica independientemente del dominio.

7.7 Líneas de mejora identificadas y recomendaciones técnicas

Los hallazgos experimentales y la discusión crítica precedente permiten formular recomendaciones técnicas concretas organizadas en tres horizontes temporales.

Mejoras inmediatas (sin cambio de arquitectura)

Ajuste de resolución de renderizado: dado que Vertex AI comprime las imágenes a 512×512 internamente, experimentar con resoluciones de renderizado que maximicen la legibilidad del texto en esa resolución final. Probar renderizado a DPI más altos combinado con técnicas de sharpening puede mejorar el OCR implícito sin modificar el pipeline.

CONFIDENCIAL



Indexación dual texto+imagen: para documentos donde el texto es extraíble de forma fiable, generar dos embeddings por página – uno textual (del texto extraído) y uno visual (de la página como imagen) – e indexar ambos. En el momento de la búsqueda, consultar ambos índices y fusionar resultados. Esto mitiga el modality gap al permitir que consultas textuales encuentren coincidencias en el índice textual sin penalización inter-modal.

Implementación de re-ranking post-retrieval: tras obtener los top-k candidatos por distancia vectorial, aplicar un paso de re-ranking utilizando el modelo generador (Gemini) como reranker: presentarle los k candidatos junto con la query y pedirle que los ordene por relevancia. Esta técnica, análoga al "Text-First, Tensor Reranking" descrito por RAGFlow, puede mejorar significativamente la precisión sin modificar la infraestructura de indexación.

Mejoras a medio plazo (evolución arquitectónica)

Migración a ColPali/ColQwen como retriever: sustituir el embedding single-vector por un retriever multi-vector basado en ColPali o ColQwen2-VL, manteniendo Gemini como generador. Esta evolución implementaría esencialmente la arquitectura M3DocRAG y se beneficiaría del matching fino por parches que resuelve la debilidad de granularidad léxica identificada. ColQwen2-VL mostró +5.3 nDCG@5 sobre ColPali en las evaluaciones del paper original, lo que sugiere que la evolución continua de los VLMs base se traduce directamente en mejoras del retriever.

Pipeline complementario de extracción de tablas: para documentos con contenido tabular crítico, implementar un paso de extracción estructurada de tablas (usando modelos de detección como TATR o herramientas como Camelot) que produzca versiones textuales precisas de las tablas. Estas versiones se indexarían como texto complementario a la página-imagen, proporcionando un canal de recuperación preciso para datos numéricos.

Evaluación continua con benchmark formal: construir un benchmark anotado con pares pregunta-respuesta sobre la documentación real de EMIE, siguiendo la metodología de Open RAG Benchmark y Chart-MRAG Bench. Incluir preguntas de diferentes tipos (texto, tabla, imagen, combinado) y evaluar con métricas automáticas (Accuracy, ROUGE-L, Recall@k).

Mejoras a largo plazo (alineadas con la hoja de ruta EMIE)

Integración de voz: implementar el pipeline speech-to-text usando Whisper como ASR, seguido del embedding textual estándar. Evaluar la degradación de rendimiento introducida por los errores de transcripción, especialmente para terminología técnica específica de dominio.

Evaluación de modelos omni: cuando modelos como Qwen2.5-Omni o sus sucesores alcancen madurez suficiente, evaluar su uso como sustituto unificado del pipeline modular actual. La ventaja potencial es enorme (una sola llamada API en lugar de tres componentes separados), pero la madurez actual no justifica la migración.

Validación en dominio real con usuarios finales: incorporar evaluación con técnicos de mantenimiento reales y usuarios de documentación de Iberdrola para



medir no solo la precisión del sistema sino su *utilidad percibida*, *confianza del usuario* y *adopción operativa*. Los benchmarks técnicos son necesarios pero no suficientes: un sistema con 90% de recall pero latencia de 30 segundos puede ser menos útil en campo que uno con 70% de recall y 2 segundos de respuesta.




Ilustración 97 Arquitectura de M3DocRAG como referencia para la evolución del pipeline de EMIE: embedding visual con ColPali, retrieval por MaxSim, y QA con Qwen2-VL. Fuente: Cho et al. (2024).

8. Aplicabilidad Industrial y Transferencia Tecnológica

La investigación desarrollada en las secciones precedentes ha operado fundamentalmente en el plano experimental: definición de preguntas de investigación, construcción de un pipeline de referencia, evaluación comparativa de modelos de embedding y análisis crítico de los hallazgos. Esta sección desplaza el foco desde los resultados de laboratorio hacia su lectura industrial: qué valor aportan a los casos de uso concretos del proyecto EMIE, en qué condiciones pueden desplegarse, qué barreras deben superarse y cuál es la secuencia de transferencia tecnológica recomendada.

La transferencia tecnológica en proyectos de IA aplicada no es un paso final que llega después de la investigación, sino un proceso de traducción continua entre el mundo de los experimentos y el mundo de la operación. Esa traducción exige responder a preguntas que los benchmarks no responden: ¿funciona en el idioma del cliente? ¿Es aceptable la latencia para el técnico en campo? ¿Puede el sistema cometer errores en datos críticos para la seguridad? ¿Qué infraestructura supone y qué dependencias introduce? Esta sección aborda estas preguntas de forma sistemática, apoyándose en los hallazgos de la experimentación y en los requisitos de los casos de uso fijados en la sección 3.

8.1 Del laboratorio al entorno industrial: evaluación de madurez tecnológica

El Technology Readiness Level (TRL) es una escala estandarizada, originalmente desarrollada por NASA y adoptada por la Comisión Europea para proyectos de I+D, que permite situar un componente tecnológico en su camino hacia la aplicación real. En el contexto de EMIE, evaluar el TRL de cada componente del pipeline experimental es el primer paso para planificar una transferencia ordenada y realista. La tabla siguiente evalúa cada componente del pipeline investigado, su nivel de madurez actual basado en los experimentos de la sección 6, la brecha que lo separa de un despliegue en producción, y la acción técnica prioritaria para acortarla.

Componente	TRL actual	Brecha hasta producción	Acción recomendada
Estrategia página-como-imagen	5	Validado en dominio de motos (EN). Sin validación en español ni en corpus Iberdrola real.	Piloto sobre corpus real en español con Vertex AI. Ajuste de DPI y sharpening.
Vertex AI multimodalembd@001	5	Dependencia de API cloud. Encoder de texto declarado english-first. Compresión interna a 512x512.	Validación de rendimiento en español. Evaluación de latencia y coste por consulta en escenario real.
Indexación dual texto+imagen	4	Diseñada pero no implementada en los experimentos. Pendiente de validación empírica.	Implementar y medir mejora de Recall@k sobre corpus en español respecto a indexación solo-imagen.



Re-ranking con Gemini	4	Propuesto en 7.7. Aún no evaluado experimentalmente en el pipeline EMIE.	Evaluar mejora de precisión en top-k. Medir latencia adicional introducida.
Gemini como generador (texto)	6	Funciona bien sobre evidencia textual recuperada. Dependencia de API propietaria.	Evaluar alternativas on-premise para entornos con restricciones de soberanía del dato.
Gemini + evidencia tabular visual	3	Alucinaciones de atributo documentadas con datos numéricos en tablas (7.4). No apto para producción sin mitigación.	Extracción estructurada de tablas (Camelot/TATR) como canal complementario obligatorio.
Pipeline con ASR (voz)	3	No implementado. Requiere Whisper o equivalente. Degradación por terminología técnica desconocida.	PoC con Whisper en terminología de mantenimiento industrial. Medir WER en dominio.
ColPali/ColQwen como retriever	4	Identificado como evolución arquitectónica superior. No integrado en pipeline EMIE.	Evaluación experimental en escenario de motos/Iberdrola. Comparar nDCG@5 frente a Vertex AI.

Tabla 5. Evaluación de madurez tecnológica (TRL) de los componentes del pipeline EMIE.

De la lectura conjunta de esta tabla emergen tres agrupaciones claras. En primer lugar, los componentes en TRL 5–6, que corresponden al núcleo del pipeline validado experimentalmente (página-como-imagen, Vertex AI, Gemini sobre texto), son los candidatos para un piloto de corto plazo. En segundo lugar, los componentes en TRL 4 (indexación dual, re-ranking, ColPali) representan mejoras arquitectónicas diseñadas o identificadas pero no evaluadas empíricamente en el contexto EMIE, y constituyen el objetivo del horizonte medio. En tercer lugar, los componentes en TRL 3 (ASR, generación sobre tablas visuales) presentan limitaciones fundamentales documentadas que requieren mitigación o rediseño antes de cualquier despliegue, y corresponden al horizonte largo.

Esta estratificación no debe interpretarse como una barrera secuencial estricta: los pilotos de corto plazo pueden ejecutarse en paralelo con el desarrollo de los componentes de TRL más bajo, siempre que las interfaces entre componentes estén bien definidas y las limitaciones sean visibles para el usuario final.

8.2 Aplicabilidad al Caso de Uso A: asistencia multimodal al mantenimiento

El caso de uso A plantea una progresión de cinco niveles de madurez que va desde el técnico que trabaja con manuales físicos hasta el asistente con realidad



aumentada, análisis de vídeo y sensores en tiempo real. Esta progresión ofrece un marco natural para mapear los resultados experimentales sobre capacidades concretas en cada nivel.

Nivel 1-2 (técnico con papel y con GMAO): El pipeline investigado no aporta valor diferencial en estos niveles, cubiertos por sistemas de gestión ya existentes. El aporte de EMIE comienza en el nivel 3.

Nivel 3 (asistente LLM conversacional): Este es el nivel al que los resultados experimentales se aplican de forma más directa. Un pipeline RAG sobre manuales indexados permite al técnico formular preguntas en lenguaje natural sobre procedimientos, herramientas, materiales y especificaciones. La condición crítica que aún debe validarse es el rendimiento en español: los experimentos se realizaron predominantemente sobre documentación en inglés, y Vertex AI documenta explícitamente soporte prioritario para ese idioma en su encoder de texto. Este riesgo no invalida el enfoque, pero obliga a realizar una validación empírica sobre el corpus real antes de cualquier despliegue.

Nivel 4 (asistente por voz): Requiere integrar un componente ASR antes del embedding. La opción más directa es Whisper, cuya integración puede formularse como un preprocesado previo al pipeline actual: voz → transcripción → embedding textual. La degradación de rendimiento introducida por errores de transcripción es predecible, pero su magnitud en terminología técnica industrial en español es una incógnita que debe medirse específicamente. Errores en términos como "par de apriete", "presostato" o referencias de recambio ("referencia 34217-B") tienen un impacto muy diferente sobre la recuperación que errores en lenguaje general.

Nivel 5 (realidad aumentada + análisis en tiempo real): Este nivel está fuera del TRL actual del pipeline investigado. Requeriría una arquitectura de inferencia de muy baja latencia, capacidad de análisis de stream de vídeo, y un modelo generador que opere de forma nativa sobre entrada visual en tiempo real. Los modelos omni mencionados en la sección 5.7 (Qwen2.5-Omni y sucesores) constituyen el horizonte tecnológico relevante, pero su madurez actual no justifica todavía una integración directa en el pipeline EMIE.

Una condición transversal a todos los niveles del caso de uso A es la integración del sistema con el GMAO o CMMS existente. El asistente no debe ser un silo de información paralelo: su valor operativo depende de que pueda consultar el estado de la orden de trabajo activa, acceder al histórico de intervenciones sobre el activo, y registrar automáticamente (o semiautomáticamente) las acciones realizadas. Esta integración, aunque no es parte del pipeline de recuperación investigado, es un requisito de producto que debe planificarse desde el inicio para que el piloto no se convierta en un demostrador aislado.

Un segundo riesgo transversal específico de este caso de uso es el de las alucinaciones de atributo en datos de seguridad. Un par de apriete incorrecto, una presión de fluido inventada o una especificación de componente errónea pueden tener consecuencias directas sobre la seguridad de la intervención. Los experimentos de la sección 7.4 documentaron precisamente este tipo de fallo en Gemini cuando la evidencia proviene de tablas visuales. La mitigación recomendada

CONFIDENCIAL

es obligatoria antes de cualquier despliegue en nivel 3 o superior: extracción estructurada de tablas técnicas como canal complementario al embedding visual, de modo que los datos numéricos críticos se sirvan desde texto extraído con precisión y no desde la interpretación visual del generador.

8.3 Aplicabilidad al Caso de Uso B: RAG multimodal documental para Iberdrola

El caso de uso B es el que el pipeline experimental valida de forma más directa. La tarea central, acceder de forma inteligente a documentación técnica extensa y heterogénea que combina texto, imágenes y tablas, coincide estructuralmente con los experimentos del escenario 4 (manuales técnicos de motos), con la diferencia de que el corpus real de Iberdrola opera en español y con tipos documentales específicos del sector eléctrico (especificaciones de equipos, procedimientos de operación, normativa técnica, planos).

La tabla siguiente sintetiza la viabilidad actual del pipeline para los tipos de consulta más relevantes en este caso de uso, los riesgos principales identificados y las acciones de mitigación recomendadas.

Tipo de consulta	Viabilidad actual	Riesgo principal	Mitigación recomendada	Horizonte
Consulta textual sobre contenido texto de documentos	Alta	Idioma (español). Chunking subóptimo en documentos largos.	Indexación dual. Validación en español.	Corto plazo
Consulta textual sobre información contenida en imágenes	Media	Modality gap (ratio 3:1 en Vertex AI). Dependencia del OCR implícito del modelo.	Indexación dual. Ajuste de DPI para maximizar legibilidad en 512×512.	Corto-medio plazo
Consulta sobre datos numéricos en tablas visuales	Baja	Alucinaciones de atributo documentadas. El modelo fabrica cifras con aparente seguridad.	Extracción estructurada de tablas (Camelot, TATR) antes de indexación.	Medio plazo
Consulta que requiere integrar evidencia de múltiples páginas o documentos	Media	El pipeline single-vector no captura relaciones cross-documento. Posible pérdida de contexto.	Re-ranking con Gemini como reranker. Evolución a ColPali multi-vector.	Medio plazo



Consulta sobre imagen aportada por el usuario en tiempo real	Media	No evaluado en EMIE. Requiere pipeline diferenciado: imagen usuario → embedding → búsqueda cross-modal.	PoC específico con consultas de imagen de usuario sobre corpus Iberdrola.	Medio plazo
Consulta por voz en campo (técnico de mantenimiento)	Baja	Pipeline ASR no implementado. Alta degradación esperada en terminología técnica.	Integración Whisper + validación WER en dominio. Memoria de diálogo ligada a OT.	Largo plazo

Tabla 6. Viabilidad del pipeline EMIE por tipo de consulta en el Caso de Uso B.

De esta tabla se desprende que el pipeline actual es directamente aplicable a las consultas más frecuentes (texto sobre texto y texto sobre imagen) con la condición de validación en español, pero presenta limitaciones significativas en las consultas sobre datos tabulares y en la integración cross-documento. Estas limitaciones no invalidan el despliegue de un piloto: simplemente delimitan el alcance funcional que puede ofrecerse al usuario en una primera fase.

Un aspecto arquitectónico específico del caso Iberdrola es la capacidad de consulta sobre imagen aportada por el usuario, descrita en la sección 3.4 como uno de los tres modos de operación del sistema. Esta funcionalidad requiere un pipeline diferenciado del RAG sobre corpus indexado: la imagen del usuario debe convertirse en un embedding que luego se use como query sobre la base vectorial, o bien procesarse directamente por el generador. Ninguno de estos flujos fue evaluado en los experimentos de EMIE, por lo que deben considerarse un desarrollo pendiente con prioridad de medio plazo.

La propuesta de arquitectura de transición para este caso de uso sigue directamente el horizonte de mejoras definido en la sección 7.7. En una primera fase, el pipeline basado en Vertex AI con indexación dual texto+imagen y re-ranking con Gemini es desplegable a corto plazo sobre un corpus piloto en español. En una segunda fase, la migración a ColPali o ColQwen2-VL como retriever multi-vector permite resolver la debilidad de granularidad léxica identificada y aproximar el sistema al estado del arte documentado en M3DocRAG. Esta segunda fase introduce también el pipeline de extracción estructurada de tablas como canal complementario obligatorio para el tipo de documentación técnica de Iberdrola.

8.4 Barreras de transferencia y condiciones de éxito

La transferencia tecnológica de un sistema de IA hacia un entorno industrial real no depende únicamente de las métricas de recuperación y generación. Existen factores no técnicos, o parcialmente técnicos, que pueden condicionar el éxito del despliegue de forma igual o más determinante que el Recall@5. Esta sección identifica las

barreras principales y las condiciones que deben cumplirse para que la transferencia sea exitosa.

Idioma y dominio. Los experimentos se realizaron predominantemente en inglés. El corpus real de EMIE opera en español, y el vocabulario técnico del sector eléctrico y del mantenimiento industrial tiene características específicas (acrónimos, nomenclaturas normativas, referencias de componentes) que pueden diferir significativamente del lenguaje general. Vertex AI documenta soporte para inglés en su encoder de texto de forma explícita, lo que introduce un riesgo no cuantificado sobre el rendimiento en español. Voyage AI, con su ventana de entrada de 32.000 tokens y arquitectura más flexible, presenta en principio menores restricciones de idioma, pero su bajo rendimiento en identificación visual (Recall@1 del 22,7% frente al 68,2% de Vertex AI en el escenario de motos) lo descarta como primera opción para corpus visualmente ricos. La resolución de esta barrera exige validación empírica en español como paso previo al despliegue.

Soberanía del dato y despliegue. Tanto Vertex AI como Voyage AI son servicios cloud propietarios. Un despliegue en Iberdrola, especialmente si involucra documentación clasificada o con restricciones regulatorias, puede requerir una arquitectura on-premise o en VPC privada. En ese escenario, los modelos de embedding y el generador deben ser sustituidos por equivalentes desplegables localmente, lo que puede implicar una degradación de rendimiento respecto a los resultados experimentales obtenidos con APIs propietarias. Esta barrera debe evaluarse específicamente para el entorno legal y de seguridad de Iberdrola antes de iniciar el piloto.

Latencia y usabilidad en campo. La sección 7.7 formuló un principio relevante para el caso de uso de mantenimiento: un sistema con 70% de recall y 2 segundos de respuesta puede ser más útil operativamente que uno con 90% de recall y 30 segundos. Este principio debe traducirse en SLAs concretos definidos con los usuarios finales antes del piloto. El pipeline actual (embedding → FAISS → generación) introduce latencias en cada etapa que deben medirse en condiciones reales de red y carga, especialmente si el técnico opera desde un dispositivo móvil con conectividad limitada.

Integración con infraestructura existente. El valor operativo del sistema depende de su integración con los flujos de trabajo ya establecidos. En el caso de mantenimiento, esto significa conexión con el GMAO para acceder al contexto de la orden de trabajo activa. En el caso Iberdrola, significa integración con los repositorios documentales existentes y con los mecanismos de control de versiones de la documentación técnica. Un sistema que requiere alimentación manual de documentos o que no refleja las actualizaciones del corpus pierde valor rápidamente en un entorno industrial real.

Evaluación continua y detección de degradación. La sección 7.6 señaló que sin un benchmark anotado con pares pregunta-respuesta sobre la documentación real de EMIE no es posible medir la calidad del sistema en producción de forma rigurosa. Esta no es una limitación menor: en un entorno donde la documentación evoluciona, los modelos reciben actualizaciones y los patrones de consulta cambian, la ausencia

CONFIDENCIAL

de métricas automáticas hace indetectable la degradación progresiva del sistema. La construcción del benchmark es una condición de éxito para el piloto, no un trabajo diferible a fases posteriores.

Gestión de las alucinaciones y confianza del usuario. El hallazgo más relevante para la seguridad del despliegue es el de las alucinaciones de atributo documentadas en la sección 7.4: el sistema produce valores numéricos incorrectos de tablas con aparente seguridad y sin autocorrección tras feedback. Este comportamiento, si no se gestiona explícitamente en el diseño de la interfaz, puede erosionar la confianza del usuario o, peor, inducir errores operativos. La mitigación recomendada incluye mostrar siempre la página fuente junto a la respuesta para permitir verificación visual, implementar indicadores de confianza diferenciados para respuestas sobre texto frente a respuestas sobre tablas o imágenes, y documentar explícitamente las limitaciones conocidas del sistema para los usuarios finales.

8.5 Hoja de ruta de transferencia tecnológica

A partir del análisis de madurez de la sección 8.1, de la aplicabilidad diferenciada por caso de uso de las secciones 8.2 y 8.3, y de las barreras identificadas en la sección 8.4, es posible formular una hoja de ruta de transferencia articulada en tres fases. Estas fases se alinean con los tres horizontes de mejora definidos en la sección 7.7, operativizando las recomendaciones técnicas en hitos, componentes y casos de uso concretos.

Fase	Horizonte	Hito principal	Componentes clave	Caso de uso
Fase 1 — Piloto validado	Corto plazo (3–6 meses)	RAG multimodal operativo en español sobre corpus real de Iberdrola. Benchmark formal anotado establecido.	Vertex AI + indexación dual texto+imagen + re-ranking Gemini + extracción tabular Camelot.	CU-B (Iberdrola)
Fase 2 — Evolución del retriever	Medio plazo (6–12 meses)	Sustitución del retriever single-vector por ColPali/ColQwen. Mejora medible en nDCG@5. Evaluación en español.	ColQwen2-VL + FAISS multi-vector + pipeline complementario TATR para tablas + métricas automáticas (ROUGE-L, Recall@k).	CU-A y CU-B
Fase 3 — Integración operativa	Largo plazo (12–24 meses)	Asistente por voz en campo. Validación con técnicos reales de mantenimiento. Integración con GMAO.	Whisper ASR + memoria de diálogo por OT + integración CMMS + evaluación con usuarios finales.	CU-A (mantenimiento)

Tabla 7. Hoja de ruta de transferencia tecnológica del pipeline multimodal EMIE.



La Fase 1 prioriza deliberadamente el Caso de Uso B (Iberdrola) porque es el que presenta mayor madurez experimental, mayor claridad en los requisitos de corpus, y menor dependencia de componentes no validados (ASR, AR). El hito central de esta fase no es solo el despliegue técnico, sino la construcción del benchmark anotado: sin él, la Fase 2 no puede evaluarse con rigor.

La Fase 2 introduce la evolución arquitectónica más significativa: la migración del retriever de embedding single-vector a ColPali o ColQwen2-VL. Esta migración resuelve las debilidades de granularidad léxica identificadas en los experimentos y aproxima el pipeline EMIE al estado del arte documentado en M3DocRAG (sección 7.5). La incorporación del pipeline complementario de extracción tabular (TATR o Camelot) en esta fase responde directamente al hallazgo de alucinaciones de atributo documentado en la sección 7.4.

La Fase 3 aborda la integración operativa plena del Caso de Uso A, incluyendo el componente ASR y la evaluación con usuarios finales. La validación con técnicos de mantenimiento reales es una condición de cierre de esta fase: los benchmarks técnicos son necesarios pero no suficientes para determinar si el sistema es útil en campo, y la experiencia del usuario (latencia percibida, confianza en las respuestas, facilidad de integración en el flujo de trabajo) es un criterio de éxito tan relevante como el Recall@5.

8.6 Valor industrial y posicionamiento competitivo

La pregunta central que debe responder esta sección es: ¿qué valor diferencial aporta la arquitectura investigada en EMIE respecto a las alternativas disponibles? Esta pregunta tiene dos dimensiones: la comparación con el estado del arte técnico y la comparación con las soluciones actualmente en uso en los entornos objetivo.

Respecto al estado del arte técnico, el posicionamiento del pipeline EMIE es el de un sistema de RAG multimodal de generación uno, validado experimentalmente en un escenario cuasi-industrial, con rendimiento competitivo (Recall@1 = 68,2%, Recall@5 = 86,4% con Vertex AI en manuales de motos) pero inferior a los sistemas de última generación basados en ColPali en benchmarks especializados como ViDoRe. La brecha es conocida, cuantificable y, sobre todo, superable mediante la hoja de ruta descrita en la sección 8.5. El valor de EMIE no está en ser el sistema de más alto rendimiento en benchmarks públicos, sino en ser el primer sistema de estas características validado en el contexto específico de documentación técnica industrial en español, con casos de uso reales y un camino de evolución documentado.

Respecto a las alternativas actualmente en uso, el diferencial más relevante es la capacidad de recuperar evidencia en imágenes, diagramas y tablas de documentos técnicos, que un RAG textual convencional ignora por completo. Esta capacidad está directamente validada por los resultados del benchmark MRAG-Bench (Hu et al., 2024), que demostró que todos los sistemas evaluados obtenían mejoras superiores con augmentación por imagen que con augmentación por texto en dominios documentales visualmente ricos. Para un cliente como Iberdrola, cuya documentación técnica combina texto, esquemas eléctricos, tablas de especificaciones y fotografías de equipos, esta capacidad no es un refinamiento

CONFIDENCIAL

incremental: es la condición para que el sistema pueda responder una fracción relevante de las consultas reales de sus técnicos.

El valor económico y operativo del sistema se puede aproximar en tres dimensiones. En tiempo de consulta, la reducción de la fricción cognitiva de buscar manualmente en manuales extensos se traduce directamente en tiempo ahorrado por intervención, acumulable sobre miles de órdenes de trabajo anuales. En calidad de la intervención, el acceso fiable y rápido a procedimientos correctos y especificaciones técnicas reduce la probabilidad de error por información desactualizada o mal localizada. En transferencia de conocimiento, el sistema actúa como un mecanismo de captura y reutilización del conocimiento experto distribuido en la documentación, especialmente relevante en contextos de renovación generacional de plantillas técnicas.

Desde la perspectiva del consorcio EMIE, la investigación realizada en esta línea de trabajo produce tres tipos de activos transferibles. El primero es el **conocimiento metodológico**: el protocolo experimental desarrollado, incluyendo la estrategia de evaluación del modality gap, la comparación de embeddings multimodales y la metodología de benchmark anotado, es reproducible y adaptable a nuevos dominios documentales. El segundo es el **conocimiento arquitectónico**: las decisiones de diseño documentadas en las secciones 4, 5 y 7, incluyendo las justificaciones de las elecciones realizadas y las limitaciones conocidas de las alternativas evaluadas, constituyen una base de conocimiento que evita repetir el mismo proceso de exploración en futuros proyectos del consorcio. El tercero es el **conocimiento de dominio**: la identificación de los tipos de consulta que el sistema puede responder con fiabilidad y los que no, junto con las mitigaciones recomendadas, es directamente utilizable por los equipos de producto de Iberdrola y LIS Data Solutions para diseñar una experiencia de usuario que gestione correctamente las expectativas y evite los escenarios de riesgo identificados.

La investigación desarrollada en EMIE sobre procesamiento multimodal sitúa al consorcio en una posición de **conocimiento avanzado y diferencial sobre la aplicabilidad real de los modelos de embedding multimodal a la documentación técnica industrial**. Los hallazgos, incluyendo los negativos, son un activo: saber que la generación sobre tablas visuales alucinan con aparente seguridad, que el modality gap es medible y que la estrategia página-como-imagen es viable pero mejorable con ColPali, es conocimiento que un competidor que no haya hecho esta investigación no tiene. La hoja de ruta propuesta convierte ese conocimiento en un plan de acción concreto orientado a entregar valor operativo real en los plazos del proyecto.



9. Conclusiones

9.1 Recapitulación del objetivo y del alcance investigado

Esta línea de investigación del proyecto EMIE se planteó un objetivo claro y acotado: determinar qué combinación de modelos de embedding multimodal, estrategias de indexación y modelos generativos produce un pipeline de RAG multimodal viable para los casos de uso industriales del proyecto, entendiendo viabilidad como el equilibrio entre calidad de recuperación, fidelidad de las respuestas generadas, coste operativo y latencia de inferencia. Para alcanzarlo, el trabajo recorrió un arco completo: desde la revisión sistemática del estado del arte en modelos multimodales y embeddings de espacio compartido, hasta la construcción de un pipeline experimental de cuatro etapas, la evaluación comparativa de dos modelos de embedding en cuatro escenarios de complejidad creciente, y el análisis crítico de los resultados incluyendo sus limitaciones y su proyección industrial.

El alcance experimental cubrió dos modelos de embedding (Vertex AI multimodalembd@001 y Voyage AI voyage-multimodal-3), cuatro escenarios de prueba (imágenes con texto visible, imágenes industriales, PDFs documentales heterogéneos y manuales técnicos de motos), y la evaluación del modelo generador Gemini 2.0 Flash bajo tres condiciones de RAG. La evaluación se apoyó en métricas de recuperación (Recall@k, distancia euclidiana, análisis PCA del modality gap) y en valoración cualitativa de la calidad de la generación. Esta sección recoge las conclusiones principales que ese trabajo permite formular.

9.2 Respuesta a las preguntas de investigación

El trabajo se articuló alrededor de cinco preguntas de investigación definidas en la sección 4.1. La tabla siguiente sintetiza el veredicto y la conclusión principal de cada una, antes de desarrollarlas en detalle.

PI	Pregunta	Veredicto	Conclusión principal
PI-1	¿Son los embeddings multimodales capaces de recuperación cross-modal sobre documentación técnica?	 Confirmada (con matiz)	Sí, con Vertex AI. Recall@1 = 68,2% y Recall@5 = 86,4% en manuales técnicos sin fine-tuning. La capacidad no es uniforme entre modelos: Voyage AI obtiene Recall@1 = 22,7% en el mismo escenario.
PI-2	¿Cuánto impacta el modality gap en la calidad de la recuperación?	 Confirmada	El gap es medible y tiene impacto directo. Ratio de distancia 3:1 en Vertex AI. Voyage AI muestra menor gap estructural (PCA 13,92%) pero peor retrieval visual: el gap es necesario pero no suficiente para explicar el rendimiento.
PI-3	¿Es viable la estrategia página-como-imagen para indexar PDFs técnicos?	 Confirmada	Viable y competitiva. Preserva layout y contenido visual. La limitación principal es la



		(con condiciones)	granularidad léxica en consultas muy específicas, mitigable con indexación dual texto+imagen.
PI-4	¿Determina la calidad del RAG la calidad de la respuesta generada?	☑ Confirmada (categórica)	Sí, de forma dramática. RAG erróneo produce respuestas que citan fuentes incorrectas con aparente seguridad. RAG exitoso produce respuestas específicas y trazables. El retriever es el cuello de botella determinante.
PI-5	¿Qué modelo de embedding supera al otro en identificación visual sobre documentación técnica?	☑ Resuelta	Vertex AI multimodalembd@001 supera a Voyage AI voyage-multimodal-3 de forma clara y consistente en todos los niveles de k evaluados (Recall@1: 68,2% vs. 22,7%; Recall@5: 86,4% vs. 45,5%).

Tabla 8. Síntesis de respuestas a las preguntas de investigación del trabajo.

PI-1 — Capacidad de recuperación cross-modal

¿Son los modelos de embedding multimodal actuales capaces de producir representaciones suficientemente alineadas entre modalidades para soportar una recuperación eficaz sobre documentación técnica real?

La respuesta es afirmativa, pero con una condición relevante: la capacidad existe y es competitiva en el caso de Vertex AI multimodalembd@001, que alcanzó un Recall@1 del 68,2% y un Recall@5 del 86,4% sobre el escenario cuasi-industrial de manuales de motos, sin ningún fine-tuning sobre el dominio. Este resultado demuestra que un pipeline de RAG multimodal basado en embeddings de espacio compartido puede localizar documentación técnica relevante a partir de consultas textuales sobre contenido indexado visualmente, lo cual justifica el enfoque y lo hace técnicamente viable como punto de partida. Sin embargo, la capacidad no es uniforme entre modelos: Voyage AI voyage-multimodal-3, a pesar de liderar benchmarks públicos como MIEB, obtuvo un Recall@1 del 22,7% en el mismo escenario. Esta divergencia entre rendimiento en benchmarks generales y rendimiento en tareas de identificación visual sobre documentación técnica es, en sí misma, una conclusión de PI-1: los benchmarks públicos no son suficientes para seleccionar el modelo de embedding adecuado para un dominio industrial específico. La validación empírica en el dominio real es imprescindible.

PI-2 — Impacto del modality gap

¿Qué magnitud tiene el modality gap en los modelos evaluados y qué impacto tiene sobre la calidad de la recuperación cross-modal?

El modality gap existe, es medible en ambos modelos y tiene impacto directo sobre la calidad de la recuperación, pero se manifiesta de formas distintas y con consecuencias no simétricas. En Vertex AI, el gap se cuantificó como una diferencia de distancia de ratio 3:1 entre consultas textuales y visuales sobre el mismo contenido (1,65 frente a 0,54), lo que confirma que el espacio latente asigna

sistemáticamente más distancia a las consultas de texto que a las de imagen respecto a los documentos indexados. A pesar de este gap pronunciado, Vertex AI obtuvo el mejor rendimiento de identificación visual. En Voyage AI, el análisis PCA reveló una separación estructural más moderada (13,92% de varianza explicada por la primera componente principal), pero el rendimiento de retrieval visual fue significativamente inferior. Esta paradoja constituye el hallazgo más teóricamente interesante de la investigación: un menor modality gap medido geométricamente no garantiza un mejor rendimiento de recuperación visual. La hipótesis más plausible es que el gap puede tener una función organizativa en la estructura interna de las representaciones visuales; su reducción sin un reentrenamiento cuidadoso puede comprometer la calidad discriminativa de los embeddings de imagen incluso cuando el espacio inter-modal se estrecha. Este resultado abre una pregunta de investigación relevante más allá del alcance de EMIE: ¿cuál es la relación óptima entre alineamiento inter-modal y capacidad discriminativa intra-modal en embeddings para retrieval visual?

PI-3 — Eficacia de la estrategia página-como-imagen

¿Es viable tratar cada página de un PDF técnico como una imagen y generar un embedding visual por página como estrategia de indexación para RAG multimodal? La estrategia es viable y produce resultados competitivos. Sus fortalezas principales son tres: primero, preserva íntegramente el contexto de layout del documento, incluyendo la relación espacial entre texto, tablas, imágenes y diseño de página, que se pierde irremediabilmente en un parsing textual convencional; segundo, captura de forma nativa la información visual contenida en diagramas, fotografías y esquemas que un extractor de texto ignora por completo; y tercero, simplifica considerablemente el pipeline de ingestión al eliminar la necesidad de parsear, separar y procesar por separado los distintos tipos de contenido. Sus debilidades principales son dos: la granularidad léxica, ya que el embedding de una página completa puede perder precisión ante consultas que buscan una cadena textual muy específica; y la compresión interna de Vertex AI a 512×512 píxeles, que reduce la resolución disponible para el OCR implícito del modelo y puede degradar la recuperación de texto de tamaño reducido. Ambas debilidades son mitigables: la primera, mediante indexación dual que combina embeddings visuales y textuales; la segunda, mediante ajuste del DPI de renderizado para maximizar la legibilidad en la resolución de destino. La estrategia página-como-imagen es, en suma, un diseño arquitectónico generalizable que puede adaptarse a cualquier dominio documental técnico con contenido visualmente rico.

PI-4 — Calidad de la generación en función del RAG

¿En qué medida determina la calidad del componente de recuperación la calidad de las respuestas generadas por el modelo multimodal?

La determinación es completa y la diferencia entre condiciones es cualitativa, no solo cuantitativa. Los experimentos compararon tres condiciones: generación sin RAG (solo conocimiento paramétrico del modelo), generación con RAG erróneo (documentos incorrectos proporcionados como contexto), y generación con RAG exitoso (documentos correctos recuperados). Los resultados son inequívocos. Sin

CONFIDENCIAL

RAG, Gemini produce respuestas genéricas y no específicas del documento consultado: útiles como conocimiento general, pero inaplicables para guiar una intervención técnica concreta. Con RAG erróneo, el modelo produce respuestas que citan páginas y documentos incorrectos con aparente seguridad y sin señales de incertidumbre, generando un riesgo de desinformación que es potencialmente más peligroso que la ausencia de respuesta. Con RAG exitoso, el modelo produce respuestas específicas, referenciadas a páginas concretas y con el nivel de detalle operativo necesario para una intervención técnica. Esta diferencia cualitativa confirma que el retriever no es un componente de soporte del sistema: es el componente determinante. Mejorar el generador no puede compensar un retriever deficiente; en cambio, un retriever preciso maximiza el valor de cualquier generador. Esta asimetría tiene implicaciones directas sobre la estrategia de inversión tecnológica del proyecto en fases futuras.

PI-5 — Comparación de modelos de embedding en identificación visual

¿Qué modelo de embedding multimodal obtiene mayor calidad en la tarea de identificación visual sobre documentación técnica industrial?

Vertex AI multimodalembd@001 supera a Voyage AI voyage-multimodal-3 de forma clara, consistente y estadísticamente robusta en el escenario de identificación visual sobre manuales técnicos. La diferencia en Recall@1 (68,2% frente a 22,7%) y en Recall@5 (86,4% frente a 45,5%) es suficientemente amplia para que no pueda atribuirse a variabilidad muestral: supone una diferencia de 15 observaciones sobre 22 en el primer caso. Este resultado es sorprendente respecto a las expectativas previas, dado que Voyage AI multimodal-3 había sido seleccionado como candidato precisamente por su posición destacada en benchmarks públicos de embedding multimodal. La discrepancia entre esos benchmarks y el rendimiento observado en el dominio de EMIE constituye en sí misma una lección metodológica: los benchmarks públicos evalúan capacidades generales sobre datasets heterogéneos, pero no predicen de forma fiable el rendimiento en tareas específicas de identificación visual sobre documentación técnica industrial. Para el proyecto EMIE, la conclusión operativa es que Vertex AI es el modelo de embedding recomendado para el pipeline actual, con la condición de validar su rendimiento sobre corpus en español antes de cualquier despliegue.

9.3 Hallazgos transversales no anticipados

Más allá de las cinco preguntas de investigación formuladas, la experimentación produjo tres hallazgos de valor propio que no estaban anticipados en el diseño del trabajo y que merecen ser destacados de forma independiente.

Alucinaciones de atributo en datos numéricos estructurados. La incapacidad sistémica de Gemini 2.0 Flash para extraer datos numéricos precisos de tablas presentadas en formato visual, documentada en detalle en la sección 7.4, no estaba formulada como pregunta de investigación. Su descubrimiento fue un resultado lateral del experimento con vídeo sobre tablas de fondos de inversión. El modelo fabricó valores incorrectos de forma consistente, sin señales de incertidumbre y sin corrección tras feedback explícito sobre la ubicación de los datos. Este

comportamiento, clasificable como alucinación de atributo según la taxonomía de Liu et al. (2024), es potencialmente el hallazgo con mayor impacto sobre la seguridad del despliegue en los casos de uso de EMIE: en entornos donde los manuales técnicos contienen tablas con pares de apriete, tolerancias de componentes, presiones de fluidos o especificaciones eléctricas, una respuesta estructuralmente correcta pero numéricamente inventada puede traducirse en un error operativo o en un riesgo de seguridad. Este hallazgo no invalida el pipeline, pero establece una condición de mitigación obligatoria antes de cualquier despliegue en dominios con datos técnicos críticos: la extracción estructurada de tablas debe operar como canal complementario al embedding visual, proporcionando los datos numéricos con precisión verificada antes de que el generador los interprete.

La paradoja del modality gap y la discriminación visual. El resultado de que un menor gap inter-modal medido geoméricamente no se traduzca en mejor retrieval visual es contraintuitivo y, en la literatura consultada, no tiene una explicación establecida para el caso específico de retrieval sobre documentación técnica. La hipótesis más coherente con los datos observados es que el gap estructural de Vertex AI organiza el espacio de embeddings de imagen en una región más compacta y discriminativa, mientras que el espacio más mezclado de Voyage AI puede introducir ambigüedad en la representación de imágenes técnicas que comparten muchos elementos visuales entre sí (páginas de manuales del mismo fabricante, imágenes del mismo tipo de equipo). Este hallazgo tiene interés teórico más allá de EMIE: sugiere que la optimización del modality gap como objetivo de diseño de embeddings multimodales puede tener un umbral de rendimiento óptimo no trivial, y que reducirlo en exceso sin controlar la discriminabilidad intra-modal puede ser contraproducente para tareas de retrieval visual especializado.

La asimetría de valor en la cadena RAG→generación. Los experimentos de PI-4 confirmaron algo que la literatura sugería pero que raramente se documenta de forma tan directa: la cadena de valor del sistema RAG es fundamentalmente asimétrica. Una mejora en el retriever tiene un efecto multiplicador sobre toda la cadena; una mejora en el generador no puede compensar las deficiencias del retriever. Esta asimetría implica que las decisiones de inversión tecnológica del proyecto deben estar orientadas prioritariamente al componente de recuperación: la migración a ColPali o ColQwen2-VL como retriever multi-vector (identificada en la sección 7.7 como mejora de medio plazo) tiene un potencial de mejora del sistema final mucho mayor que cualquier actualización del modelo generador con rendimiento similar al actual.

9.4 Limitaciones de la investigación

Las conclusiones anteriores deben interpretarse con el conocimiento explícito de las limitaciones del trabajo, que condicionan su alcance y su capacidad de generalización.

Tamaño muestral en el escenario principal. El escenario cuasi-industrial de manuales de motos, que es el que permite formular las conclusiones más relevantes para el dominio de EMIE, se evaluó sobre un conjunto de 22 consultas. Con este

tamaño, cada observación individual equivale a aproximadamente 4,5 puntos porcentuales en las métricas de Recall. Los resultados son estadísticamente indicativos pero no concluyentes con el rigor exigible a un benchmark de producción. Esta limitación no invalida los hallazgos cualitativos (la diferencia entre 68% y 23% de Recall@1 es robusta a variaciones muestrales razonables), pero obliga a interpretar los valores numéricos exactos como aproximaciones y no como medidas definitivas.

Idioma de la experimentación. Todos los experimentos se realizaron sobre documentación predominantemente en inglés. El despliegue operativo de EMIE requiere que el sistema funcione en español, tanto en las consultas de los usuarios como en el corpus documental de Iberdrola y en los manuales de mantenimiento. Vertex AI documenta soporte prioritario para inglés en su encoder de texto, lo que introduce un riesgo no cuantificado sobre el rendimiento en español que debe ser evaluado empíricamente antes de cualquier decisión de despliegue. Esta brecha entre el idioma de validación y el idioma de operación es la limitación con mayor impacto práctico sobre las conclusiones del trabajo.

Evaluación cualitativa de la generación. La evaluación de la calidad de las respuestas generadas se realizó mediante juicio experto del equipo, sin métricas automáticas (BLEU, ROUGE-L, METEOR, Accuracy) y sin respuestas de referencia anotadas. Esto hace que los resultados de la fase de generación sean informativos y coherentes con los hallazgos de la fase de recuperación, pero no directamente comparables con otros sistemas evaluados con benchmarks estandarizados. La construcción de un conjunto de referencia anotado sobre corpus real de EMIE es una condición necesaria para superar esta limitación en fases futuras.

Cobertura de tipos documentales. Los experimentos se concentraron en fotografías de productos y manuales técnicos de fabricantes. Otros tipos documentales relevantes para los casos de uso de EMIE –planos técnicos, registros de inspección, normativa sectorial, informes de incidencias– no fueron evaluados. La generalización de los resultados a estos tipos debe hacerse con cautela, dado que sus características visuales y textuales son significativamente distintas a las de los manuales evaluados.

9.5 Líneas de trabajo futuro

Los hallazgos de este trabajo generan preguntas abiertas que definen las líneas de investigación y desarrollo más relevantes para las fases siguientes del proyecto. No se formulan aquí como tareas sino como preguntas, porque su respuesta no es conocida y requiere investigación o experimentación específica.

¿Cómo se comporta el pipeline sobre corpus en español con documentación técnica del sector eléctrico? Esta es la pregunta con mayor urgencia práctica. Responderla requiere construir un corpus piloto en español sobre documentación real de Iberdrola, anotar un conjunto de pares pregunta-respuesta de referencia, y ejecutar los mismos experimentos de Recall@k con los que se evaluó el escenario de motos. El resultado determinará si la arquitectura actual es desplegable



directamente o si requiere ajustes específicos para el idioma y el vocabulario técnico del dominio.

¿Puede ColPali o ColQwen2-VL cerrar la brecha con el estado del arte sin fine-tuning en el dominio EMIE? La literatura reporta que ColQwen2-VL supera a ColPali en +5,3 nDCG@5 en el benchmark ViDoRe, y que ambos superan a los sistemas de embedding single-vector. La pregunta relevante para EMIE no es si lo hacen en benchmarks públicos, sino si esa ventaja se mantiene sobre documentación técnica industrial en español. Un experimento controlado que compare Vertex AI (actual) con ColQwen2-VL sobre el mismo escenario de motos y sobre el corpus piloto de Iberdrola respondería esta pregunta.

¿Qué impacto introduce la transcripción ASR sobre el rendimiento de recuperación en terminología técnica industrial? El caso de uso de mantenimiento requiere interacción por voz. La integración de Whisper como ASR antes del pipeline de embedding introduce errores de transcripción cuya magnitud en terminología técnica industrial en español (referencias de componentes, nombres de procedimientos, acrónimos normativos) es desconocida. Un experimento que mida el Word Error Rate de Whisper sobre un corpus de audio de técnicos de mantenimiento y evalúe cómo los errores de transcripción degradan el Recall@k del pipeline sería la base necesaria para diseñar el Nivel 4 del caso de uso A.

¿Puede la extracción estructurada de tablas eliminar las alucinaciones de atributo, o son una limitación más profunda del generador? La hipótesis de mitigación propuesta en la sección 7.4 consiste en proporcionar al generador los datos numéricos de las tablas en formato textual estructurado, extraídos con herramientas especializadas como Camelot o TATR, en lugar de pedirle que los interprete visualmente. Si esta intervención elimina o reduce significativamente el comportamiento alucinatorio, el problema tiene solución arquitectónica dentro del pipeline actual. Si el problema persiste incluso con datos tabulares correctamente estructurados, apuntaría a una limitación más fundamental del modelo generador que requeriría evaluación de alternativas.

¿Cuál es la latencia real del pipeline en condiciones de uso por técnicos en campo? Los experimentos de este trabajo se ejecutaron en entorno de laboratorio sin restricciones de latencia. Un técnico de mantenimiento que opera desde un dispositivo móvil en una planta industrial con conectividad limitada experimenta el sistema de forma radicalmente distinta. Medir la latencia extremo a extremo del pipeline (embedding de la consulta, búsqueda vectorial, generación de respuesta) bajo condiciones reales de red y carga, y contrastarla con los SLAs que los propios técnicos consideran aceptables, es una pregunta con respuesta empírica directa que debe responderse antes de iniciar el piloto del Nivel 3 del caso de uso A.

9.6 Reflexión final

Una parte sustancial del conocimiento técnico industrial está atrapada en formatos que los sistemas de recuperación convencionales no pueden explotar: páginas de manuales con esquemas y fotografías, tablas de especificaciones integradas en documentos complejos, diagramas de despiece donde el texto y la imagen son

inseparables. Ese conocimiento existe, está en los servidores de las empresas, pero para el sistema RAG textual es invisible. La investigación desarrollada en esta línea de trabajo de EMIE es un paso concreto y documentado hacia hacer visible ese conocimiento.

Los hallazgos no son todos positivos, y eso es precisamente su valor. Saber que la estrategia página-como-imagen funciona con Vertex AI pero no con Voyage AI en identificación visual; saber que el modality gap no predice el rendimiento de la forma que la teoría sugeriría; saber que Gemini alucina con datos numéricos en tablas de una manera que resulta peligrosa en un entorno industrial: todo esto es conocimiento que un competidor que no haya hecho esta investigación no tiene. La investigación rigurosa que produce resultados negativos documentados es, en ingeniería de sistemas de IA, tan valiosa como la que confirma hipótesis.

El proyecto EMIE tiene ahora una base experimental sólida, un pipeline de referencia validado, una evaluación crítica de sus limitaciones y una hoja de ruta técnica para cerrarlas. Lo que queda por delante es, fundamentalmente, trabajo de ingeniería aplicada orientado por preguntas claras.



10. Referencias Bibliográficas

- Yin, S., Fu, C., Zhao, S., Li, K., Sun, X., Xu, T., & Chen, E. (2023). *A Survey on Multimodal Large Language Models*. arXiv. URL: <https://arxiv.org/abs/2306.13549>
- Zhu, X., Zhang, Z., Chen, X., Shi, Y., Li, M., & Wu, J. (2025). *Connector-S: A Survey of Connectors in Multi-modal Large Language Models*. arXiv. URL: <https://arxiv.org/abs/2502.11453>
- Zhang, X., Guo, J., Zhao, S., Fu, M., Duan, L., Wang, G.-H., Chen, Q.-G., Xu, Z., Luo, W., & Zhang, K. (2025). *Unified Multimodal Understanding and Generation Models: Advances, Challenges, and Opportunities*. arXiv. URL: <https://arxiv.org/abs/2505.02567>
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). *Learning Transferable Visual Models From Natural Language Supervision*. ICML / PMLR. URL: <https://arxiv.org/abs/2103.00020>
- Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., & Houlsby, N. (2021). *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. ICLR. URL: <https://arxiv.org/abs/2010.11929>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR. URL: <https://arxiv.org/abs/1512.03385>
- Kingma, D. P., & Welling, M. (2014). *Auto-Encoding Variational Bayes*. arXiv. URL: <https://arxiv.org/abs/1312.6114>
- Alayrac, J.-B., Donahue, J., Luc, P., Miech, A., Barr, I., Hasson, Y., Lenc, K., Mensch, A., Millican, K., Reynolds, M., Ring, R., Rutherford, E., Cabi, S., Han, T., Gong, Z., Samangooei, S., Monteiro, M., Menick, J., Borgeaud, S., Brock, A., Nematzadeh, A., Sharifzadeh, S., Binkowski, M., Barreira, R., Vinyals, O., Zisserman, A., & Simonyan, K. (2022). *Flamingo: a Visual Language Model for Few-Shot Learning*. NeurIPS. URL: <https://arxiv.org/abs/2204.14198>
- Li, J., Li, D., Savarese, S., & Hoi, S. (2023). *BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models*. ICML / PMLR. URL: <https://arxiv.org/abs/2301.12597>
- Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). *Visual Instruction Tuning*. NeurIPS. URL: <https://arxiv.org/abs/2304.08485>
- Liu, H., Li, C., Li, Y., & Lee, Y. J. (2023). *Improved Baselines with Visual Instruction Tuning*. arXiv. URL: <https://arxiv.org/abs/2310.03744>
- Wang, P., Bai, S., Tan, S., Wang, Y., Fan, Z., Bai, J., Chen, K., Liu, J., Wang, J., Ge, W., Fan, Y., Dang, K., Du, M., Ren, X., Men, R., Liu, D., Zhou, C., Zhou, J., &

- Lin, J. (2024). *Qwen2-VL: Enhancing Vision-Language Model's Perception of the World at Any Resolution*. arXiv. URL: <https://arxiv.org/abs/2409.12191>
- Bai, S., et al. (2025). *Qwen2.5-VL Technical Report*. arXiv. URL: <https://arxiv.org/abs/2502.13923>
 - Li, B., Zhang, Y., Guo, D., Zhang, R., Li, F., Zhang, H., Zhang, K., Zhang, P., Li, Y., Liu, Z., & Li, C. (2024). *LLaVA-OneVision: Easy Visual Task Transfer*. arXiv. URL: <https://arxiv.org/abs/2408.03326>
 - Xu, J., Guo, Z., He, J., Hu, H., He, T., Bai, S., Chen, K., Wang, J., Fan, Y., Dang, K., Zhang, B., Wang, X., Chu, Y., & Lin, J. (2025). *Qwen2.5-Omni Technical Report*. arXiv. URL: <https://arxiv.org/abs/2503.20215>
 - Chu, Y., et al. (2024). *Qwen2-Audio Technical Report*. arXiv. URL: <https://arxiv.org/abs/2407.10759>
 - Baevski, A., Zhou, H., Mohamed, A., & Auli, M. (2020). *wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations*. NeurIPS. URL: <https://arxiv.org/abs/2006.11477>
 - Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). *Robust Speech Recognition via Large-Scale Weak Supervision*. ICML / PMLR. URL: <https://arxiv.org/abs/2212.04356>
 - Ramesh, A., Dhariwal, P., Nichol, A., Chu, C., & Chen, M. (2022). *Hierarchical Text-Conditional Image Generation with CLIP Latents*. arXiv. URL: <https://arxiv.org/abs/2204.06125>
 - Rombach, R., Blattmann, A., Lorenz, D., Esser, P., & Ommer, B. (2022). *High-Resolution Image Synthesis with Latent Diffusion Models*. CVPR. URL: <https://arxiv.org/abs/2112.10752>
 - Yue, X., Ni, Y., Zhang, K., Zheng, T., Liu, R., Zhang, G., Stevens, S., Jiang, D., Ren, W., Sun, Y., Wei, C., Yu, B., Yuan, R., Sun, R., Yin, M., Zheng, B., Yang, Z., Liu, Y., Huang, W., Sun, H., Su, Y., & Chen, W. (2024). *MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI*. CVPR. URL: <https://arxiv.org/abs/2311.16502>
 - Chen, L., Li, J., Dong, X., Zhang, P., Zang, Y., Chen, Z., Duan, H., Wang, J., Qiao, Y., Lin, D., & Zhao, F. (2024). *Are We on the Right Way for Evaluating Large Vision-Language Models?* NeurIPS. URL: <https://arxiv.org/abs/2403.20330>
 - Liang, W., Zhang, Y., Kwon, Y., Yeung, S., & Zou, J. Y. (2022). *Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning*. NeurIPS, 35, 17612–17625. URL: <https://arxiv.org/abs/2203.02053>
 - Eshraghi, S., et al. (2025). *Mitigate the Gap: Improving Cross-Modal Alignment in CLIP*. ICLR 2025. URL: <https://openreview.net/forum?id=aPTGvFqile>
 - Abootorabi, M. M., et al. (2025). *Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation*. arXiv:2502.08826. URL: <https://arxiv.org/abs/2502.08826>
 - Wasserman, N., et al. (2025). *REAL-MM-RAG: A Real-World Multi-Modal Retrieval Benchmark*. ACL 2025. URL: <https://aclanthology.org/2025.acl-long.1528.pdf>

- Yang, Y., et al. (2025). Benchmarking Multimodal RAG through a Chart-based Document Question-Answering Generation Framework. *arXiv:2502.14864*. URL: <https://arxiv.org/abs/2502.14864>
- Hu, W., et al. (2024). MRAG-Bench: Vision-Centric Evaluation for Retrieval-Augmented Multimodal Models. *arXiv:2410.08182*. URL: <https://mragebench.github.io/>
- Xiao, S., et al. (2025). MIEB: Massive Image Embedding Benchmark. HuggingFace MTEB Leaderboard. URL: <https://hf.co/spaces/mteb/leaderboard>
- Cho, J., et al. (2024). M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding. *arXiv*.
- Douze, M., et al. (2024). The Faiss Library. *arXiv:2401.08281*. URL: <https://arxiv.org/abs/2401.08281>
- RAGFlow (2025). From RAG to Context — A 2025 Year-End Review of RAG. URL: <https://ragflow.io/blog/rag-review-2025-from-rag-to-context>
- Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *NeurIPS 2020*. URL: <https://arxiv.org/abs/2005.11401>
- Abootorabi, M. M., et al. (2025). Ask in Any Modality: A Comprehensive Survey on Multimodal Retrieval-Augmented Generation. *arXiv:2502.08826*.
- Faysse, M., Sibille, H., Wu, T., Omrani, B., Viaud, G., Hudelot, C., & Colombo, P. (2025). ColPali: Efficient Document Retrieval with Vision Language Models. *ICLR 2025*. URL: <https://arxiv.org/abs/2407.01449>
- Cho, J., Mahata, D., Irsoy, O., He, Y., & Bansal, M. (2024). M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding. *arXiv:2411.04952*. URL: <https://arxiv.org/abs/2411.04952>
- Liang, W., Zhang, Y., Kwon, Y., Yeung, S., & Zou, J. Y. (2022). Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning. *NeurIPS 2022*. URL: <https://arxiv.org/abs/2203.02053>
- Eshraghi, S., et al. (2025). Mitigate the Gap: Improving Cross-Modal Alignment in CLIP. *ICLR 2025*. URL: <https://openreview.net/forum?id=aPTGvFqile>
- van den Oord, A., Li, Y., & Vinyals, O. (2018). Representation Learning with Contrastive Predictive Coding. *arXiv:1807.03748*.
- Lin, Z., et al. (2023). Relaxing Contrastiveness in Multimodal Representation Learning. *WACV 2023*. URL: https://openaccess.thecvf.com/content/WACV2023/papers/Lin_Relaxing_Contrastiveness_in_Multimodal_Representation_Learning_WACV_2023_paper.pdf
- Elizalde, B., et al. (2023). CLAP: Learning Audio Concepts from Natural Language Supervision. *ICASSP 2023*. URL: <https://arxiv.org/abs/2206.04769>
- Xu, J., et al. (2025). Qwen2.5-Omni Technical Report. *arXiv:2503.20215*. URL: <https://arxiv.org/abs/2503.20215>
- Yang, Y., et al. (2025). Benchmarking Multimodal RAG through a Chart-based Document Question-Answering Generation Framework. *arXiv:2502.14864*.

- RAGFlow (2025). From RAG to Context — A 2025 Year-End Review of RAG. URL: <https://ragflow.io/blog/rag-review-2025-from-rag-to-context>
- Xiao, S., et al. (2025). MIEB: Massive Image Embedding Benchmark. URL: <https://hf.co/spaces/mteb/leaderboard>
- Liang, W., Zhang, Y., Kwon, Y., Yeung, S., & Zou, J. Y. (2022). Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning. NeurIPS 2022. URL: <https://arxiv.org/abs/2203.02053>
- Schrod, S., Hoffmann, D. T., Argus, M., Fischer, V., & Brox, T. (2024). Two Effects, One Trigger: On the Modality Gap, Object Bias, and Information Imbalance in Contrastive Vision-Language Models. arXiv.
- Dai, Z., et al. (2024). Explaining and Mitigating the Modality Gap in Contrastive Multimodal Learning. arXiv:2412.07909. URL: <https://arxiv.org/abs/2412.07909>
- Eshraghi, S., et al. (2025). Mitigate the Gap: Improving Cross-Modal Alignment in CLIP. ICLR 2025. URL: <https://openreview.net/forum?id=aPTGvFqile>
- Faysse, M., et al. (2025). ColPali: Efficient Document Retrieval with Vision Language Models. ICLR 2025. URL: <https://arxiv.org/abs/2407.01449>
- Cho, J., et al. (2024). M3DocRAG: Multi-modal Retrieval is What You Need for Multi-page Multi-document Understanding. arXiv:2411.04952. URL: <https://arxiv.org/abs/2411.04952>
- Yang, Y., et al. (2025). Benchmarking Multimodal RAG through a Chart-based Document Question-Answering Generation Framework. arXiv:2502.14864. URL: <https://arxiv.org/abs/2502.14864>
- Liu, H., et al. (2024). A Survey on Hallucination in Large Vision-Language Models. arXiv:2402.00253. URL: <https://arxiv.org/abs/2402.00253>
- Huang, L., et al. (2024). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. ACM TOIS. URL: <https://arxiv.org/abs/2311.05232>
- Hu, W., et al. (2024). MRAG-Bench: Vision-Centric Evaluation for Retrieval-Augmented Multimodal Models. arXiv:2410.08182. URL: <https://mragbench.github.io/>
- Wasserman, N., et al. (2025). REAL-MM-RAG: A Real-World Multi-Modal Retrieval Benchmark. ACL 2025. URL: <https://aclanthology.org/2025.acl-long.1528.pdf>
- Chen, L., et al. (2024). Are We on the Right Way for Evaluating Large Vision-Language Models? NeurIPS 2024. URL: <https://arxiv.org/abs/2403.20330>
- RAGFlow (2025). From RAG to Context — A 2025 Year-End Review. URL: <https://ragflow.io/blog/rag-review-2025-from-rag-to-context>
- Vectara (2025). Open RAG Benchmark. URL: <https://www.vectara.com/blog/open-rag-benchmark-a-new-frontier-for-multimodal-pdf-understanding-in-rag>
-

